

The background is a dark grey canvas filled with a complex, abstract composition of various data visualization elements. On the left side, there are three vertically stacked charts: a line graph with multiple overlapping lines, a line graph with two distinct wave patterns, and a bar chart with numerous vertical bars of varying heights. On the right side, there are three vertically stacked charts: a line graph with a single wavy line, a bar chart with tall, thin vertical bars, and a line graph with a single smooth wave. Scattered throughout the center and around these charts are numerous geometric shapes, including circles of different sizes and colors (orange, red, yellow, white), some of which are divided into segments like pie charts. Thin white lines and arcs connect these shapes, creating a sense of movement and interconnectedness. The overall aesthetic is technical and analytical, with a color palette dominated by warm tones like orange, red, and yellow against the dark background.

# Case-Study zur Arbeitslosigkeit in Deutschland

# Organisatorische Hinweise

- + Viele Deadlines
- + Ungewohntes Format (sehr technisch)
- + Github, RStudio, R
- + Arbeitsschritte mit Github (3. Problem Set von Github herunterladen und lösen)

Dies ist alles neu und das ist uns bewusst!

Warum das Ganze?

# Organisatorische Hinweise

- + Viele Deadlines
- + Ungewohntes Format (sehr technisch)
- + Github, RStudio, R
- + Arbeitsschritte mit Github (3. Problem Set von Github herunterladen und lösen)

Dies ist alles neu und das ist uns bewusst!

Warum das Ganze?

- + Durch die Deadlines sollten Sie sich mit dem Stoff auseinandersetzen
- + Github, R, RStudio und RMarkdown müssen Sie in den Projekten nutzen → Üben mit RTutor
- + Visualisierung, Interpretation und Präsentation in den Projekten gefragt → Üben mit der Case-Study
- + Arbeiten mit AI → Lernen wie AI ihre Arbeit sinnvoll ergänzen kann und wo nicht

# Recap letzte Vorlesungseinheit

- + Verschiedene Arten einen Datensatz einzulesen
  - + `readr`, `readxl`, `haven`...
- + Variablenbezeichnungen stehen nicht zwangsläufig in erster Spalte
- + Es gibt oft und viele `NA`s in echten Daten
  - + Konsistenzchecks wichtig
- + Datensätze sind nicht immer in der Form das wir diese direkt Einlesen können
  - + Aus verschiedenen Quellen einlesen, z.B. über eine `for`-Schleife oder `lapply`
  - + Umformen, da die Daten im `wide`-Format vorliegen -> `pivot_longer`
- + Es ist wichtig sich selbst ein Bild von den Daten zu machen

# Analyse der Daten

# Deskriptive vs. induktive Statistik

- + Deskriptive Statistik (beschreibende Statistik) ist beschreibend (wer hätte es gedacht)
- + Induktive (auch schließende) Statistik versucht aus der Stichprobe auf die Grundgesamtheit zu schließen

# Deskriptive vs. induktive Statistik

- ✚ Deskriptive Statistik (beschreibende Statistik) ist beschreibend (wer hätte es gedacht)
- ✚ Induktive (auch schließende) Statistik versucht aus der Stichprobe auf die Grundgesamtheit zu schließen
- ✚ Keine Unterscheidung in der Formel
- ✚ Keine Unterscheidung in dem Datensatz der verwendet wird

# Deskriptive vs. induktive Statistik

- + Deskriptive Statistik (beschreibende Statistik) ist beschreibend (wer hätte es gedacht)
- + Induktive (auch schließende) Statistik versucht aus der Stichprobe auf die Grundgesamtheit zu schließen
- + Keine Unterscheidung in der Formel
- + Keine Unterscheidung in dem Datensatz der verwendet wird

Worin genau besteht der Unterschied zwischen der deskriptiven und der induktiven Statistik?



# Deskriptive Statistik

- + Beschreibung des Datensatzes
  - + **Beispiel:** Daten von der Agentur für Arbeit über die Arbeitslosenquote in den Landkreisen
- + Mehrere Arten denkbar
  - + Tabellenform
  - + Visualisierung mittels Schaubildern

Sie wollen etwas über ihren aktuellen Datensatz lernen.

# Induktive Statistik

- + Interesse gilt nicht dem Datensatz selbst, sondern der Population
  - + Sie haben keine Vollerhebung durchgeführt, sondern nur eine (zufällige) Stichprobe der Population gezogen
- + **Beispiel:** Mikrozensus, d.h. eine Befragung von zufällig ausgewählten Haushalten in Deutschland
- + Sie wollen aus der Stichprobe schätzen, wie sich die beobachtete Größe in der Population verhält
- + Es gibt viele Arten der induktiven Statistik. Die zwei häufigsten:
  - + Vorhersage
  - + Erkennen kausaler Zusammenhänge

# Induktive Statistik

- + Interesse gilt nicht dem Datensatz selbst, sondern der Population
  - + Sie haben keine Vollerhebung durchgeführt, sondern nur eine (zufällige) Stichprobe der Population gezogen
- + **Beispiel:** Mikrozensus, d.h. eine Befragung von zufällig ausgewählten Haushalten in Deutschland
- + Sie wollen aus der Stichprobe schätzen, wie sich die beobachtete Größe in der Population verhält
- + Es gibt viele Arten der induktiven Statistik. Die zwei häufigsten:
  - + Vorhersage
  - + Erkennen kausaler Zusammenhänge

In die induktive Statistik tauchen wir nächstes Semester tiefer ein.

# Deskriptive Statistik


# Univariate deskriptive Statistik

- + Eine Variable wird dargestellt:
  - + Verteilung
  - + Mittelwert
  - + Standardabweichung
  - + Median
  - + Quantile
- + Überblick verschaffen, Eigenschaften der Variablen aufzeigen

# Univariate deskriptive Statistik

- + Darstellung über eine Tabelle
  - + Median, Mittelwert, Standardabweichung und Quantile
- + Darstellung über einen Boxplot
  - + Median, Inter-Quartile-Range (ICR), Ausreißer
- + Darstellung über ein Histogramm
  - + Verteilung mit Anzahl an Beobachtungen
- + Darstellung über einen Kerndichteschätzer
  - + Verteilung mit Dichte

# Univariate descriptive Statistik (Boxplot)



# Bivariate deskriptive Statistik

Darstellung von Zusammenhängen zweier Variablen

- + Korrelation zweier Variablen
- + Wenn sich eine Variable verändert, wie verändert sich die andere Variable?

Darstellung als:

- + Streudiagramm
- + Korrelationskoeffizient (meist innerhalb einer Korrelationsmatrix)



Wie sieht die deskriptive Statistik in  
der Praxis aus?

# Zweiter Teil der Case Study

Eingelesene Daten deskriptiv untersuchen

- + Erster Schritt: Deskriptive Tabellen mit `kableExtra` und `gt`
- + Zweiter Schritt: Grafiken mit `ggplot2`

# Zweiter Teil der Case Study

Eingelesene Daten deskriptiv untersuchen

- + Erster Schritt: Deskriptive Tabellen mit `kableExtra` und `gt`
- + Zweiter Schritt: Grafiken mit `ggplot2`

Ziele des zweiten Teils der Case Study:

- + Daten visualisieren und Zusammenhänge grafisch veranschaulichen
- + Deskriptive Analysen mittels Korrelationstabellen und deskriptiven Tabellen anfertigen
- + Das Verständnis, wie Sie ihre Informationen zu bestimmten Fragestellungen möglichst effektiv aufbereiten
- + Interaktive Grafiken erstellen

# Zweiter Teil der Case Study

Eingelesene Daten deskriptiv untersuchen

- + Erster Schritt: Deskriptive Tabellen mit `kableExtra` und `gt`
- + Zweiter Schritt: Grafiken mit `ggplot2`

Ziele des zweiten Teils der Case Study:

- + Daten visualisieren und Zusammenhänge grafisch veranschaulichen
- + Deskriptive Analysen mittels Korrelationstabellen und deskriptiven Tabellen anfertigen
- + Das Verständnis, wie Sie ihre Informationen zu bestimmten Fragestellungen möglichst effektiv aufbereiten
- + Interaktive Grafiken erstellen

Im dritten RTutor Problem Set werden Sie Visualisierung zu einzelnen Ländern auf europäischer Ebene erstellen.

# Daten und Pakete laden

Wir laden die aus Teil 1 erstellten Datensätze:

```
library(tidyverse)
library(skimr)
library(sf)
library(viridis)
library(plotly)
library(kableExtra)
library(gt)
library(corrrr)
```

```
# Daten einlesen
einkommen <- readRDS("../case-study/data/einkommen.rds")
bundesland <- readRDS("../case-study/data/bundesland.rds")
landkreise <- readRDS("../case-study/data/landkreise.rds")
bip_zeitreihe <- readRDS("../case-study/data/bip_zeitreihe.rds")
gemeinden <- readRDS("../case-study/data/gemeinden.rds")
gesamtdaten <- readRDS("../case-study/data/gesamtdaten.rds")
schulden_bereinigt <- readRDS("../case-study/data/schulden_bereinigt.rds")
```

# Deskriptive Analysen

# Arbeitslosenquote berechnen

**Zuerst:** Überblick über die Daten gewinnen

- + Wie viele Landkreise haben wir in den Daten?
- + Wie ist die Verteilung der Schulden, Arbeitsquote und des BIP?

# Arbeitslosenquote berechnen

**Zuerst:** Überblick über die Daten gewinnen

- + Wie viele Landkreise haben wir in den Daten?
- + Wie ist die Verteilung der Schulden, Arbeitsquote und des BIP?

Hierzu müssen wir erst noch die Arbeitslosenquote berechnen:

$$\text{Arbeitslosenquote} = \text{Erwerbslose} / (\text{Erwerbstätige} + \text{Erwerbslose})$$

```
# Zuerst wollen wir uns noch die Arbeitslosenquote pro Landkreis berechnen
gesamtdaten <- gesamtdaten %>%
  mutate(alo_quote = (total_alo / (erw+total_alo))*100)
```



# Anzahl an Beobachtungen

**Quick and dirty** (einfacher Tibble Datensatz): Einen Blick auf die Anzahl an Erwerbstätigen und Einwohnern in Deutschland werfen.

```
# Wie viele Erwerbstätige und Einwohner (ohne Berlin, Hamburg, Bremen und Bremerhaven) hat Deutschland?  
gesamtdaten %>%  
  summarise(total_erw = sum(erw, na.rm=TRUE), total_einwohner = sum(Einwohner, na.rm=TRUE))
```

```
## # A tibble: 1 × 2  
##   total_erw total_einwohner  
##       <dbl>         <dbl>  
## 1  42115549      78122610
```

# Anzahl an Beobachtungen

**Quick and dirty** (einfacher Tibble Datensatz): Einen Blick auf die Anzahl an Erwerbstätigen und Einwohnern in Deutschland werfen.

```
# Wie viele Erwerbstätige und Einwohner (ohne Berlin, Hamburg, Bremen und Bremerhaven) hat Deutschland?  
gesamtdaten %>%  
  summarise(total_erw = sum(erw, na.rm=TRUE), total_einwohner = sum(Einwohner, na.rm=TRUE))
```

```
## # A tibble: 1 × 2  
##   total_erw total_einwohner  
##   <dbl>         <dbl>  
## 1  42115549      78122610
```

- ✚ 42,1 Mio. Erwerbstätige und 78,1 Mio. Einwohner in Deutschland
- ✚ Folgende Stadtstaaten sind nicht in unseren Berechnungen enthalten:
  - ✚ Hamburg (1,8 Mio.)
  - ✚ Berlin (3,8 Mio.)
  - ✚ Bremen (0,6 Mio.)
  - ✚ Bremerhaven (0,1 Mio.)

# Anzahl an Beobachtungen

*Etwas besser mit `skimr` Daten veranschaulichen*

# Anzahl an Beobachtungen

*Etwas besser mit `skimr` Daten veranschaulichen*

```
# Anschließend wollen wir eine Summary Statistic für alle Variablen ausgeben lassen
# Entfernen der Histogramme, damit alles auch schön in PDF gedruckt werden kann
gesamtdaten %>%
  select(aio_quote, Schulden_pro_kopf_lk, bip_pro_kopf, landkreis_name) %>%
  skim_without_charts() %>%
  summary()
```

# Anzahl an Beobachtungen

Table: Data summary

|                        |            |
|------------------------|------------|
| Name                   | Piped data |
| Number of rows         | 400        |
| Number of columns      | 4          |
| —                      |            |
| Column type frequency: |            |
| character              | 1          |
| numeric                | 3          |
| —                      |            |
| Group variables        | None       |

# Anzahl an Beobachtungen

✚ 400 individuelle Beobachtungen in unserem Datensatz.

Hierbei handelt es sich um alle Landkreise und kreisfreien Städte in Deutschland.

Stimmen diese Angaben?

# Anzahl an Beobachtungen

- + 400 individuelle Beobachtungen in unserem Datensatz.

Hierbei handelt es sich um alle Landkreise und kreisfreien Städte in Deutschland.

Stimmen diese Angaben?

- + In Deutschland gibt es 294 Landkreise)
- + Weiterhin gibt es in Deutschland 106 kreisfreie Städte

(Quelle: Wikipedia)

# Anzahl an Beobachtungen

Variable type: character

| skim_variable  | n_missing | complete_rate | min | max | empty | n_unique | whitespace |
|----------------|-----------|---------------|-----|-----|-------|----------|------------|
| landkreis_name | 0         | 1             | 3   | 32  | 0     | 378      | 0          |

- + Nur 378 unterschiedliche Landkreis Namen in unserem Datensatz mit 400 unterschiedlichen Beobachtungen (Regionalschlüsseln).

Woher kommt dies?



# Anzahl an Beobachtungen

Variable type: character

| skim_variable  | n_missing | complete_rate | min | max | empty | n_unique | whitespace |
|----------------|-----------|---------------|-----|-----|-------|----------|------------|
| landkreis_name | 0         | 1             | 3   | 32  | 0     | 378      | 0          |

- + Nur 378 unterschiedliche Landkreis Namen in unserem Datensatz mit 400 unterschiedlichen Beobachtungen (Regionalschlüsseln).

Woher kommt dies?

- + Stadt München ist eine Beobachtung
- + Landkreis München eine weitere Beobachtung

Beide haben unterschiedliche Regionalschlüssel. D.h. der "landkreis\_name" ist der gleiche, jedoch ist der Regionalschlüssel ein anderer.

# Anzahl an Beobachtungen

Nun möchten wir uns noch die einzelnen Variablen aus dem Datensatz näher anschauen:

**Variable type: numeric**

| skim_variable        | n_missing | complete_rate | mean      | sd        | p0       | p25       | p50       | p75       | p100      |
|----------------------|-----------|---------------|-----------|-----------|----------|-----------|-----------|-----------|-----------|
| alo_quote            | 2         | 1.00          | 5.29      | 2.08      | 1.64     | 3.63      | 5.07      | 6.62      | 14.2      |
| Schulden_pro_kopf_lk | 4         | 0.99          | 3051.94   | 2303.19   | 202.36   | 1564.83   | 2367.83   | 3778.56   | 17680.7   |
| bip_pro_kopf         | 2         | 1.00          | 42801.26  | 17280.40  | 17953.34 | 32377.34  | 38778.96  | 46569.47  | 149442.9  |
| Einwohner            | 4         | 0.99          | 197279.32 | 153820.49 | 34607.00 | 104722.25 | 157359.00 | 241283.75 | 1502969.0 |

# Anzahl an Beobachtungen

- + Fehlende Beobachtungen für Schulden pro Kopf: *vier* Landkreise
- + Fehlende Beobachtung für Einwohner: *vier* Landkreise
- + Fehlende Beobachtungen für BIP pro Kopf: *zwei* Landkreise
- + Fehlende Beobachtungen für die Arbeitslosenquote: *zwei* Landkreise

```
gesamtdaten %>%  
  filter(is.na(Einwohner)) %>%  
  select(landkreis_name)
```

```
## # A tibble: 4 × 1  
##   landkreis_name  
##   <chr>  
## 1 Hamburg  
## 2 Bremen  
## 3 Bremerhaven  
## 4 Berlin
```

# Anzahl an Beobachtungen

- + Fehlende Beobachtungen für Schulden pro Kopf: *vier* Landkreise
- + Fehlende Beobachtung für Einwohner: *vier* Landkreise
- + Fehlende Beobachtungen für BIP pro Kopf: *zwei* Landkreise
- + Fehlende Beobachtungen für die Arbeitslosenquote: *zwei* Landkreise

```
gesamtdaten %>%  
  filter(is.na(Einwohner)) %>%  
  select(landkreis_name)
```

```
## # A tibble: 4 × 1  
##   landkreis_name  
##   <chr>  
## 1 Hamburg  
## 2 Bremen  
## 3 Bremerhaven  
## 4 Berlin
```

Wir können diese Landkreise nicht mit in unsere Analyse mit einbeziehen auf Grund der fehlenden Informationen zu Einwohnern!

# Beschreibung der Tabelle

Variable type: numeric

| skim_variable        | n_missing | complete_rate | mean     | sd       | p0       | p25      | p50      | p75      | p100      |
|----------------------|-----------|---------------|----------|----------|----------|----------|----------|----------|-----------|
| alo_quote            | 2         | 1.00          | 5.29     | 2.08     | 1.64     | 3.63     | 5.07     | 6.62     | 14.23     |
| Schulden_pro_kopf_lk | 4         | 0.99          | 3051.94  | 2303.19  | 202.36   | 1564.83  | 2367.83  | 3778.56  | 17680.79  |
| bip_pro_kopf         | 2         | 1.00          | 42801.26 | 17280.40 | 17953.34 | 32377.34 | 38778.96 | 46569.47 | 149442.98 |

# Beschreibung der Tabelle

Variable type: numeric

| skim_variable        | n_missing | complete_rate | mean     | sd       | p0       | p25      | p50      | p75      | p100      |
|----------------------|-----------|---------------|----------|----------|----------|----------|----------|----------|-----------|
| alo_quote            | 2         | 1.00          | 5.29     | 2.08     | 1.64     | 3.63     | 5.07     | 6.62     | 14.23     |
| Schulden_pro_kopf_lk | 4         | 0.99          | 3051.94  | 2303.19  | 202.36   | 1564.83  | 2367.83  | 3778.56  | 17680.79  |
| bip_pro_kopf         | 2         | 1.00          | 42801.26 | 17280.40 | 17953.34 | 32377.34 | 38778.96 | 46569.47 | 149442.98 |

Bitte diskutieren Sie mit ihrem/ihrer Sitznachbar\*in und beschreiben Sie die Tabelle in ihren eigenen Worten!

Gehen Sie hierbei bitte auf **eine Variable** (alo\_quote, Schulden\_pro\_Kopf\_lk, bip\_pro\_kopf) und die folgenden Punkte ein:

- + Mittelwert
- + Standardabweichung
- + Median

05:00

# Arbeitslosenquote

Mittelwert: 5,29 Prozent

- + Hoch
- + Jedoch SGB II und SGB III
- + Konsistenzcheck auf [Statista](#) zeigt eine Arbeitslosenquote von 5,7% für 2023
- + **Jedoch:** Wir haben nicht Berlin und Hamburg in den Daten

Standardabweichung: 2,08

- + Sehr hohe Streuung
- + Deutliche regionale Unterschiede
- + Ist in Prozentpunkten

Median: 5,07 Prozent

- + Nahe am Mittelwert
- + Deutet darauf hin das es wenige Landkreise mit sehr extremen Ausreißern gibt

# Verschuldung pro Kopf

Mittelwert: 3052€

- + Relativ hoch

Standardabweichung: 2303€

- + Sehr hohe Streuung

- + Deutliche regionale Unterschiede

Median: 2368€

- + Weiter weg vom Mittelwert

- + Deutet darauf hin das es einzelne Landkreise mit sehr extremen Ausreißern gibt



# BIP pro Kopf

Mittelwert: 42801€

- + Insgesamt recht hoch
- + Starker Wirtschaftsstandort Deutschland

Standardabweichung: 17280€

- + Sehr hohe Streuung
- + Deutliche regionale Unterschiede
- + Könnte von einzelnen Landkreisen getrieben werden

Median: 38779€

- + Weiter weg vom Mittelwert
- + Deutet darauf hin das es einzelne Landkreise mit sehr extremen Ausreißern gibt

# Die Arbeitslosenquote auf Bundeslandebene

# Die Arbeitslosenquote auf Bundeslandebene

Es gibt deutliche Unterschiede in der Arbeitslosenquote über die Bundesländer hinweg!

Wir betrachten:

- + Querschnittsdaten aus 2023
- + Alle Landkreise
- + Für einige Landkreise haben wir keine Informationen (sogenannte "Missing values" -> `n_missing`)

Wir möchten nun die regionale Verteilung der Arbeitslosenquote in Deutschland im Jahr 2023 näher betrachten.

# Die Arbeitslosenquote auf Bundeslandebene

Zuerst aggregieren wir die Daten auf Bundeslandebene:

```
bula_data <- gesamtdaten %>%  
  group_by( bundesland_name ) %>%  
  summarise(mean_alo = mean(alo_quote), sd_alo = sd(alo_quote), median_alo = median(alo_quote), .groups = 'dr
```

# Die Arbeitslosenquote auf Bundeslandebene

count: false

```
gesamtdaten
```

```
## # A tibble: 400 × 12
##   Regionalschlüssel total_alo landkreis_name bundesland bundesland_name
##   <chr>                <dbl> <chr>          <chr>      <chr>
## 1 01001                4131. Flensburg    01        Schleswig-Holst
## 2 01002               10581 Kiel          01        Schleswig-Holst
## 3 01003                9216. Lübeck     01        Schleswig-Holst
## 4 01004                3604. Neumünster  01        Schleswig-Holst
## 5 01051                4126. Dithmarschen  01        Schleswig-Holst
## 6 01053                5586. Herzogtum Lauenburg 01        Schleswig-Holst
## 7 01054                4491. Nordfriesland  01        Schleswig-Holst
## 8 01055                5176. Ostholstein   01        Schleswig-Holst
## 9 01056                9280. Pinneberg    01        Schleswig-Holst
## 10 01057               2848. Plön        01        Schleswig-Holst
## # i 390 more rows
## # i 7 more variables: Schulden_pro_kopf_lk <dbl>, Einwohner <dbl>,
## #   Schulden_gesamt <dbl>, bip <dbl>, bip_pro_kopf <dbl>, erw <dbl>,
## #   alo_quote <dbl>
```

```
gesamtdaten %>%
```

```
  group_by( bundesland_name )
```

```
## # A tibble: 400 × 12
```

```
## # Groups:   bundesland_name [16]
```

```
##   Regionalschlüssel total_alo landkreis_name   bundesland bundesland_name
##   <chr>              <dbl> <chr>          <chr>         <chr>
## 1 01001              4131. Flensburg      01         Schleswig-Holst
## 2 01002             10581 Kiel            01         Schleswig-Holst
## 3 01003             9216. Lübeck          01         Schleswig-Holst
## 4 01004             3604. Neumünster      01         Schleswig-Holst
## 5 01051             4126. Dithmarschen    01         Schleswig-Holst
## 6 01053             5586. Herzogtum Lauenburg 01         Schleswig-Holst
## 7 01054             4491. Nordfriesland    01         Schleswig-Holst
## 8 01055             5176. Ostholstein     01         Schleswig-Holst
## 9 01056             9280. Pinneberg       01         Schleswig-Holst
## 10 01057            2848. Plön            01         Schleswig-Holst
```

```
## # i 390 more rows
```

```
## # i 7 more variables: Schulden_pro_kopf_lk <dbl>, Einwohner <dbl>,
```

```
## #   Schulden_gesamt <dbl>, bip <dbl>, bip_pro_kopf <dbl>, erw <dbl>,
```

```
## #   alo_quote <dbl>
```

```
gesamtdaten %>%  
  group_by( bundesland_name ) %>%  
  summarise(mean_alo = mean(alo_quote),  
            sd_alo = sd(alo_quote),  
            median_alo = median(alo_quote), .groups
```

# Die Arbeitslosenquote auf Bundeslandebene

Anschließend wollen wir uns eine ansprechende und informative deskriptive Tabelle erstellen:

```
## # A tibble: 14 × 4
##   bundesland_name    mean_alo sd_alo median_alo
##   <chr>            <dbl>  <dbl>    <dbl>
## 1 Bayern           3.26   0.715
## 2 Baden-Württemberg 3.73   0.722
## 3 Hessen           5.25   1.27
## 4 Rheinland-Pfalz   5.41   1.46
## 5 Schleswig-Holstein 5.76   0.832
## 6 Saarland          6.01   1.74
## 7 Niedersachsen     6.05   1.73
## 8 Sachsen           6.09   0.854
## 9 Thüringen         6.26   1.58
## 10 Brandenburg       6.75   1.51
## 11 Nordrhein-Westfalen 7.03   2.35
## 12 Mecklenburg-Vorpommern 7.64   1.22
## 13 Sachsen-Anhalt    7.84   1.43
## 14 Bremen            9.59   2.97
```



# Die Arbeitslosenquote auf Bundeslandebene

Anschließend wollen wir uns eine ansprechende und informative deskriptive Tabelle erstellen:

```
## # A tibble: 14 × 4
##   bundesland_name    mean_alo sd_alo median_alo
##   <chr>            <dbl>   <dbl>   <dbl>
## 1 Bayern           3.26    0.715
## 2 Baden-Württemberg 3.73    0.722
## 3 Hessen           5.25    1.27
## 4 Rheinland-Pfalz   5.41    1.46
## 5 Schleswig-Holstein 5.76    0.832
## 6 Saarland          6.01    1.74
## 7 Niedersachsen     6.05    1.73
## 8 Sachsen           6.09    0.854
## 9 Thüringen         6.26    1.58
## 10 Brandenburg       6.75    1.51
## 11 Nordrhein-Westfalen 7.03    2.35
## 12 Mecklenburg-Vorpommern 7.64    1.22
## 13 Sachsen-Anhalt    7.84    1.43
## 14 Bremen            9.59    2.97
```

| Bundesland             | Arbeitslosenquote |      |        |
|------------------------|-------------------|------|--------|
|                        | Mittelwert        | Std. | Median |
| Bayern                 | 3.26              | 0.72 | 3.14   |
| Baden-Württemberg      | 3.73              | 0.72 | 3.66   |
| Hessen                 | 5.25              | 1.27 | 5.37   |
| Rheinland-Pfalz        | 5.41              | 1.46 | 5.36   |
| Schleswig-Holstein     | 5.76              | 0.83 | 5.87   |
| Saarland               | 6.01              | 1.74 | 5.61   |
| Niedersachsen          | 6.05              | 1.73 | 6.22   |
| Sachsen                | 6.09              | 0.85 | 5.98   |
| Thüringen              | 6.26              | 1.58 | 5.70   |
| Brandenburg            | 6.75              | 1.51 | 7.11   |
| Nordrhein-Westfalen    | 7.03              | 2.35 | 6.62   |
| Mecklenburg-Vorpommern | 7.64              | 1.22 | 7.81   |
| Sachsen-Anhalt         | 7.84              | 1.43 | 7.75   |
| Bremen                 | 9.59              | 2.97 | 9.59   |

*Bitte beachten:*

Wir haben keine Informationen zu Berlin und Hamburg, weshalb sie nicht in der Tabelle aufgeführt wurden.

<sup>1</sup> Die ostdeutschen Bundesländer sind grau hinterlegt.

# Die Arbeitslosenquote auf Bundeslandebene

Die Darstellung mit dem Paket `kableExtra` ist deutlich ansprechender als nur einen Tibble zu zeigen!

Folgender Code wurde hier verwendet, welchen wir in der nächsten Folie Schritt für Schritt durchgehen werden:

```
bula_data %>%
  arrange( mean_alo ) %>%
  filter( !is.na(mean_alo) ) %>%
  kbl(col.names = c("Bundesland",
                   "Mittelwert",
                   "Std.",
                   "Median"), digits = 2) %>%
  kable_styling(bootstrap_options = c("striped", "hover", "condensed", "responsive")) %>%
  kable_paper(full_width = F) %>%
  row_spec(c(8,9, 10, 12,13), bold = T, color = "white", background = "#BBBBBB") %>%
  add_header_above(c(" " = 1, "Arbeitslosenquote" = 3), align = "c") %>%
  footnote(general = "Wir haben keine Informationen zu Berlin und Hamburg, weshalb sie nicht in der Tabelle a",
           general_title = "Bitte beachten: ",
           number = "Die ostdeutschen Bundesländer sind grau hinterlegt.")
```

```
bula_data
```

```
## # A tibble: 16 × 4
##   bundesland_name    mean_alo sd_alo median_alo
##   <chr>            <dbl>   <dbl>     <dbl>
## 1 Baden-Württemberg  3.73    0.722     3.66
## 2 Bayern            3.26    0.715     3.14
## 3 Berlin            NA      NA        NA
## 4 Brandenburg       6.75    1.51     7.11
## 5 Bremen            9.59    2.97     9.59
## 6 Hamburg           NA      NA        NA
## 7 Hessen            5.25    1.27     5.37
## 8 Mecklenburg-Vorpommern 7.64    1.22     7.81
## 9 Niedersachsen     6.05    1.73     6.22
## 10 Nordrhein-Westfalen 7.03    2.35     6.62
## 11 Rheinland-Pfalz    5.41    1.46     5.36
## 12 Saarland          6.01    1.74     5.61
## 13 Sachsen           6.09    0.854     5.98
## 14 Sachsen-Anhalt    7.84    1.43     7.75
## 15 Schleswig-Holstein  5.76    0.832     5.87
## 16 Thüringen         6.26    1.58     5.70
```

```
bula_data %>%
```

```
  arrange( mean_alo )
```

```
## # A tibble: 16 × 4
```

| ##    | bundesland_name        | mean_alo | sd_alo | median_alo |
|-------|------------------------|----------|--------|------------|
| ##    | <chr>                  | <dbl>    | <dbl>  | <dbl>      |
| ## 1  | Bayern                 | 3.26     | 0.715  | 3.14       |
| ## 2  | Baden-Württemberg      | 3.73     | 0.722  | 3.66       |
| ## 3  | Hessen                 | 5.25     | 1.27   | 5.37       |
| ## 4  | Rheinland-Pfalz        | 5.41     | 1.46   | 5.36       |
| ## 5  | Schleswig-Holstein     | 5.76     | 0.832  | 5.87       |
| ## 6  | Saarland               | 6.01     | 1.74   | 5.61       |
| ## 7  | Niedersachsen          | 6.05     | 1.73   | 6.22       |
| ## 8  | Sachsen                | 6.09     | 0.854  | 5.98       |
| ## 9  | Thüringen              | 6.26     | 1.58   | 5.70       |
| ## 10 | Brandenburg            | 6.75     | 1.51   | 7.11       |
| ## 11 | Nordrhein-Westfalen    | 7.03     | 2.35   | 6.62       |
| ## 12 | Mecklenburg-Vorpommern | 7.64     | 1.22   | 7.81       |
| ## 13 | Sachsen-Anhalt         | 7.84     | 1.43   | 7.75       |
| ## 14 | Bremen                 | 9.59     | 2.97   | 9.59       |
| ## 15 | Berlin                 | NA       | NA     | NA         |
| ## 16 | Hamburg                | NA       | NA     | NA         |

```
bula_data %>%  
  arrange( mean_alo ) %>%  
  filter( !is.na(mean_alo) )
```

```
## # A tibble: 14 × 4  
##   bundesland_name    mean_alo sd_alo median_alo  
##   <chr>            <dbl>   <dbl>     <dbl>  
## 1 Bayern           3.26   0.715     3.14  
## 2 Baden-Württemberg 3.73   0.722     3.66  
## 3 Hessen           5.25   1.27      5.37  
## 4 Rheinland-Pfalz   5.41   1.46      5.36  
## 5 Schleswig-Holstein 5.76   0.832     5.87  
## 6 Saarland          6.01   1.74      5.61  
## 7 Niedersachsen     6.05   1.73      6.22  
## 8 Sachsen           6.09   0.854     5.98  
## 9 Thüringen         6.26   1.58      5.70  
## 10 Brandenburg       6.75   1.51      7.11  
## 11 Nordrhein-Westfalen 7.03   2.35      6.62  
## 12 Mecklenburg-Vorpommern 7.64   1.22      7.81  
## 13 Sachsen-Anhalt    7.84   1.43      7.75  
## 14 Bremen            9.59   2.97      9.59
```

```

bula_data %>%
  arrange( mean_alo ) %>%
  filter( !is.na(mean_alo) ) %>%
  kbl(col.names = c("Bundesland",
                    "Mittelwert",
                    "Std.",
                    "Median"), digits = 2)

```

| Bundesland             | Mittelwert | Std. | Median |
|------------------------|------------|------|--------|
| Bayern                 | 3.26       | 0.72 | 3.14   |
| Baden-Württemberg      | 3.73       | 0.72 | 3.66   |
| Hessen                 | 5.25       | 1.27 | 5.37   |
| Rheinland-Pfalz        | 5.41       | 1.46 | 5.36   |
| Schleswig-Holstein     | 5.76       | 0.83 | 5.87   |
| Saarland               | 6.01       | 1.74 | 5.61   |
| Niedersachsen          | 6.05       | 1.73 | 6.22   |
| Sachsen                | 6.09       | 0.85 | 5.98   |
| Thüringen              | 6.26       | 1.58 | 5.70   |
| Brandenburg            | 6.75       | 1.51 | 7.11   |
| Nordrhein-Westfalen    | 7.03       | 2.35 | 6.62   |
| Mecklenburg-Vorpommern | 7.64       | 1.22 | 7.81   |
| Sachsen-Anhalt         | 7.84       | 1.43 | 7.75   |
| Bremen                 | 9.59       | 2.97 | 9.59   |

```

bula_data %>%
  arrange( mean_alo ) %>%
  filter( !is.na(mean_alo) ) %>%
  kbl(col.names = c("Bundesland",
                    "Mittelwert",
                    "Std.",
                    "Median"), digits = 2) %>%
  kable_styling(bootstrap_options = c("striped", "ho

```

| Bundesland             | Mittelwert | Std. | Median |
|------------------------|------------|------|--------|
| Bayern                 | 3.26       | 0.72 | 3.14   |
| Baden-Württemberg      | 3.73       | 0.72 | 3.66   |
| Hessen                 | 5.25       | 1.27 | 5.37   |
| Rheinland-Pfalz        | 5.41       | 1.46 | 5.36   |
| Schleswig-Holstein     | 5.76       | 0.83 | 5.87   |
| Saarland               | 6.01       | 1.74 | 5.61   |
| Niedersachsen          | 6.05       | 1.73 | 6.22   |
| Sachsen                | 6.09       | 0.85 | 5.98   |
| Thüringen              | 6.26       | 1.58 | 5.70   |
| Brandenburg            | 6.75       | 1.51 | 7.11   |
| Nordrhein-Westfalen    | 7.03       | 2.35 | 6.62   |
| Mecklenburg-Vorpommern | 7.64       | 1.22 | 7.81   |
| Sachsen-Anhalt         | 7.84       | 1.43 | 7.75   |
| Bremen                 | 9.59       | 2.97 | 9.59   |

```

bula_data %>%
  arrange( mean_alo ) %>%
  filter( !is.na(mean_alo) ) %>%
  kbl(col.names = c("Bundesland",
                    "Mittelwert",
                    "Std.",
                    "Median"), digits = 2) %>%
  kable_styling(bootstrap_options = c("striped", "ho
  kable_paper(full_width = F)

```

| Bundesland             | Mittelwert | Std. | Median |
|------------------------|------------|------|--------|
| Bayern                 | 3.26       | 0.72 | 3.14   |
| Baden-Württemberg      | 3.73       | 0.72 | 3.66   |
| Hessen                 | 5.25       | 1.27 | 5.37   |
| Rheinland-Pfalz        | 5.41       | 1.46 | 5.36   |
| Schleswig-Holstein     | 5.76       | 0.83 | 5.87   |
| Saarland               | 6.01       | 1.74 | 5.61   |
| Niedersachsen          | 6.05       | 1.73 | 6.22   |
| Sachsen                | 6.09       | 0.85 | 5.98   |
| Thüringen              | 6.26       | 1.58 | 5.70   |
| Brandenburg            | 6.75       | 1.51 | 7.11   |
| Nordrhein-Westfalen    | 7.03       | 2.35 | 6.62   |
| Mecklenburg-Vorpommern | 7.64       | 1.22 | 7.81   |
| Sachsen-Anhalt         | 7.84       | 1.43 | 7.75   |
| Bremen                 | 9.59       | 2.97 | 9.59   |



```

bula_data %>%
  arrange( mean_alo ) %>%
  filter( !is.na(mean_alo) ) %>%
  kbl(col.names = c("Bundesland",
                    "Mittelwert",
                    "Std.",
                    "Median"), digits = 2) %>%
  kable_styling(bootstrap_options = c("striped", "ho
  kable_paper(full_width = F) %>%
  row_spec(c(8,9, 10, 12,13), bold = T, color = "whi

```

| Bundesland             | Mittelwert | Std. | Median |
|------------------------|------------|------|--------|
| Bayern                 | 3.26       | 0.72 | 3.14   |
| Baden-Württemberg      | 3.73       | 0.72 | 3.66   |
| Hessen                 | 5.25       | 1.27 | 5.37   |
| Rheinland-Pfalz        | 5.41       | 1.46 | 5.36   |
| Schleswig-Holstein     | 5.76       | 0.83 | 5.87   |
| Saarland               | 6.01       | 1.74 | 5.61   |
| Niedersachsen          | 6.05       | 1.73 | 6.22   |
| Sachsen                | 6.09       | 0.85 | 5.98   |
| Thüringen              | 6.26       | 1.58 | 5.70   |
| Brandenburg            | 6.75       | 1.51 | 7.11   |
| Nordrhein-Westfalen    | 7.03       | 2.35 | 6.62   |
| Mecklenburg-Vorpommern | 7.64       | 1.22 | 7.81   |
| Sachsen-Anhalt         | 7.84       | 1.43 | 7.75   |
| Bremen                 | 9.59       | 2.97 | 9.59   |

```

bula_data %>%
  arrange( mean_alo ) %>%
  filter( !is.na(mean_alo) ) %>%
  kbl(col.names = c("Bundesland",
                    "Mittelwert",
                    "Std.",
                    "Median"), digits = 2) %>%
  kable_styling(bootstrap_options = c("striped", "ho
  kable_paper(full_width = F) %>%
  row_spec(c(8,9, 10, 12,13), bold = T, color = "whi
  add_header_above(c(" " = 1, "Arbeitslosenquote" =

```

| Bundesland             | Arbeitslosenquote |      |        |
|------------------------|-------------------|------|--------|
|                        | Mittelwert        | Std. | Median |
| Bayern                 | 3.26              | 0.72 | 3.14   |
| Baden-Württemberg      | 3.73              | 0.72 | 3.66   |
| Hessen                 | 5.25              | 1.27 | 5.37   |
| Rheinland-Pfalz        | 5.41              | 1.46 | 5.36   |
| Schleswig-Holstein     | 5.76              | 0.83 | 5.87   |
| Saarland               | 6.01              | 1.74 | 5.61   |
| Niedersachsen          | 6.05              | 1.73 | 6.22   |
| Sachsen                | 6.09              | 0.85 | 5.98   |
| Thüringen              | 6.26              | 1.58 | 5.70   |
| Brandenburg            | 6.75              | 1.51 | 7.11   |
| Nordrhein-Westfalen    | 7.03              | 2.35 | 6.62   |
| Mecklenburg-Vorpommern | 7.64              | 1.22 | 7.81   |
| Sachsen-Anhalt         | 7.84              | 1.43 | 7.75   |
| Bremen                 | 9.59              | 2.97 | 9.59   |

```
bula_data %>%
  arrange( mean_alo ) %>%
  filter( !is.na(mean_alo) ) %>%
  kbl(col.names = c("Bundesland",
                    "Mittelwert",
                    "Std.",
                    "Median"), digits = 2) %>%
  kable_styling(bootstrap_options = c("striped", "hover"),
  kable_paper(full_width = F) %>%
  row_spec(c(8,9, 10, 12,13), bold = T, color = "white",
  add_header_above(c(" " = 1, "Arbeitslosenquote" = 3))
  footnote(general = "Wir haben keine Informationen zu Berlin und Hamburg, weshalb sie nicht in der Tabelle aufgeführt wurden.",
           general_title = "Bitte beachten: ",
           number = "Die ostdeutschen Bundesländer sind grau hinterlegt.")
```

| Bundesland             | Arbeitslosenquote |      |        |
|------------------------|-------------------|------|--------|
|                        | Mittelwert        | Std. | Median |
| Bayern                 | 3.26              | 0.72 | 3.14   |
| Baden-Württemberg      | 3.73              | 0.72 | 3.66   |
| Hessen                 | 5.25              | 1.27 | 5.37   |
| Rheinland-Pfalz        | 5.41              | 1.46 | 5.36   |
| Schleswig-Holstein     | 5.76              | 0.83 | 5.87   |
| Saarland               | 6.01              | 1.74 | 5.61   |
| Niedersachsen          | 6.05              | 1.73 | 6.22   |
| Sachsen                | 6.09              | 0.85 | 5.98   |
| Thüringen              | 6.26              | 1.58 | 5.70   |
| Brandenburg            | 6.75              | 1.51 | 7.11   |
| Nordrhein-Westfalen    | 7.03              | 2.35 | 6.62   |
| Mecklenburg-Vorpommern | 7.64              | 1.22 | 7.81   |
| Sachsen-Anhalt         | 7.84              | 1.43 | 7.75   |
| Bremen                 | 9.59              | 2.97 | 9.59   |

*Bitte beachten:*

Wir haben keine Informationen zu Berlin und Hamburg, weshalb sie nicht in der Tabelle aufgeführt wurden.

<sup>1</sup> Die ostdeutschen Bundesländer sind grau hinterlegt.

## Was ist hier eine Beobachtung?

| Bundesland             | Arbeitslosenquote |      |        |
|------------------------|-------------------|------|--------|
|                        | Mittelwert        | Std. | Median |
| Bayern                 | 3.26              | 0.72 | 3.14   |
| Baden-Württemberg      | 3.73              | 0.72 | 3.66   |
| Hessen                 | 5.25              | 1.27 | 5.37   |
| Rheinland-Pfalz        | 5.41              | 1.46 | 5.36   |
| Schleswig-Holstein     | 5.76              | 0.83 | 5.87   |
| Saarland               | 6.01              | 1.74 | 5.61   |
| Niedersachsen          | 6.05              | 1.73 | 6.22   |
| Sachsen                | 6.09              | 0.85 | 5.98   |
| Thüringen              | 6.26              | 1.58 | 5.70   |
| Brandenburg            | 6.75              | 1.51 | 7.11   |
| Nordrhein-Westfalen    | 7.03              | 2.35 | 6.62   |
| Mecklenburg-Vorpommern | 7.64              | 1.22 | 7.81   |
| Sachsen-Anhalt         | 7.84              | 1.43 | 7.75   |
| Bremen                 | 9.59              | 2.97 | 9.59   |

*Bitte beachten:*

Wir haben keine Informationen zu Berlin und Hamburg, weshalb sie nicht in der Tabelle aufgeführt wurden.

<sup>1</sup> Die ostdeutschen Bundesländer sind grau hinterlegt.

# Die Arbeitslosenquote auf Bundeslandebene

Was lernen wir aus der deskriptiven Tabelle?

# Die Arbeitslosenquote auf Bundeslandebene

Was lernen wir aus der deskriptiven Tabelle?

- + Landkreise im Süden Deutschlands haben durchschnittlich eine eher niedrige Arbeitslosenquote (<4%)

# Die Arbeitslosenquote auf Bundeslandebene

Was lernen wir aus der deskriptiven Tabelle?

- + Landkreise im Süden Deutschlands haben durchschnittlich eine eher niedrige Arbeitslosenquote ( $<4\%$ )
- + Landkreise in den ostdeutschen Bundesländern haben tendenziell höhere Arbeitslosenquoten ( $>5.5\%$ )

# Die Arbeitslosenquote auf Bundeslandebene

## Was lernen wir aus der deskriptiven Tabelle?

- + Landkreise im Süden Deutschlands haben durchschnittlich eine eher niedrige Arbeitslosenquote ( $<4\%$ )
- + Landkreise in den ostdeutschen Bundesländern haben tendenziell höhere Arbeitslosenquoten ( $>5.5\%$ )
- + Bundesländer wie Bayern oder Baden-Württemberg haben relativ niedrige Arbeitslosenquoten und relativ geringe regionale Unterschiede (niedrige Standardabweichungen).



# Die Arbeitslosenquote auf Bundeslandebene

## Was lernen wir aus der deskriptiven Tabelle?

- + Landkreise im Süden Deutschlands haben durchschnittlich eine eher niedrige Arbeitslosenquote ( $<4\%$ )
- + Landkreise in den ostdeutschen Bundesländern haben tendenziell höhere Arbeitslosenquoten ( $>5.5\%$ )
- + Bundesländer wie Bayern oder Baden-Württemberg haben relativ niedrige Arbeitslosenquoten und relativ geringe regionale Unterschiede (niedrige Standardabweichungen).
- + Bundesländer wie Nordrhein-Westfalen haben zwar eine relativ niedrige Arbeitslosenquote, aber sehr unterschiedliche regionale Verteilungen (hohe Standardabweichungen), was auf starke regionale Unterschiede hinweist.

# Die Arbeitslosenquote auf Bundeslandebene

## Was lernen wir aus der deskriptiven Tabelle?

- + Landkreise im Süden Deutschlands haben durchschnittlich eine eher niedrige Arbeitslosenquote ( $<4\%$ )
- + Landkreise in den ostdeutschen Bundesländern haben tendenziell höhere Arbeitslosenquoten ( $>5.5\%$ )
- + Bundesländer wie Bayern oder Baden-Württemberg haben relativ niedrige Arbeitslosenquoten und relativ geringe regionale Unterschiede (niedrige Standardabweichungen).
- + Bundesländer wie Nordrhein-Westfalen haben zwar eine relativ niedrige Arbeitslosenquote, aber sehr unterschiedliche regionale Verteilungen (hohe Standardabweichungen), was auf starke regionale Unterschiede hinweist.
- + Median liegt recht nahe am Mittelwert für die Bundesländern

Sehr große Unterschiede in den durchschnittlichen Arbeitslosenquoten zwischen Landkreisen in Ost- und Westdeutschland!

# Die Arbeitslosenquote zwischen Ost- und Westdeutschland

Wir wollen uns eine neue Variable "ost", bzw. "ost\_name" generieren. Anschließend können wir uns die Arbeitslosigkeit für Ost- und Westdeutschland anschauen.

```
gesamtdaten <- gesamtdaten %>%  
  mutate( ost = as.factor(ifelse(bundesland_name %in% c("Brandenburg", "Mecklenburg-Vorpommern", "Sachsen", "  
    ost_name = ifelse(ost == 1, "Ostdeutschland", "Westdeutschland"))
```

gesamtdaten

```
## # A tibble: 400 × 12
##   Regionalschlüssel total_alo landkreis_name bundesland bundesland_name
##   <chr>                <dbl> <chr>                <chr>      <chr>
## 1 01001                4131. Flensburg      01        Schleswig-Holst
## 2 01002                10581 Kiel          01        Schleswig-Holst
## 3 01003                9216. Lübeck      01        Schleswig-Holst
## 4 01004                3604. Neumünster    01        Schleswig-Holst
## 5 01051                4126. Dithmarschen  01        Schleswig-Holst
## 6 01053                5586. Herzogtum Lauenburg 01        Schleswig-Holst
## 7 01054                4491. Nordfriesland  01        Schleswig-Holst
## 8 01055                5176. Ostholstein   01        Schleswig-Holst
## 9 01056                9280. Pinneberg     01        Schleswig-Holst
## 10 01057               2848. Plön        01        Schleswig-Holst
## # i 390 more rows
## # i 7 more variables: Schulden_pro_kopf_lk <dbl>, Einwohner <dbl>,
## #   Schulden_gesamt <dbl>, bip <dbl>, bip_pro_kopf <dbl>, erw <dbl>,
## #   alo_quote <dbl>
```

```
gesamtdaten %>%
```

```
  mutate( ost = as.factor(ifelse(bundesland_name %in%  
    ost_name = ifelse(ost == 1, "Ostdeutschland", "Westdeutschland")
```

```
## # A tibble: 400 × 14
```

```
##   Regionalschlüssel total_alo landkreis_name bundesland bundesland_name  
##   <chr>                <dbl> <chr>          <chr>      <chr>  
## 1 01001                4131. Flensburg      01      Schleswig-Holst  
## 2 01002                10581 Kiel          01      Schleswig-Holst  
## 3 01003                9216. Lübeck       01      Schleswig-Holst  
## 4 01004                3604. Neumünster    01      Schleswig-Holst  
## 5 01051                4126. Dithmarschen    01      Schleswig-Holst  
## 6 01053                5586. Herzogtum Lauenburg 01      Schleswig-Holst  
## 7 01054                4491. Nordfriesland    01      Schleswig-Holst  
## 8 01055                5176. Ostholstein     01      Schleswig-Holst  
## 9 01056                9280. Pinneberg      01      Schleswig-Holst  
## 10 01057               2848. Plön         01      Schleswig-Holst  
## # i 390 more rows  
## # i 9 more variables: Schulden_pro_kopf_lk <dbl>, Einwohner <dbl>,  
## #   Schulden_gesamt <dbl>, bip <dbl>, bip_pro_kopf <dbl>, erw <dbl>,  
## #   alo_quote <dbl>, ost <fct>, ost_name <chr>
```

# Die Arbeitslosenquote zwischen Ost- und Westdeutschland

```
gesamtdaten %>%
  group_by(ost_name) %>%
  summarise(mean_alo = mean(alo_quote, na.rm = T), sd_alo = sd(alo_quote, na.rm = T), min_alo = min(alo_quote), max_alo = max(alo_quote))
ungroup() %>%
  kbl(col.names = c("Bundesland",
                    "Mittelwert",
                    "Std.",
                    "Minimum",
                    "P25",
                    "Median",
                    "P75",
                    "Maximum"), digits = 2) %>%
  kable_styling(bootstrap_options = c("striped", "hover", "condensed", "responsive")) %>%
  kable_paper(full_width = F) %>%
  add_header_above(c(" " = 1, "Arbeitslosenquote" = 7), align = "c") %>%
  footnote(general = "Wir haben keine Informationen zu Berlin und Hamburg, weshalb sie nicht in der Berechnung enthalten sind.",
           general_title = "Bitte beachten: ")
```

gesamtdaten

```
## # A tibble: 400 × 14
##   Regionalschlüssel total_alo landkreis_name    bundesland bundesland_name
##   <chr>              <dbl> <chr>          <chr>      <chr>
## 1 01001              4131. Flensburg      01        Schleswig-Holst
## 2 01002             10581 Kiel            01        Schleswig-Holst
## 3 01003             9216. Lübeck         01        Schleswig-Holst
## 4 01004             3604. Neumünster      01        Schleswig-Holst
## 5 01051             4126. Dithmarschen    01        Schleswig-Holst
## 6 01053             5586. Herzogtum Lauenburg 01        Schleswig-Holst
## 7 01054             4491. Nordfriesland    01        Schleswig-Holst
## 8 01055             5176. Ostholstein      01        Schleswig-Holst
## 9 01056             9280. Pinneberg      01        Schleswig-Holst
## 10 01057            2848. Plön          01        Schleswig-Holst
## # i 390 more rows
## # i 9 more variables: Schulden_pro_kopf_lk <dbl>, Einwohner <dbl>,
## #   Schulden_gesamt <dbl>, bip <dbl>, bip_pro_kopf <dbl>, erw <dbl>,
## #   alo_quote <dbl>, ost <fct>, ost_name <chr>
```

```
gesamtdaten %>%
```

```
  group_by(ost_name)
```

```
## # A tibble: 400 × 14
## # Groups:   ost_name [2]
##   Regionalschluessel total_alo landkreis_name    bundesland bundesland_name
##   <chr>                <dbl> <chr>          <chr>      <chr>
## 1 01001                4131. Flensburg      01        Schleswig-Holst
## 2 01002               10581 Kiel            01        Schleswig-Holst
## 3 01003               9216. Lübeck          01        Schleswig-Holst
## 4 01004               3604. Neumünster      01        Schleswig-Holst
## 5 01051               4126. Dithmarschen    01        Schleswig-Holst
## 6 01053               5586. Herzogtum Lauenburg 01        Schleswig-Holst
## 7 01054               4491. Nordfriesland    01        Schleswig-Holst
## 8 01055               5176. Ostholstein     01        Schleswig-Holst
## 9 01056               9280. Pinneberg      01        Schleswig-Holst
## 10 01057              2848. Plön            01        Schleswig-Holst
## # i 390 more rows
## # i 9 more variables: Schulden_pro_kopf_lk <dbl>, Einwohner <dbl>,
## #   Schulden_gesamt <dbl>, bip <dbl>, bip_pro_kopf <dbl>, erw <dbl>,
## #   alo_quote <dbl>, ost <fct>, ost_name <chr>
```



```
gesamtdaten %>%  
  group_by(ost_name) %>%  
  summarise(mean_alo = mean(alo_quote, na.rm = T), s
```

```
## # A tibble: 2 × 8  
##   ost_name      mean_alo sd_alo min_alo   q25 median_alo   q75 max_alo  
##   <chr>          <dbl>  <dbl>  <dbl> <dbl>      <dbl> <dbl>  <dbl>  
## 1 Ostdeutschland    6.79    1.52    4.09  5.69      6.74    7.70   11.1  
## 2 Westdeutschland   4.94    2.03    1.64  3.38      4.37    6.17   14.2
```

```
gesamtdaten %>%  
  group_by(ost_name) %>%  
  summarise(mean_alo = mean(alo_quote, na.rm = T), s  
  ungroup()
```

```
## # A tibble: 2 × 8  
##   ost_name      mean_alo sd_alo min_alo   q25 median_alo   q75 max_alo  
##   <chr>          <dbl>  <dbl>  <dbl> <dbl>      <dbl> <dbl>  <dbl>  
## 1 Ostdeutschland    6.79    1.52    4.09  5.69      6.74    7.70   11.1  
## 2 Westdeutschland   4.94    2.03    1.64  3.38      4.37    6.17   14.2
```

```
gesamtdaten %>%
  group_by(ost_name) %>%
  summarise(mean_alo = mean(alo_quote, na.rm = T), s
  ungroup() %>%
```

```
kbl(col.names = c("Bundesland",
                  "Mittelwert",
                  "Std.",
                  "Minimum",
                  "P25",
                  "Median",
                  "P75",
                  "Maximum"), digits = 2)
```

| Bundesland      | Mittelwert | Std. | Minimum | P25  | Median | P75  | Maximum |
|-----------------|------------|------|---------|------|--------|------|---------|
| Ostdeutschland  | 6.79       | 1.52 | 4.09    | 5.69 | 6.74   | 7.70 | 11.11   |
| Westdeutschland | 4.94       | 2.03 | 1.64    | 3.38 | 4.37   | 6.17 | 14.23   |

```

gesamtdaten %>%
  group_by(ost_name) %>%
  summarise(mean_alo = mean(alo_quote, na.rm = T), s
  ungroup() %>%
  kbl(col.names = c("Bundesland",
                    "Mittelwert",
                    "Std.",
                    "Minimum",
                    "P25",
                    "Median",
                    "P75",
                    "Maximum"), digits = 2) %>%
  kable_styling(bootstrap_options = c("striped", "ho

```

| Bundesland      | Mittelwert | Std. | Minimum | P25  | Median | P75  | Maximum |
|-----------------|------------|------|---------|------|--------|------|---------|
| Ostdeutschland  | 6.79       | 1.52 | 4.09    | 5.69 | 6.74   | 7.70 | 11.11   |
| Westdeutschland | 4.94       | 2.03 | 1.64    | 3.38 | 4.37   | 6.17 | 14.23   |

```

gesamtdaten %>%
  group_by(ost_name) %>%
  summarise(mean_alo = mean(alo_quote, na.rm = T), s
  ungroup() %>%
  kbl(col.names = c("Bundesland",
                    "Mittelwert",
                    "Std.",
                    "Minimum",
                    "P25",
                    "Median",
                    "P75",
                    "Maximum"), digits = 2) %>%
  kable_styling(bootstrap_options = c("striped", "ho
  kable_paper(full_width = F)

```

| Bundesland      | Mittelwert | Std. | Minimum | P25  | Median | P75  | Maximum |
|-----------------|------------|------|---------|------|--------|------|---------|
| Ostdeutschland  | 6.79       | 1.52 | 4.09    | 5.69 | 6.74   | 7.70 | 11.11   |
| Westdeutschland | 4.94       | 2.03 | 1.64    | 3.38 | 4.37   | 6.17 | 14.23   |

```

gesamtdaten %>%
  group_by(ost_name) %>%
  summarise(mean_alo = mean(alo_quote, na.rm = T), s
  ungroup() %>%
  kbl(col.names = c("Bundesland",
                    "Mittelwert",
                    "Std.",
                    "Minimum",
                    "P25",
                    "Median",
                    "P75",
                    "Maximum"), digits = 2) %>%
  kable_styling(bootstrap_options = c("striped", "ho
  kable_paper(full_width = F) %>%
  add_header_above(c(" " = 1, "Arbeitslosenquote" =

```

|                 | Arbeitslosenquote |      |         |      |        |      |         |
|-----------------|-------------------|------|---------|------|--------|------|---------|
| Bundesland      | Mittelwert        | Std. | Minimum | P25  | Median | P75  | Maximum |
| Ostdeutschland  | 6.79              | 1.52 | 4.09    | 5.69 | 6.74   | 7.70 | 11.11   |
| Westdeutschland | 4.94              | 2.03 | 1.64    | 3.38 | 4.37   | 6.17 | 14.23   |

```

gesamtdaten %>%
  group_by(ost_name) %>%
  summarise(mean_alo = mean(alo_quote, na.rm = T), s
  ungroup() %>%
  kbl(col.names = c("Bundesland",
                    "Mittelwert",
                    "Std.",
                    "Minimum",
                    "P25",
                    "Median",
                    "P75",
                    "Maximum"), digits = 2) %>%
  kable_styling(bootstrap_options = c("striped", "ho
  kable_paper(full_width = F) %>%
  add_header_above(c(" " = 1, "Arbeitslosenquote" =
  footnote(general = "Wir haben keine Informationen
            general_title = "Bitte beachten: ")

```

| Bundesland      | Arbeitslosenquote |      |         |      |        |      |         |
|-----------------|-------------------|------|---------|------|--------|------|---------|
|                 | Mittelwert        | Std. | Minimum | P25  | Median | P75  | Maximum |
| Ostdeutschland  | 6.79              | 1.52 | 4.09    | 5.69 | 6.74   | 7.70 | 11.11   |
| Westdeutschland | 4.94              | 2.03 | 1.64    | 3.38 | 4.37   | 6.17 | 14.23   |

*Bitte beachten:*

Wir haben keine Informationen zu Berlin und Hamburg, weshalb sie nicht in der Berechnung enthalten sind.

```

gesamtdaten %>%
  group_by(ost_name) %>%
  summarise(mean_alo = mean(alo_quote, na.rm = T), s
  ungroup() %>%
  kbl(col.names = c("Bundesland",
                    "Mittelwert",
                    "Std.",
                    "Minimum",
                    "P25",
                    "Median",
                    "P75",
                    "Maximum"), digits = 2) %>%
  kable_styling(bootstrap_options = c("striped", "ho
  kable_paper(full_width = F) %>%
  add_header_above(c(" " = 1, "Arbeitslosenquote" =
  footnote(general = "Wir haben keine Informationen
            general_title = "Bitte beachten: ")

```

## Arbeitslosenquote

| Bundesland      | Mittelwert | Std. | Minimum | P25  | Median | P75  | Maximum |
|-----------------|------------|------|---------|------|--------|------|---------|
| Ostdeutschland  | 6.79       | 1.52 | 4.09    | 5.69 | 6.74   | 7.70 | 11.11   |
| Westdeutschland | 4.94       | 2.03 | 1.64    | 3.38 | 4.37   | 6.17 | 14.23   |

*Bitte beachten:*

Wir haben keine Informationen zu Berlin und Hamburg, weshalb sie nicht in der Berechnung enthalten sind.

Beschreiben Sie die Tabelle!



# Die Arbeitslosenquote zwischen Ost- und Westdeutschland

Große Unterschiede werden sichtbar:

- + Mittelwert über 1,8 Prozentpunkte niedriger in den Landkreisen der westdeutschen Bundesländer
- + Die Standardabweichung ist in Westdeutschland deutlich höher als in Ostdeutschland
- + Der Median der ostdeutschen Landkreise liegt nahe dem Mittelwert dieser Landkreise. Der Median in den westdeutschen Landkreisen liegt jedoch deutlich unter deren Mittelwert
- + Im **25% Quantil** in den **ostdeutschen Landkreisen** ist die Arbeitslosenquote bei **5,69%**
- + Bei den **westdeutschen Landkreisen** ist das **75% Quantil** bei einer Arbeitslosenquote von **6,17%**!

# ARBEITSLOSENQUOTE, BIP PRO KOPF UND SCHULDEN PRO KOPF

```
gesamtdaten %>%
  group_by( bundesland_name ) %>%
  summarise(mean_alo = mean(alo_quote), sd_alo = sd(alo_quote),
            mean_bip_kopf = mean(bip_pro_kopf), sd_bip_kopf = sd(bip_pro_kopf),
            mean_schulden_kopf = mean(Schulden_gesamt/Einwohner), sd_schulden = sd(Schulden_gesamt/Einwohner))
ungroup() -> bula_data_all

bula_data_all %>%
  arrange( mean_alo ) %>%
  filter( !is.na(mean_schulden_kopf) ) %>%
  kbl(col.names = c("Bundesland", "Mittelwert", "Std.", "Mittelwert", "Std.", "Mittelwert", "Std."), digits = 2,
      caption = "Deskriptive Tabelle komplett") %>%
  kable_styling(bootstrap_options = c("striped", "hover", "condensed", "responsive")) %>%
  kable_paper(full_width = F) %>%
  row_spec(c(8,9, 10, 12,13), bold = T, color = "white", background = "#BBBBBB") %>%
  add_header_above(c(" " = 1, "Arbeitslosenquote" = 2, "BIP pro Kopf" = 2, "Schulden pro Kopf" = 2), align = "left")
  footnote(general = "Wir haben keine Informationen zu Berlin, Hamburg und Bremen bzgl. ihrer Schulden pro Kopf",
           general_title = "Bitte beachten: ",
           number = "Die ostdeutschen Bundesländer sind grau hinterlegt.")
```

gesamtdaten

```
## # A tibble: 400 × 14
##   Regionalschlüssel total_alo landkreis_name bundesland bundesland_name
##   <chr>                <dbl> <chr>                <chr>      <chr>
## 1 01001                4131. Flensburg      01        Schleswig-Holst
## 2 01002                10581 Kiel          01        Schleswig-Holst
## 3 01003                9216. Lübeck      01        Schleswig-Holst
## 4 01004                3604. Neumünster    01        Schleswig-Holst
## 5 01051                4126. Dithmarschen  01        Schleswig-Holst
## 6 01053                5586. Herzogtum Lauenburg 01        Schleswig-Holst
## 7 01054                4491. Nordfriesland  01        Schleswig-Holst
## 8 01055                5176. Ostholstein   01        Schleswig-Holst
## 9 01056                9280. Pinneberg     01        Schleswig-Holst
## 10 01057               2848. Plön        01        Schleswig-Holst
## # i 390 more rows
## # i 9 more variables: Schulden_pro_kopf_lk <dbl>, Einwohner <dbl>,
## #   Schulden_gesamt <dbl>, bip <dbl>, bip_pro_kopf <dbl>, erw <dbl>,
## #   alo_quote <dbl>, ost <fct>, ost_name <chr>
```

```
gesamtdaten %>%
```

```
  group_by( bundesland_name )
```

```
## # A tibble: 400 × 14
```

```
## # Groups:   bundesland_name [16]
```

```
##   Regionalschlüssel total_alo landkreis_name   bundesland bundesland_name
##   <chr>                <dbl> <chr>                <chr>         <chr>
## 1 01001                4131. Flensburg      01          Schleswig-Holst
## 2 01002                10581 Kiel            01          Schleswig-Holst
## 3 01003                9216. Lübeck         01          Schleswig-Holst
## 4 01004                3604. Neumünster      01          Schleswig-Holst
## 5 01051                4126. Dithmarschen    01          Schleswig-Holst
## 6 01053                5586. Herzogtum Lauenburg 01          Schleswig-Holst
## 7 01054                4491. Nordfriesland    01          Schleswig-Holst
## 8 01055                5176. Ostholstein      01          Schleswig-Holst
## 9 01056                9280. Pinneberg      01          Schleswig-Holst
## 10 01057               2848. Plön            01          Schleswig-Holst
```

```
## # i 390 more rows
```

```
## # i 9 more variables: Schulden_pro_kopf_lk <dbl>, Einwohner <dbl>,
```

```
## #   Schulden_gesamt <dbl>, bip <dbl>, bip_pro_kopf <dbl>, erw <dbl>,
```

```
## #   alo_quote <dbl>, ost <fct>, ost_name <chr>
```

```
gesamtdaten %>%
  group_by( bundesland_name ) %>%
  summarise(mean_alo = mean(alo_quote), sd_alo = sd(
```

```
## # A tibble: 16 × 7
##   bundesland_name mean_alo sd_alo mean_bip_kopf sd_bip_kopf mean_schulden_ko
##   <chr>          <dbl>  <dbl>          <dbl>          <dbl>          <dbl>
## 1 Baden-Württembe...   3.73  0.722          49825.          15017.          318
## 2 Bayern              3.26  0.715          49282.          21402.          224
## 3 Berlin              NA    NA              NA              NA              NA
## 4 Brandenburg         6.75  1.51          35440.           7563.          241
## 5 Bremen              9.59  2.97          47873.          14123.           NA
## 6 Hamburg             NA    NA              NA              NA              NA
## 7 Hessen              5.25  1.27          45974.          18556.          400
## 8 Mecklenburg-Vor...   7.64  1.22          34664.           7288.          399
## 9 Niedersachsen       6.05  1.73          40510.          20508.          253
## 10 Nordrhein-Westf...   7.03  2.35          41435.          12334.          438
## 11 Rheinland-Pfalz     5.41  1.46          40223.          18368.          313
## 12 Saarland            6.01  1.74          36453.           8555.          523
## 13 Sachsen             6.09  0.854          34595.           5879.          244
## 14 Sachsen-Anhalt      7.84  1.43          33644.           5192.          293
## 15 Schleswig-Holst...   5.76  0.832          39300.           9913.          328
## 16 Thüringen           6.26  1.58          32240.           6650.          276
## # i 1 more variable: sd_schulden <dbl>
```

```
gesamtdaten %>%  
  group_by( bundesland_name ) %>%  
  summarise(mean_alo = mean(alo_quote), sd_alo = sd(  
ungroup() -> bula_data_all
```

```
gesamtdaten %>%
  group_by( bundesland_name ) %>%
  summarise(mean_alo = mean(alo_quote), sd_alo = sd(
  ungroup() -> bula_data_all
```

```
bula_data_all
```

```
## # A tibble: 16 × 7
##   bundesland_name mean_alo sd_alo mean_bip_kopf sd_bip_kopf mean_schulden_ko
##   <chr>          <dbl>  <dbl>          <dbl>          <dbl>          <dbl>
## 1 Baden-Württembe...   3.73  0.722          49825.          15017.          318
## 2 Bayern              3.26  0.715          49282.          21402.          224
## 3 Berlin              NA     NA              NA              NA              NA
## 4 Brandenburg         6.75  1.51          35440.           7563.          241
## 5 Bremen              9.59  2.97          47873.          14123.           NA
## 6 Hamburg             NA     NA              NA              NA              NA
## 7 Hessen              5.25  1.27          45974.          18556.          400
## 8 Mecklenburg-Vor...   7.64  1.22          34664.           7288.          399
## 9 Niedersachsen       6.05  1.73          40510.          20508.          253
## 10 Nordrhein-Westf...   7.03  2.35          41435.          12334.          438
## 11 Rheinland-Pfalz     5.41  1.46          40223.          18368.          313
## 12 Saarland            6.01  1.74          36453.           8555.          523
## 13 Sachsen             6.09  0.854          34595.           5879.          244
## 14 Sachsen-Anhalt      7.84  1.43          33644.           5192.          293
## 15 Schleswig-Holst...   5.76  0.832          39300.           9913.          328
## 16 Thüringen           6.26  1.58          32240.           6650.          278
## # i 1 more variable: sd_schulden <dbl>
```

```

gesamtdaten %>%
  group_by( bundesland_name ) %>%
  summarise(mean_alo = mean(alo_quote), sd_alo = sd(
  ungroup() -> bula_data_all

bula_data_all %>%
  arrange( mean_alo )

```

```

## # A tibble: 16 × 7
##   bundesland_name mean_alo sd_alo mean_bip_kopf sd_bip_kopf mean_schulden_ko
##   <chr>          <dbl> <dbl>          <dbl>          <dbl>          <dbl>
## 1 Bayern          3.26  0.715          49282.          21402.          224
## 2 Baden-Württembe... 3.73  0.722          49825.          15017.          318
## 3 Hessen           5.25  1.27           45974.          18556.          400
## 4 Rheinland-Pfalz    5.41  1.46           40223.          18368.          313
## 5 Schleswig-Holst... 5.76  0.832          39300.           9913.          328
## 6 Saarland          6.01  1.74           36453.           8555.          523
## 7 Niedersachsen      6.05  1.73           40510.          20508.          253
## 8 Sachsen           6.09  0.854          34595.           5879.          244
## 9 Thüringen         6.26  1.58           32240.           6650.          276
## 10 Brandenburg        6.75  1.51           35440.           7563.          241
## 11 Nordrhein-Westf... 7.03  2.35           41435.          12334.          438
## 12 Mecklenburg-Vor... 7.64  1.22           34664.           7288.          399
## 13 Sachsen-Anhalt     7.84  1.43           33644.           5192.          293
## 14 Bremen            9.59  2.97           47873.          14123.           NA
## 15 Berlin             NA    NA              NA              NA              NA
## 16 Hamburg            NA    NA              NA              NA              NA
## # i 1 more variable: sd_schulden <dbl>

```



```

gesamtdaten %>%
  group_by( bundesland_name ) %>%
  summarise(mean_alo = mean(alo_quote), sd_alo = sd(
  ungroup() -> bula_data_all

bula_data_all %>%
  arrange( mean_alo ) %>%
  filter( !is.na(mean_schulden_kopf) )

```

```

## # A tibble: 13 × 7
##   bundesland_name mean_alo sd_alo mean_bip_kopf sd_bip_kopf mean_schulden_kopf
##   <chr>          <dbl> <dbl>          <dbl>          <dbl>          <dbl>
## 1 Bayern          3.26  0.715          49282.          21402.          224
## 2 Baden-Württembe... 3.73  0.722          49825.          15017.          318
## 3 Hessen           5.25  1.27           45974.          18556.          400
## 4 Rheinland-Pfalz    5.41  1.46           40223.          18368.          313
## 5 Schleswig-Holst...  5.76  0.832          39300.           9913.          328
## 6 Saarland          6.01  1.74           36453.           8555.          523
## 7 Niedersachsen      6.05  1.73           40510.          20508.          253
## 8 Sachsen           6.09  0.854          34595.           5879.          244
## 9 Thüringen         6.26  1.58           32240.           6650.          276
## 10 Brandenburg        6.75  1.51           35440.           7563.          241
## 11 Nordrhein-Westf...  7.03  2.35           41435.          12334.          438
## 12 Mecklenburg-Vor...  7.64  1.22           34664.           7288.          399
## 13 Sachsen-Anhalt     7.84  1.43           33644.           5192.          293
## # i 1 more variable: sd_schulden <dbl>

```

```

gesamtdaten %>%
  group_by( bundesland_name ) %>%
  summarise(mean_alo = mean(alo_quote), sd_alo = sd(
  ungroup() -> bula_data_all

bula_data_all %>%
  arrange( mean_alo ) %>%
  filter( !is.na(mean_schulden_kopf) ) %>%
  kbl(col.names = c("Bundesland", "Mittelwert", "Std.
  caption = "Deskriptive Tabelle komplett")

```

| Deskriptive Tabelle komplett |            |      |            |          |            |         |
|------------------------------|------------|------|------------|----------|------------|---------|
| Bundesland                   | Mittelwert | Std. | Mittelwert | Std.     | Mittelwert | Std.    |
| Bayern                       | 3.26       | 0.72 | 49281.51   | 21402.37 | 2242.23    | 1658.98 |
| Baden-Württemberg            | 3.73       | 0.72 | 49824.77   | 15016.77 | 3181.10    | 2482.35 |
| Hessen                       | 5.25       | 1.27 | 45974.34   | 18556.10 | 4002.22    | 3566.69 |
| Rheinland-Pfalz              | 5.41       | 1.46 | 40223.17   | 18368.50 | 3134.87    | 3519.37 |
| Schleswig-Holstein           | 5.76       | 0.83 | 39299.56   | 9913.17  | 3282.60    | 1319.29 |
| Saarland                     | 6.01       | 1.74 | 36453.36   | 8554.62  | 5232.31    | 1217.73 |
| Niedersachsen                | 6.05       | 1.73 | 40509.82   | 20508.37 | 2533.96    | 1808.01 |
| Sachsen                      | 6.09       | 0.85 | 34595.31   | 5878.85  | 2447.50    | 1000.71 |
| Thüringen                    | 6.26       | 1.58 | 32239.94   | 6650.04  | 2766.11    | 622.36  |
| Brandenburg                  | 6.75       | 1.51 | 35440.47   | 7562.58  | 2416.97    | 1183.76 |
| Nordrhein-Westfalen          | 7.03       | 2.35 | 41434.87   | 12333.98 | 4387.14    | 2378.29 |
| Mecklenburg-Vorpommern       | 7.64       | 1.22 | 34663.84   | 7287.85  | 3998.78    | 2075.06 |
| Sachsen-Anhalt               | 7.84       | 1.43 | 33643.87   | 5191.52  | 2934.74    | 1495.63 |

```

gesamtdaten %>%
  group_by( bundesland_name ) %>%
  summarise(mean_alo = mean(alo_quote), sd_alo = sd(
  ungroup() -> bula_data_all

bula_data_all %>%
  arrange( mean_alo ) %>%
  filter( !is.na(mean_schulden_kopf) ) %>%
  kbl(col.names = c("Bundesland", "Mittelwert", "Std.
    caption = "Deskriptive Tabelle komplett") %>%
  kable_styling(bootstrap_options = c("striped", "no
    font_size = 9)

```

## Deskriptive Tabelle komplett

| Bundesland             | Mittelwert | Std. | Mittelwert | Std.     | Mittelwert | Std.    |
|------------------------|------------|------|------------|----------|------------|---------|
| Bayern                 | 3.26       | 0.72 | 49281.51   | 21402.37 | 2242.23    | 1658.98 |
| Baden-Württemberg      | 3.73       | 0.72 | 49824.77   | 15016.77 | 3181.10    | 2482.35 |
| Hessen                 | 5.25       | 1.27 | 45974.34   | 18556.10 | 4002.22    | 3566.69 |
| Rheinland-Pfalz        | 5.41       | 1.46 | 40223.17   | 18368.50 | 3134.87    | 3519.37 |
| Schleswig-Holstein     | 5.76       | 0.83 | 39299.56   | 9913.17  | 3282.60    | 1319.29 |
| Saarland               | 6.01       | 1.74 | 36453.36   | 8554.62  | 5232.31    | 1217.73 |
| Niedersachsen          | 6.05       | 1.73 | 40509.82   | 20508.37 | 2533.96    | 1808.01 |
| Sachsen                | 6.09       | 0.85 | 34595.31   | 5878.85  | 2447.50    | 1000.71 |
| Thüringen              | 6.26       | 1.58 | 32239.94   | 6650.04  | 2766.11    | 622.36  |
| Brandenburg            | 6.75       | 1.51 | 35440.47   | 7562.58  | 2416.97    | 1183.76 |
| Nordrhein-Westfalen    | 7.03       | 2.35 | 41434.87   | 12333.98 | 4387.14    | 2378.29 |
| Mecklenburg-Vorpommern | 7.64       | 1.22 | 34663.84   | 7287.85  | 3998.78    | 2075.06 |
| Sachsen-Anhalt         | 7.84       | 1.43 | 33643.87   | 5191.52  | 2934.74    | 1495.63 |

```
gesamtdaten %>%
  group_by( bundesland_name ) %>%
  summarise(mean_alo = mean(alo_quote), sd_alo = sd(
  ungroup() -> bula_data_all

bula_data_all %>%
  arrange( mean_alo ) %>%
  filter( !is.na(mean_schulden_kopf) ) %>%
  kbl(col.names = c("Bundesland", "Mittelwert", "Std.
    caption = "Deskriptive Tabelle komplett") %>%
  kable_styling(bootstrap_options = c("striped", "ho
    font_size = 9) %>%
  kable_paper(full_width = F)
```

Deskriptive Tabelle komplett

| Bundesland             | Mittelwert | Std. | Mittelwert | Std.     | Mittelwert | Std.    |
|------------------------|------------|------|------------|----------|------------|---------|
| Bayern                 | 3.26       | 0.72 | 49281.51   | 21402.37 | 2242.23    | 1658.98 |
| Baden-Württemberg      | 3.73       | 0.72 | 49824.77   | 15016.77 | 3181.10    | 2482.35 |
| Hessen                 | 5.25       | 1.27 | 45974.34   | 18556.10 | 4002.22    | 3566.69 |
| Rheinland-Pfalz        | 5.41       | 1.46 | 40223.17   | 18368.50 | 3134.87    | 3519.37 |
| Schleswig-Holstein     | 5.76       | 0.83 | 39299.56   | 9913.17  | 3282.60    | 1319.29 |
| Saarland               | 6.01       | 1.74 | 36453.36   | 8554.62  | 5232.31    | 1217.73 |
| Niedersachsen          | 6.05       | 1.73 | 40509.82   | 20508.37 | 2533.96    | 1808.01 |
| Sachsen                | 6.09       | 0.85 | 34595.31   | 5878.85  | 2447.50    | 1000.71 |
| Thüringen              | 6.26       | 1.58 | 32239.94   | 6650.04  | 2766.11    | 622.36  |
| Brandenburg            | 6.75       | 1.51 | 35440.47   | 7562.58  | 2416.97    | 1183.76 |
| Nordrhein-Westfalen    | 7.03       | 2.35 | 41434.87   | 12333.98 | 4387.14    | 2378.29 |
| Mecklenburg-Vorpommern | 7.64       | 1.22 | 34663.84   | 7287.85  | 3998.78    | 2075.06 |
| Sachsen-Anhalt         | 7.84       | 1.43 | 33643.87   | 5191.52  | 2934.74    | 1495.63 |

```
gesamtdaten %>%
  group_by( bundesland_name ) %>%
  summarise(mean_alo = mean(alo_quote), sd_alo = sd(
  ungroup() -> bula_data_all

bula_data_all %>%
  arrange( mean_alo ) %>%
  filter( !is.na(mean_schulden_kopf) ) %>%
  kbl(col.names = c("Bundesland", "Mittelwert", "Std.
    caption = "Deskriptive Tabelle komplett") %>%
  kable_styling(bootstrap_options = c("striped", "ho
    font_size = 9) %>%
  kable_paper(full_width = F) %>%
  row_spec(c(8,9, 10, 12,13), bold = T, color = "whi
```

Deskriptive Tabelle komplett

| Bundesland             | Mittelwert | Std. | Mittelwert | Std.     | Mittelwert | Std.    |
|------------------------|------------|------|------------|----------|------------|---------|
| Bayern                 | 3.26       | 0.72 | 49281.51   | 21402.37 | 2242.23    | 1658.98 |
| Baden-Württemberg      | 3.73       | 0.72 | 49824.77   | 15016.77 | 3181.10    | 2482.35 |
| Hessen                 | 5.25       | 1.27 | 45974.34   | 18556.10 | 4002.22    | 3566.69 |
| Rheinland-Pfalz        | 5.41       | 1.46 | 40223.17   | 18368.50 | 3134.87    | 3519.37 |
| Schleswig-Holstein     | 5.76       | 0.83 | 39299.56   | 9913.17  | 3282.60    | 1319.29 |
| Saarland               | 6.01       | 1.74 | 36453.36   | 8554.62  | 5232.31    | 1217.73 |
| Niedersachsen          | 6.05       | 1.73 | 40509.82   | 20508.37 | 2533.96    | 1808.01 |
| Sachsen                | 6.09       | 0.85 | 34595.31   | 5878.85  | 2447.50    | 1000.71 |
| Thüringen              | 6.26       | 1.58 | 32239.94   | 6650.04  | 2766.11    | 622.36  |
| Brandenburg            | 6.75       | 1.51 | 35440.47   | 7562.58  | 2416.97    | 1183.76 |
| Nordrhein-Westfalen    | 7.03       | 2.35 | 41434.87   | 12333.98 | 4387.14    | 2378.29 |
| Mecklenburg-Vorpommern | 7.64       | 1.22 | 34663.84   | 7287.85  | 3998.78    | 2075.06 |
| Sachsen-Anhalt         | 7.84       | 1.43 | 33643.87   | 5191.52  | 2934.74    | 1495.63 |

```
gesamtdaten %>%
  group_by( bundesland_name ) %>%
  summarise(mean_alo = mean(alo_quote), sd_alo = sd(
  ungroup() -> bula_data_all

bula_data_all %>%
  arrange( mean_alo ) %>%
  filter( !is.na(mean_schulden_kopf) ) %>%
  kbl(col.names = c("Bundesland", "Mittelwert", "Std.
    caption = "Deskriptive Tabelle komplett") %>%
  kable_styling(bootstrap_options = c("striped", "ho
    font_size = 9) %>%
  kable_paper(full_width = F) %>%
  row_spec(c(8,9, 10, 12,13), bold = T, color = "whi
  add_header_above(c(" " = 1, "Arbeitslosenquote" =
```

Deskriptive Tabelle komplett

| Bundesland             | Arbeitslosenquote |      | BIP pro Kopf |          | Schulden pro Kopf |         |
|------------------------|-------------------|------|--------------|----------|-------------------|---------|
|                        | Mittelwert        | Std. | Mittelwert   | Std.     | Mittelwert        | Std.    |
| Bayern                 | 3.26              | 0.72 | 49281.51     | 21402.37 | 2242.23           | 1658.98 |
| Baden-Württemberg      | 3.73              | 0.72 | 49824.77     | 15016.77 | 3181.10           | 2482.35 |
| Hessen                 | 5.25              | 1.27 | 45974.34     | 18556.10 | 4002.22           | 3566.69 |
| Rheinland-Pfalz        | 5.41              | 1.46 | 40223.17     | 18368.50 | 3134.87           | 3519.37 |
| Schleswig-Holstein     | 5.76              | 0.83 | 39299.56     | 9913.17  | 3282.60           | 1319.29 |
| Saarland               | 6.01              | 1.74 | 36453.36     | 8554.62  | 5232.31           | 1217.73 |
| Niedersachsen          | 6.05              | 1.73 | 40509.82     | 20508.37 | 2533.96           | 1808.01 |
| Sachsen                | 6.09              | 0.85 | 34595.31     | 5878.85  | 2447.50           | 1000.71 |
| Thüringen              | 6.26              | 1.58 | 32239.94     | 6650.04  | 2766.11           | 622.36  |
| Brandenburg            | 6.75              | 1.51 | 35440.47     | 7562.58  | 2416.97           | 1183.76 |
| Nordrhein-Westfalen    | 7.03              | 2.35 | 41434.87     | 12333.98 | 4387.14           | 2378.29 |
| Mecklenburg-Vorpommern | 7.64              | 1.22 | 34663.84     | 7287.85  | 3998.78           | 2075.06 |
| Sachsen-Anhalt         | 7.84              | 1.43 | 33643.87     | 5191.52  | 2934.74           | 1495.63 |

```
gesamtdaten %>%
  group_by( bundesland_name ) %>%
  summarise(mean_alo = mean(alo_quote), sd_alo = sd(alo_quote))
ungroup() -> bula_data_all

bula_data_all %>%
  arrange( mean_alo ) %>%
  filter( !is.na(mean_schulden_kopf) ) %>%
  kbl(col.names = c("Bundesland", "Mittelwert", "Std.", "Arbeitslosenquote", "BIP pro Kopf", "Schulden pro Kopf"),
      caption = "Deskriptive Tabelle komplett") %>%
  kable_styling(bootstrap_options = c("striped", "hover"), font_size = 9) %>%
  kable_paper(full_width = F) %>%
  row_spec(c(8,9, 10, 12,13), bold = T, color = "white")
add_header_above(c(" " = 1, "Arbeitslosenquote" = 1, "BIP pro Kopf" = 1, "Schulden pro Kopf" = 1))
footnote(general = "Wir haben keine Informationen zu Berlin, Hamburg und Bremen bzgl. ihrer Schulden pro Kopf, weshalb sie nicht in der Tabelle aufgeführt wurden.",
         general_title = "Bitte beachten: ",
         number = "Die ostdeutschen Bundesländer sind grau hinterlegt.")
```

Deskriptive Tabelle komplett

| Bundesland             | Arbeitslosenquote |      | BIP pro Kopf |          | Schulden pro Kopf |         |
|------------------------|-------------------|------|--------------|----------|-------------------|---------|
|                        | Mittelwert        | Std. | Mittelwert   | Std.     | Mittelwert        | Std.    |
| Bayern                 | 3.26              | 0.72 | 49281.51     | 21402.37 | 2242.23           | 1658.98 |
| Baden-Württemberg      | 3.73              | 0.72 | 49824.77     | 15016.77 | 3181.10           | 2482.35 |
| Hessen                 | 5.25              | 1.27 | 45974.34     | 18556.10 | 4002.22           | 3566.69 |
| Rheinland-Pfalz        | 5.41              | 1.46 | 40223.17     | 18368.50 | 3134.87           | 3519.37 |
| Schleswig-Holstein     | 5.76              | 0.83 | 39299.56     | 9913.17  | 3282.60           | 1319.29 |
| Saarland               | 6.01              | 1.74 | 36453.36     | 8554.62  | 5232.31           | 1217.73 |
| Niedersachsen          | 6.05              | 1.73 | 40509.82     | 20508.37 | 2533.96           | 1808.01 |
| Sachsen                | 6.09              | 0.85 | 34595.31     | 5878.85  | 2447.50           | 1000.71 |
| Thüringen              | 6.26              | 1.58 | 32239.94     | 6650.04  | 2766.11           | 622.36  |
| Brandenburg            | 6.75              | 1.51 | 35440.47     | 7562.58  | 2416.97           | 1183.76 |
| Nordrhein-Westfalen    | 7.03              | 2.35 | 41434.87     | 12333.98 | 4387.14           | 2378.29 |
| Mecklenburg-Vorpommern | 7.64              | 1.22 | 34663.84     | 7287.85  | 3998.78           | 2075.06 |
| Sachsen-Anhalt         | 7.84              | 1.43 | 33643.87     | 5191.52  | 2934.74           | 1495.63 |

*Bitte beachten:*  
Wir haben keine Informationen zu Berlin, Hamburg und Bremen bzgl. ihrer Schulden pro Kopf, weshalb sie nicht in der Tabelle aufgeführt wurden.  
<sup>1</sup> Die ostdeutschen Bundesländer sind grau hinterlegt.

# ARBEITSLOSENQUOTE, BIP PRO KOPF UND SCHULDEN PRO KOPF

| Deskriptive Tabelle komplett |                   |      |              |          |                   |         |
|------------------------------|-------------------|------|--------------|----------|-------------------|---------|
| Bundesland                   | Arbeitslosenquote |      | BIP pro Kopf |          | Schulden pro Kopf |         |
|                              | Mittelwert        | Std. | Mittelwert   | Std.     | Mittelwert        | Std.    |
| Bayern                       | 3.26              | 0.72 | 49281.51     | 21402.37 | 2242.23           | 1658.98 |
| Baden-Württemberg            | 3.73              | 0.72 | 49824.77     | 15016.77 | 3181.10           | 2482.35 |
| Hessen                       | 5.25              | 1.27 | 45974.34     | 18556.10 | 4002.22           | 3566.69 |
| Rheinland-Pfalz              | 5.41              | 1.46 | 40223.17     | 18368.50 | 3134.87           | 3519.37 |
| Schleswig-Holstein           | 5.76              | 0.83 | 39299.56     | 9913.17  | 3282.60           | 1319.29 |
| Saarland                     | 6.01              | 1.74 | 36453.36     | 8554.62  | 5232.31           | 1217.73 |
| Niedersachsen                | 6.05              | 1.73 | 40509.82     | 20508.37 | 2533.96           | 1808.01 |
| Sachsen                      | 6.09              | 0.85 | 34595.31     | 5878.85  | 2447.50           | 1000.71 |
| Thüringen                    | 6.26              | 1.58 | 32239.94     | 6650.04  | 2766.11           | 622.36  |
| Brandenburg                  | 6.75              | 1.51 | 35440.47     | 7562.58  | 2416.97           | 1183.76 |
| Nordrhein-Westfalen          | 7.03              | 2.35 | 41434.87     | 12333.98 | 4387.14           | 2378.29 |
| Mecklenburg-Vorpommern       | 7.64              | 1.22 | 34663.84     | 7287.85  | 3998.78           | 2075.06 |
| Sachsen-Anhalt               | 7.84              | 1.43 | 33643.87     | 5191.52  | 2934.74           | 1495.63 |

*Bitte beachten:*

Wir haben keine Informationen zu Berlin, Hamburg und Bremen bzgl. ihrer Schulden pro Kopf, weshalb sie nicht in der Tabelle aufgeführt wurden.

<sup>1</sup> Die ostdeutschen Bundesländer sind grau hinterlegt.

Was lernen wir aus dieser Tabelle?



## ARBEITSLOSENQUOTE, BIP PRO KOPF UND SCHULDEN PRO KOPF

- + Landkreise in Bundesländer mit niedrigen Arbeitslosenquoten haben durchschnittlich ein hohes BIP pro Kopf
- + Ostdeutsche Landkreise haben im Durchschnitt ein BIP pro Kopf  $< 36000\text{€}$
- + Westdeutsche Landkreise haben im Durchschnitt ein BIP pro Kopf  $> 36000\text{€}$
- + Kein klares Bild der Landkreise hinsichtlich der Schulden pro Kopf

# ARBEITSLOSENQUOTE, BIP PRO KOPF UND SCHULDEN PRO KOPF

- + Landkreise in Bundesländer mit niedrigen Arbeitslosenquoten haben durchschnittlich ein hohes BIP pro Kopf
- + Ostdeutsche Landkreise haben im Durchschnitt ein BIP pro Kopf  $< 36000\text{€}$
- + Westdeutsche Landkreise haben im Durchschnitt ein BIP pro Kopf  $> 36000\text{€}$
- + Kein klares Bild der Landkreise hinsichtlich der Schulden pro Kopf

Allein durch Mittelwert und Standardabweichung können wir bereits sehr viel über regionale Unterschiede lernen.

# Entwicklung des BIP

Auch zeitliche Entwicklungen können in einer Tabelle dargestellt werden

Als Beispiel sollten Sie sich die Tabelle zur Entwicklung des BIP pro Kopf in der Case-Study anschauen

Hier gelangen Sie direkt zur [entsprechenden Sektion in der ausformulierten Case-Study](#).

# Datenvisualisierung

# Arbeitslosenquote

Das Auge verarbeitet Informationen deutlich schneller und intuitiver wenn diese in einer Grafik präsentiert werden, anstatt in Tabellenform.

# Arbeitslosenquote

Das Auge verarbeitet Informationen deutlich schneller und intuitiver wenn diese in einer Grafik präsentiert werden, anstatt in Tabellenform.

Daher ist es wichtig Grafiken in den deskriptiven Analysen mit einzubeziehen

**Daten:** Querschnittsdaten zur Arbeitslosigkeit in den Landkreisen aus dem Jahr 2023

# Arbeitslosenquote

Das Auge verarbeitet Informationen deutlich schneller und intuitiver wenn diese in einer Grafik präsentiert werden, anstatt in Tabellenform.

Daher ist es wichtig Grafiken in den deskriptiven Analysen mit einzubeziehen

**Daten:** Querschnittsdaten zur Arbeitslosigkeit in den Landkreisen aus dem Jahr 2023

Die folgende Grafik sollte enthalten:

- + **Zeige alle Daten:** Jeder Landkreis wird durch einen Punkt in der Grafik repräsentiert
- + Boxplot der Arbeitslosigkeit wird über die Punktwolke gelegt

gesamtdaten

```
## # A tibble: 400 × 14
##   Regionalschlüssel total_alo landkreis_name bundesland bundesland_name
##   <chr>                <dbl> <chr>                <chr>      <chr>
## 1 01001                4131. Flensburg      01        Schleswig-Holst
## 2 01002                10581 Kiel          01        Schleswig-Holst
## 3 01003                9216. Lübeck      01        Schleswig-Holst
## 4 01004                3604. Neumünster    01        Schleswig-Holst
## 5 01051                4126. Dithmarschen  01        Schleswig-Holst
## 6 01053                5586. Herzogtum Lauenburg 01        Schleswig-Holst
## 7 01054                4491. Nordfriesland  01        Schleswig-Holst
## 8 01055                5176. Ostholstein   01        Schleswig-Holst
## 9 01056                9280. Pinneberg     01        Schleswig-Holst
## 10 01057               2848. Plön          01        Schleswig-Holst
## # i 390 more rows
## # i 9 more variables: Schulden_pro_kopf_lk <dbl>, Einwohner <dbl>,
## #   Schulden_gesamt <dbl>, bip <dbl>, bip_pro_kopf <dbl>, erw <dbl>,
## #   alo_quote <dbl>, ost <fct>, ost_name <chr>
```



```
gesamtdaten %>%
```

```
  select(alo_quote, landkreis_name, bundesland_name,
```

```
## # A tibble: 400 × 4
```

```
##   alo_quote landkreis_name  bundesland_name  ost_name
```

```
##   <dbl> <chr>                <chr>                <chr>
```

```
## 1     6.28 Flensburg        Schleswig-Holstein Westdeutschland
```

```
## 2     5.59 Kiel            Schleswig-Holstein Westdeutschland
```

```
## 3     6.36 Lübeck          Schleswig-Holstein Westdeutschland
```

```
## 4     6.06 Neumünster       Schleswig-Holstein Westdeutschland
```

```
## 5     6.17 Dithmarschen     Schleswig-Holstein Westdeutschland
```

```
## 6     7.06 Herzogtum Lauenburg Schleswig-Holstein Westdeutschland
```

```
## 7     4.53 Nordfriesland     Schleswig-Holstein Westdeutschland
```

```
## 8     5.16 Ostholstein      Schleswig-Holstein Westdeutschland
```

```
## 9     6.56 Pinneberg        Schleswig-Holstein Westdeutschland
```

```
## 10    5.85 Plön            Schleswig-Holstein Westdeutschland
```

```
## # i 390 more rows
```


```
gesamtdaten %>%
  select(alo_quote, landkreis_name, bundesland_name,
  mutate(baden_wuerttemberg = as.factor(ifelse(bunde
```

```
## # A tibble: 400 × 5
##   alo_quote landkreis_name  bundesland_name  ost_name  baden_wuerttembe
##   <dbl> <chr>                <chr>          <chr>    <fct>
## 1      6.28 Flensburg        Schleswig-Holstein Westdeut... 0
## 2      5.59 Kiel            Schleswig-Holstein Westdeut... 0
## 3      6.36 Lübeck          Schleswig-Holstein Westdeut... 0
## 4      6.06 Neumünster      Schleswig-Holstein Westdeut... 0
## 5      6.17 Dithmarschen    Schleswig-Holstein Westdeut... 0
## 6      7.06 Herzogtum Lauenburg Schleswig-Holstein Westdeut... 0
## 7      4.53 Nordfriesland    Schleswig-Holstein Westdeut... 0
## 8      5.16 Ostholstein      Schleswig-Holstein Westdeut... 0
## 9      6.56 Pinneberg        Schleswig-Holstein Westdeut... 0
## 10     5.85 Plön            Schleswig-Holstein Westdeut... 0
## # i 390 more rows
```

```
gesamtdaten %>%  
  select(alo_quote, landkreis_name, bundesland_name,  
    mutate(baden_wuerttemberg = as.factor(ifelse(bunde  
ggplot(aes(x = ost_name, y=alo_quote))
```



```
gesamtdaten %>%
  select(alo_quote, landkreis_name, bundesland_name,
  mutate(baden_wuerttemberg = as.factor(ifelse(bunde
  ggplot(aes(x = ost_name, y=alo_quote)) +
  geom_jitter(aes(color = ifelse(baden_wuerttemberg
```




```
gesamtdaten %>%
  select(alo_quote, landkreis_name, bundesland_name,
  mutate(baden_wuerttemberg = as.factor(ifelse(bunde
ggplot(aes(x = ost_name, y=alo_quote)) +
  geom_jitter(aes(color = ifelse(baden_wuerttemberg
  scale_color_identity()
```



```

gesamtdaten %>%
  select(alo_quote, landkreis_name, bundesland_name,
  mutate(baden_wuerttemberg = as.factor(ifelse(bunde
ggplot(aes(x = ost_name, y=alo_quote)) +
  geom_jitter(aes(color = ifelse(baden_wuerttemberg
scale_color_identity() +
  geom_boxplot(alpha = 0.1)


```



```

gesamtdaten %>%
  select(alo_quote, landkreis_name, bundesland_name,
  mutate(baden_wuerttemberg = as.factor(ifelse(bunde
ggplot(aes(x = ost_name, y=alo_quote)) +
  geom_jitter(aes(color = ifelse(baden_wuerttemberg
scale_color_identity() +
  geom_boxplot(alpha = 0.1) +
  theme_minimal()


```



```
gesamtdaten %>%
  select(alo_quote, landkreis_name, bundesland_name,
  mutate(baden_wuerttemberg = as.factor(ifelse(bunde
ggplot(aes(x = ost_name, y=alo_quote)) +
  geom_jitter(aes(color = ifelse(baden_wuerttemberg
scale_color_identity() +
  geom_boxplot(alpha = 0.1) +
  theme_minimal() +
  labs(title = "Arbeitslosenquote in Deutschland",
        subtitle = "Eine Beobachtung repräsentiert ei
        x = "",
        y = "Arbeitslosenquote",
        caption = "Quelle: Daten der Agentur für Arbe
```

## Arbeitslosenquote in Deutschland

Eine Beobachtung repräsentiert einen Landkreis, Baden-Württemberg rot eingefärbt



Quelle: Daten der Agentur für Arbeit aus dem Jahr 2023




# Arbeitslosenquote

Beschreiben Sie das gezeigte Schaubild

Arbeitslosenquote in Deutschland

Eine Beobachtung repräsentiert einen Landkreis, Baden-Württemberg rot eingefärbt



Quelle: Daten der Agentur für Arbeit aus dem Jahr 2023

# Arbeitslosenquote

## Beschreibung des Schaubilds:

- + Rote Datenpunkte Baden-Württemberg, fast alle unter dem Median in Westdeutschland
- + Median in Westdeutschland deutlich geringer als in Ostdeutschland
- + 75% Quantil in Westdeutschland deutlich unter dem Median in Ostdeutschland
- + Die meisten Landkreise unter 15% Arbeitslosenquote; Verglichen mit den europäischen Daten sehr gut

# Bruttoinlandsprodukt pro Kopf

Es gibt deutliche regionale Unterschiede zwischen den Landkreisen. Doch ist dies auch beim BIP pro Kopf der Fall? Und war das schon immer so?

Wir betrachten das BIP pro Kopf über die Zeit für ost- und westdeutsche Landkreise!

Hier können wir sehen:

- + ob es auch regionale Unterschiede im BIP pro Kopf gibt
- + ob die regionalen Unterschiede schon längere Zeit bestehen
- + ob die regionalen Unterschiede sich vergrößern oder verkleinern

# Bruttoinlandsprodukt pro Kopf

Das Bruttoinlandsprodukt stellt die wichtigste gesamtwirtschaftliche Kenngröße dar. Falls das BIP in einem Landkreis hoch ist könnte dies unter anderem daran liegen, dass

- + viele Personen in diesem Landkreis erwerbstätig sind,
- + oder das die Erwerbstätigen in Branchen mit hoher Produktivität arbeiten.

Falls der erste Punkt zutrifft sollte ein hohes BIP pro Kopf (berechnet als BIP pro **Einwohner**) tendenziell auch mit einer niedrigeren Arbeitslosenquote einhergehen.

```
options(scipen = 5)
```

```
options(scipen = 5)
bip_zeitreihe_namen
```

```
## # A tibble: 11,940 × 8
##   Regionalschlüssel Jahr      bip_einwohner bip_pro_kopf bundesland_name
##   <chr>          <dbl>      <dbl>      <dbl>      <dbl> <chr>
## 1 08111          1992 32946884000    593628    55501. Baden-Württembe
## 2 08115          1992 12090930000    343190    35231. Baden-Württembe
## 3 08116          1992 12275605000    487370    25187. Baden-Württembe
## 4 08117          1992  5062037000    248688    20355. Baden-Württembe
## 5 08118          1992 11714160000    475248    24649. Baden-Württembe
## 6 08119          1992  8500405000    389670    21814. Baden-Württembe
## 7 08121          1992  4219259000    118566    35586. Baden-Württembe
## 8 08125          1992  6073525000    283163    21449. Baden-Württembe
## 9 08126          1992  2273334000     96072    23663. Baden-Württembe
## 10 08127         1992  3432175000    169617    20235. Baden-Württembe
## # i 11,930 more rows
## # i 2 more variables: landkreis_name <chr>, ost_name <chr>
```

```
options(scipen = 5)
bip_zeitreihe_namen %>%
  filter( Jahr >= 2000 )
```

```
## # A tibble: 9,154 × 8
##   Regionalschlüssel  Jahr      bip_einwohner bip_pro_kopf bundesland_name
##   <chr>            <dbl>      <dbl>      <dbl>      <dbl> <chr>
## 1 08111            2000 35273886000    571528    61719. Baden-Württembe
## 2 08115            2000 13867882000    359476    38578. Baden-Württembe
## 3 08116            2000 14404617000    492914    29223. Baden-Württembe
## 4 08117            2000  6000420000    253970    23626. Baden-Württembe
## 5 08118            2000 14657540000    492014    29791. Baden-Württembe
## 6 08119            2000 10367512000    403830    25673. Baden-Württembe
## 7 08121            2000  5273634000    115590    45624. Baden-Württembe
## 8 08125            2000  8453750000    316406    26718. Baden-Württembe
## 9 08126            2000  3083030000    106494    28950. Baden-Württembe
## 10 08127           2000  4503834000    184222    24448. Baden-Württembe
## # i 9,144 more rows
## # i 2 more variables: landkreis_name <chr>, ost_name <chr>
```

```
options(scipen = 5)
bip_zeitreihe_namen %>%
  filter( Jahr >= 2000 ) %>%
  group_by(ost_name, Jahr)
```

```
## # A tibble: 9,154 × 8
## # Groups:   ost_name, Jahr [46]
##   Regionalschlüssel  Jahr      bip_einwohner bip_pro_kopf bundesland_name
##   <chr>             <dbl>      <dbl>      <dbl>      <dbl> <chr>
## 1 08111             2000 35273886000    571528    61719. Baden-Württembe
## 2 08115             2000 13867882000    359476    38578. Baden-Württembe
## 3 08116             2000 14404617000    492914    29223. Baden-Württembe
## 4 08117             2000  6000420000    253970    23626. Baden-Württembe
## 5 08118             2000 14657540000    492014    29791. Baden-Württembe
## 6 08119             2000 10367512000    403830    25673. Baden-Württembe
## 7 08121             2000  5273634000    115590    45624. Baden-Württembe
## 8 08125             2000  8453750000    316406    26718. Baden-Württembe
## 9 08126             2000 30830300000    106494    28950. Baden-Württembe
## 10 08127            2000  4503834000    184222    24448. Baden-Württembe
## # i 9,144 more rows
## # i 2 more variables: landkreis_name <chr>, ost_name <chr>
```




```
options(scipen = 5)
bip_zeitreihe_namen %>%
  filter( Jahr >= 2000 ) %>%
  group_by(ost_name, Jahr) %>%
  mutate( durchschnitt = mean(bip_pro_kopf),
          ulm = ifelse(landkreis_name == "Ulm", bip_
```

```
## # A tibble: 9,154 × 10
## # Groups:   ost_name, Jahr [46]
##   Regionalschlüssel  Jahr      bip_einwohner bip_pro_kopf bundesland_name
##   <chr>            <dbl>      <dbl>      <dbl>      <dbl> <chr>
## 1 08111            2000 35273886000    571528    61719. Baden-Württembe
## 2 08115            2000 13867882000    359476    38578. Baden-Württembe
## 3 08116            2000 14404617000    492914    29223. Baden-Württembe
## 4 08117            2000  6000420000    253970    23626. Baden-Württembe
## 5 08118            2000 14657540000    492014    29791. Baden-Württembe
## 6 08119            2000 10367512000    403830    25673. Baden-Württembe
## 7 08121            2000  5273634000    115590    45624. Baden-Württembe
## 8 08125            2000  8453750000    316406    26718. Baden-Württembe
## 9 08126            2000  3083030000    106494    28950. Baden-Württembe
## 10 08127           2000  4503834000    184222    24448. Baden-Württembe
## # i 9,144 more rows
## # i 4 more variables: landkreis_name <chr>, ost_name <chr>, durchschnitt <dbl>
## #   ulm <dbl>
```

```
options(scipen = 5)
bip_zeitreihe_namen %>%
  filter( Jahr >= 2000 ) %>%
  group_by(ost_name, Jahr) %>%
  mutate( durchschnitt = mean(bip_pro_kopf),
          ulm = ifelse(landkreis_name == "Ulm", bip_
ggplot()
```


```
options(scipen = 5)
bip_zeitreihe_namen %>%
  filter( Jahr >= 2000 ) %>%
  group_by(ost_name, Jahr) %>%
  mutate( durchschnitt = mean(bip_pro_kopf),
          ulm = ifelse(landkreis_name == "Ulm", bip_
ggplot() +
  geom_line(aes(x = Jahr, y = bip_pro_kopf, group =
```




```

options(scipen = 5)
bip_zeitreihe_namen %>%
  filter( Jahr >= 2000 ) %>%
  group_by(ost_name, Jahr) %>%
  mutate( durchschnitt = mean(bip_pro_kopf),
          ulm = ifelse(landkreis_name == "Ulm", bip_
ggplot() +
  geom_line(aes(x = Jahr, y = bip_pro_kopf, group =
  geom_line(aes(x = Jahr, y = durchschnitt, group =

```




```
options(scipen = 5)
bip_zeitreihe_namen %>%
  filter( Jahr >= 2000 ) %>%
  group_by(ost_name, Jahr) %>%
  mutate( durchschnitt = mean(bip_pro_kopf),
          ulm = ifelse(landkreis_name == "Ulm", bip_
ggplot() +
  geom_line(aes(x = Jahr, y = bip_pro_kopf, group =
  geom_line(aes(x = Jahr, y = durchschnitt, group =
  geom_line(aes(x = Jahr, y = ulm, group = Regionals
```



```

options(scipen = 5)
bip_zeitreihe_namen %>%
  filter( Jahr >= 2000 ) %>%
  group_by(ost_name, Jahr) %>%
  mutate( durchschnitt = mean(bip_pro_kopf),
          ulm = ifelse(landkreis_name == "Ulm", bip_
ggplot() +
  geom_line(aes(x = Jahr, y = bip_pro_kopf, group =
  geom_line(aes(x = Jahr, y = durchschnitt, group =
  geom_line(aes(x = Jahr, y = ulm, group = Regionals
  scale_y_continuous(trans = "log10")


```




```

options(scipen = 5)
bip_zeitreihe_namen %>%
  filter( Jahr >= 2000 ) %>%
  group_by(ost_name, Jahr) %>%
  mutate( durchschnitt = mean(bip_pro_kopf),
          ulm = ifelse(landkreis_name == "Ulm", bip_
ggplot() +
  geom_line(aes(x = Jahr, y = bip_pro_kopf, group =
  geom_line(aes(x = Jahr, y = durchschnitt, group =
  geom_line(aes(x = Jahr, y = ulm, group = Regionals
  scale_y_continuous(trans = "log10") +
  theme_minimal()

```



```
options(scipen = 5)
bip_zeitreihe_namen %>%
  filter( Jahr >= 2000 ) %>%
  group_by(ost_name, Jahr) %>%
  mutate( durchschnitt = mean(bip_pro_kopf),
          ulm = ifelse(landkreis_name == "Ulm", bip_
ggplot() +
  geom_line(aes(x = Jahr, y = bip_pro_kopf, group =
  geom_line(aes(x = Jahr, y = durchschnitt, group =
  geom_line(aes(x = Jahr, y = ulm, group = Regionals
  scale_y_continuous(trans = "log10") +
  theme_minimal() +
  facet_wrap(ost_name ~ .)
```






```

options(scipen = 5)
bip_zeitreihe_namen %>%
  filter( Jahr >= 2000 ) %>%
  group_by(ost_name, Jahr) %>%
  mutate( durchschnitt = mean(bip_pro_kopf),
          ulm = ifelse(landkreis_name == "Ulm", bip_
ggplot() +
  geom_line(aes(x = Jahr, y = bip_pro_kopf, group =
  geom_line(aes(x = Jahr, y = durchschnitt, group =
  geom_line(aes(x = Jahr, y = ulm, group = Regionals
  scale_y_continuous(trans = "log10") +
  theme_minimal() +
  facet_wrap(ost_name ~ .) +
  theme(legend.position = "none")

```




```

options(scipen = 5)
bip_zeitreihe_namen %>%
  filter( Jahr >= 2000 ) %>%
  group_by(ost_name, Jahr) %>%
  mutate( durchschnitt = mean(bip_pro_kopf),
          ulm = ifelse(landkreis_name == "Ulm", bip_
ggplot() +
  geom_line(aes(x = Jahr, y = bip_pro_kopf, group = 
  geom_line(aes(x = Jahr, y = durchschnitt, group = 
  geom_line(aes(x = Jahr, y = ulm, group = Regionals
  scale_y_continuous(trans = "log10") +
  theme_minimal() +
  facet_wrap(ost_name ~ .) +
  theme(legend.position = "none") +
  labs(title = "Ein Vergleich des BIP pro Kopf von o
        subtitle = "Durchschnittswerte in Dunkelblau,
        caption = "Quelle: Daten der Statistischen Äm
        x = "Jahr",
        y = "BIP pro Kopf")

```


## Ein Vergleich des BIP pro Kopf von ost- und westdeutschen Land

Durchschnittswerte in Dunkelblau, Ulm in Dunkelgrün



Quelle: Daten der Statistischen Ämter der Länder und des Bundes.

```
options(scipen = 5)
bip_zeitreihe_namen %>%
  filter( Jahr >= 2000 ) %>%
  group_by(ost_name, Jahr) %>%
  mutate( durchschnitt = mean(bip_pro_kopf),
          ulm = ifelse(landkreis_name == "Ulm", bip_
ggplot() +
  geom_line(aes(x = Jahr, y = bip_pro_kopf, group =
  geom_line(aes(x = Jahr, y = durchschnitt, group =
  geom_line(aes(x = Jahr, y = ulm, group = Regionals
  scale_y_continuous(trans = "log10") +
  theme_minimal() +
  facet_wrap(ost_name ~ .) +
  theme(legend.position = "none") +
  labs(title = "Ein Vergleich des BIP pro Kopf von o
        subtitle = "Durchschnittswerte in Dunkelblau,
        caption = "Quelle: Daten der Statistischen Äm
        x = "Jahr",
        y = "BIP pro Kopf")
```



Beschreiben und interpretieren Sie das gezeigte Schaubild.

# Bruttoinlandsprodukt pro Kopf

## Beschreibung:

- + Logarithmische Skalierung der y-Achse
- + Das Niveau des BIP pro Kopf ist in den ostdeutschen Landkreisen deutlich niedriger als in den westdeutschen.
- + Stadtkreis Ulm hat ein sehr hohes BIP pro Kopf, auch im Zeitablauf
- + Das BIP Pro Kopf nimmt im Zeitablauf in den ostdeutschen Landkreisen zu, doch erreicht es mit durchschnittlich 33936€ den Wert, welchen die westdeutschen Landkreise durchschnittlich in 2012 hatten!
- + In 2008/2009 gibt es überall einen Einbruch beim BIP pro Kopf, jedoch scheint dieser in den ostdeutschen Bundesländern nicht so stark gewesen zu sein

# Bruttoinlandsprodukt pro Kopf

## Beschreibung:

- + Logarithmische Skalierung der y-Achse
- + Das Niveau des BIP pro Kopf ist in den ostdeutschen Landkreisen deutlich niedriger als in den westdeutschen.
- + Stadtkreis Ulm hat ein sehr hohes BIP pro Kopf, auch im Zeitablauf
- + Das BIP Pro Kopf nimmt im Zeitablauf in den ostdeutschen Landkreisen zu, doch erreicht es mit durchschnittlich 33936€ den Wert, welchen die westdeutschen Landkreise durchschnittlich in 2012 hatten!
- + In 2008/2009 gibt es überall einen Einbruch beim BIP pro Kopf, jedoch scheint dieser in den ostdeutschen Bundesländern nicht so stark gewesen zu sein

## Interpretation:


- + Eine Wachstumsprozess im BIP pro Kopf findet in allen Landkreisen statt, jedoch gibt es für die ostdeutschen Landkreise, welche deutlich niedriger gestartet sind, keinen erkennbaren Anpassungsprozess in Form eines schnelleren Wachstums
- + Wir sehen auch keinen Anpassungsprozess der Landkreise in Westdeutschland
- + Fraglich ist, ob wir hier mit einem Anpassungsprozess von strukturschwachen Landkreisen überhaupt rechnen sollten

# Bruttoinlandsprodukt pro Kopf

Daten ab 1992 vorhanden, d.h. wir können auch weiter zurück gehen:

- + **Allerdings:** Keine Daten zu *allen* Landkreisen, daher Vorsicht!
- + Hier sehen wir einen Anpassungsprozess in den 1990er Jahren
- + Anpassung verlangsamt sich, ab 2010 praktisch parallel

Ein Vergleich des BIP pro Kopf von ost- und westdeutschen Landkreisen  
Zeitreihe ab 1992 bis 2022



Quelle: Daten der Statistischen Ämter der Länder und des Bundes.

# Wachstum des BIP pro Kopf

Paneldaten beim BIP pro Kopf vorhanden, d.h. wir können:

- + Das **Wachstum** des BIP pro Kopf
- + Für alle Landkreise in Deutschland
- + Seit 2000 bis 2022

berechnen und visualisieren.



# Wachstum des BIP pro Kopf

Paneldaten beim BIP pro Kopf vorhanden, d.h. wir können:

- + Das **Wachstum** des BIP pro Kopf
- + Für alle Landkreise in Deutschland
- + Seit 2000 bis 2022

berechnen und visualisieren.

Können wir einen Anpassungsprozess über die Wachstumsraten des BIP pro Kopf feststellen?

bip\_zeitreihe\_namen

```
## # A tibble: 11,940 × 8
##   Regionalschlüssel Jahr      bip einwohner bip_pro_kopf bundesland_name
##   <chr>          <dbl>    <dbl>    <dbl>    <dbl> <chr>
## 1 08111          1992 32946884000    593628    55501. Baden-Württembe
## 2 08115          1992 12090930000    343190    35231. Baden-Württembe
## 3 08116          1992 12275605000    487370    25187. Baden-Württembe
## 4 08117          1992  5062037000    248688    20355. Baden-Württembe
## 5 08118          1992 11714160000    475248    24649. Baden-Württembe
## 6 08119          1992  8500405000    389670    21814. Baden-Württembe
## 7 08121          1992  4219259000    118566    35586. Baden-Württembe
## 8 08125          1992  6073525000    283163    21449. Baden-Württembe
## 9 08126          1992  2273334000     96072    23663. Baden-Württembe
## 10 08127         1992  3432175000    169617    20235. Baden-Württembe
## # i 11,930 more rows
## # i 2 more variables: landkreis_name <chr>, ost_name <chr>
```

```
bip_zeitreihe_namen %>%
```

```
  group_by(Regionalschlüssel)
```

```
## # A tibble: 11,940 × 8
## # Groups:   Regionalschlüssel [398]
##   Regionalschlüssel  Jahr      bip einwohner bip_pro_kopf bundesland_name
##   <chr>            <dbl>    <dbl>    <dbl>    <dbl> <chr>
## 1 08111            1992 32946884000  593628    55501. Baden-Württembe
## 2 08115            1992 12090930000  343190    35231. Baden-Württembe
## 3 08116            1992 12275605000  487370    25187. Baden-Württembe
## 4 08117            1992  5062037000  248688    20355. Baden-Württembe
## 5 08118            1992 11714160000  475248    24649. Baden-Württembe
## 6 08119            1992  8500405000  389670    21814. Baden-Württembe
## 7 08121            1992  4219259000  118566    35586. Baden-Württembe
## 8 08125            1992  6073525000  283163    21449. Baden-Württembe
## 9 08126            1992  2273334000   96072    23663. Baden-Württembe
## 10 08127           1992  3432175000  169617    20235. Baden-Württembe
## # i 11,930 more rows
## # i 2 more variables: landkreis_name <chr>, ost_name <chr>
```

```
bip_zeitreihe_namen %>%  
  group_by(Regionalschlüssel) %>%  
  arrange(Regionalschlüssel, Jahr)
```

```
## # A tibble: 11,940 × 8  
## # Groups:   Regionalschlüssel [398]  
##   Regionalschlüssel  Jahr      bip einwohner bip_pro_kopf bundesland_name  
##   <chr>            <dbl>    <dbl>    <dbl>    <dbl> <chr>  
## 1 01001            1992 2555393000    86642    29494. Schleswig-Holste  
## 2 01001            1994 2624290000    86287    30414. Schleswig-Holste  
## 3 01001            1995 2628469000    85506    30740. Schleswig-Holste  
## 4 01001            1996 2578880000    84499    30520. Schleswig-Holste  
## 5 01001            1997 2725086000    83344    32697. Schleswig-Holste  
## 6 01001            1998 2872187000    82112    34979. Schleswig-Holste  
## 7 01001            1999 2712126000    81276    33369. Schleswig-Holste  
## 8 01001            2000 2487282000    80758    30799. Schleswig-Holste  
## 9 01001            2001 2465393000    80489    30630. Schleswig-Holste  
## 10 01001           2002 2635779000    80414    32778. Schleswig-Holste  
## # i 11,930 more rows  
## # i 2 more variables: landkreis_name <chr>, ost_name <chr>
```

```
bip_zeitreihe_namen %>%
  group_by(Regionalschlüssel) %>%
  arrange(Regionalschlüssel, Jahr) %>%
  mutate( bip_pro_kopf_wachstum = 100*(bip_pro_kopf
```

```
## # A tibble: 11,940 × 9
## # Groups:   Regionalschlüssel [398]
##   Regionalschlüssel  Jahr      bip einwohner bip_pro_kopf bundesland_name
##   <chr>              <dbl>    <dbl>    <dbl>    <dbl> <chr>
## 1 01001              1992 2555393000    86642    29494. Schleswig-Holste
## 2 01001              1994 2624290000    86287    30414. Schleswig-Holste
## 3 01001              1995 2628469000    85506    30740. Schleswig-Holste
## 4 01001              1996 2578880000    84499    30520. Schleswig-Holste
## 5 01001              1997 2725086000    83344    32697. Schleswig-Holste
## 6 01001              1998 2872187000    82112    34979. Schleswig-Holste
## 7 01001              1999 2712126000    81276    33369. Schleswig-Holste
## 8 01001              2000 2487282000    80758    30799. Schleswig-Holste
## 9 01001              2001 2465393000    80489    30630. Schleswig-Holste
## 10 01001             2002 2635779000    80414    32778. Schleswig-Holste
## # i 11,930 more rows
## # i 3 more variables: landkreis_name <chr>, ost_name <chr>,
## #   bip_pro_kopf_wachstum <dbl>
```

```
bip_zeitreihe_namen %>%
  group_by(Regionalschlüssel) %>%
  arrange(Regionalschlüssel, Jahr) %>%
  mutate( bip_pro_kopf_wachstum = 100*(bip_pro_kopf
  ungroup())
```

```
## # A tibble: 11,940 × 9
##   Regionalschlüssel  Jahr      bip einwohner bip_pro_kopf bundesland_name
##   <chr>            <dbl>    <dbl>    <dbl>    <dbl> <chr>
## 1 01001            1992 2555393000    86642    29494. Schleswig-Holste
## 2 01001            1994 2624290000    86287    30414. Schleswig-Holste
## 3 01001            1995 2628469000    85506    30740. Schleswig-Holste
## 4 01001            1996 2578880000    84499    30520. Schleswig-Holste
## 5 01001            1997 2725086000    83344    32697. Schleswig-Holste
## 6 01001            1998 2872187000    82112    34979. Schleswig-Holste
## 7 01001            1999 2712126000    81276    33369. Schleswig-Holste
## 8 01001            2000 2487282000    80758    30799. Schleswig-Holste
## 9 01001            2001 2465393000    80489    30630. Schleswig-Holste
## 10 01001           2002 2635779000    80414    32778. Schleswig-Holste
## # i 11,930 more rows
## # i 3 more variables: landkreis_name <chr>, ost_name <chr>,
## #   bip_pro_kopf_wachstum <dbl>
```

```
bip_zeitreihe_namen %>%
  group_by(Regionalschlüssel) %>%
  arrange(Regionalschlüssel, Jahr) %>%
  mutate( bip_pro_kopf_wachstum = 100*(bip_pro_kopf
  ungroup() %>%
  group_by(ost_name, Jahr)
```

```
## # A tibble: 11,940 × 9
## # Groups:   ost_name, Jahr [60]
##   Regionalschlüssel  Jahr      bip einwohner bip_pro_kopf bundesland_name
##   <chr>             <dbl>    <dbl>    <dbl>    <dbl> <chr>
## 1 01001             1992 2555393000    86642    29494. Schleswig-Holste
## 2 01001             1994 2624290000    86287    30414. Schleswig-Holste
## 3 01001             1995 2628469000    85506    30740. Schleswig-Holste
## 4 01001             1996 2578880000    84499    30520. Schleswig-Holste
## 5 01001             1997 2725086000    83344    32697. Schleswig-Holste
## 6 01001             1998 2872187000    82112    34979. Schleswig-Holste
## 7 01001             1999 2712126000    81276    33369. Schleswig-Holste
## 8 01001             2000 2487282000    80758    30799. Schleswig-Holste
## 9 01001             2001 2465393000    80489    30630. Schleswig-Holste
## 10 01001            2002 2635779000    80414    32778. Schleswig-Holste
## # i 11,930 more rows
## # i 3 more variables: landkreis_name <chr>, ost_name <chr>,
## #   bip_pro_kopf_wachstum <dbl>
```

```
bip_zeitreihe_namen %>%
  group_by(Regionalschlüssel) %>%
  arrange(Regionalschlüssel, Jahr) %>%
  mutate( bip_pro_kopf_wachstum = 100*(bip_pro_kopf
  ungroup() %>%
  group_by(ost_name, Jahr) %>%
  mutate( durchschnitt = mean(bip_pro_kopf_wachstum,
```

```
## # A tibble: 11,940 × 10
## # Groups:   ost_name, Jahr [60]
##   Regionalschlüssel  Jahr      bip einwohner bip_pro_kopf bundesland_name
##   <chr>              <dbl>    <dbl>      <dbl>      <dbl> <chr>
## 1 01001              1992 2555393000    86642    29494. Schleswig-Holste
## 2 01001              1994 2624290000    86287    30414. Schleswig-Holste
## 3 01001              1995 2628469000    85506    30740. Schleswig-Holste
## 4 01001              1996 2578880000    84499    30520. Schleswig-Holste
## 5 01001              1997 2725086000    83344    32697. Schleswig-Holste
## 6 01001              1998 2872187000    82112    34979. Schleswig-Holste
## 7 01001              1999 2712126000    81276    33369. Schleswig-Holste
## 8 01001              2000 2487282000    80758    30799. Schleswig-Holste
## 9 01001              2001 2465393000    80489    30630. Schleswig-Holste
## 10 01001             2002 2635779000    80414    32778. Schleswig-Holste
## # i 11,930 more rows
## # i 4 more variables: landkreis_name <chr>, ost_name <chr>,
## #   bip_pro_kopf_wachstum <dbl>, durchschnitt <dbl>
```



```
bip_zeitreihe_namen %>%  
  group_by(Regionalschluessel) %>%  
  arrange(Regionalschluessel, Jahr) %>%  
  mutate( bip_pro_kopf_wachstum = 100*(bip_pro_kopf  
  ungroup() %>%  
  group_by(ost_name, Jahr) %>%  
  mutate( durchschnitt = mean(bip_pro_kopf_wachstum,  
  ungroup() -> bip_wachstum
```

```
bip_zeitreihe_namen %>%
  group_by(Regionalschlüssel) %>%
  arrange(Regionalschlüssel, Jahr) %>%
  mutate( bip_pro_kopf_wachstum = 100*(bip_pro_kopf
  ungroup() %>%
  group_by(ost_name, Jahr) %>%
  mutate( durchschnitt = mean(bip_pro_kopf_wachstum,
  ungroup() -> bip_wachstum
```

```
bip_wachstum
```

```
## # A tibble: 11,940 × 10
##   Regionalschlüssel  Jahr      bip einwohner bip_pro_kopf bundesland_name
##   <chr>            <dbl>    <dbl>    <dbl>    <dbl> <chr>
## 1 01001            1992 2555393000    86642    29494. Schleswig-Holste
## 2 01001            1994 2624290000    86287    30414. Schleswig-Holste
## 3 01001            1995 2628469000    85506    30740. Schleswig-Holste
## 4 01001            1996 2578880000    84499    30520. Schleswig-Holste
## 5 01001            1997 2725086000    83344    32697. Schleswig-Holste
## 6 01001            1998 2872187000    82112    34979. Schleswig-Holste
## 7 01001            1999 2712126000    81276    33369. Schleswig-Holste
## 8 01001            2000 2487282000    80758    30799. Schleswig-Holste
## 9 01001            2001 2465393000    80489    30630. Schleswig-Holste
## 10 01001           2002 2635779000    80414    32778. Schleswig-Holste
## # i 11,930 more rows
## # i 4 more variables: landkreis_name <chr>, ost_name <chr>,
## #   bip_pro_kopf_wachstum <dbl>, durchschnitt <dbl>
```

```

bip_zeitreihe_namen %>%
  group_by(Regionalschlüssel) %>%
  arrange(Regionalschlüssel, Jahr) %>%
  mutate( bip_pro_kopf_wachstum = 100*(bip_pro_kopf
  ungroup() %>%
  group_by(ost_name, Jahr) %>%
  mutate( durchschnitt = mean(bip_pro_kopf_wachstum,
  ungroup() -> bip_wachstum

bip_wachstum %>%
  filter( Jahr >= 2000 )

```

```

## # A tibble: 9,154 × 10
##   Regionalschlüssel  Jahr      bip einwohner bip_pro_kopf bundesland_name
##   <chr>            <dbl>    <dbl>    <dbl>    <dbl> <chr>
## 1 01001            2000 2487282000    80758    30799. Schleswig-Holste
## 2 01001            2001 2465393000    80489    30630. Schleswig-Holste
## 3 01001            2002 2635779000    80414    32778. Schleswig-Holste
## 4 01001            2003 2705233000    80538    33590. Schleswig-Holste
## 5 01001            2004 2867823000    80783    35500. Schleswig-Holste
## 6 01001            2005 2900791000    80892    35860. Schleswig-Holste
## 7 01001            2006 3021890000    81052    37283. Schleswig-Holste
## 8 01001            2007 3051250000    81634    37377. Schleswig-Holste
## 9 01001            2008 3105912000    82403    37692. Schleswig-Holste
## 10 01001           2009 2993960000    82478    36300. Schleswig-Holste
## # i 9,144 more rows
## # i 4 more variables: landkreis_name <chr>, ost_name <chr>,
## #   bip_pro_kopf_wachstum <dbl>, durchschnitt <dbl>

```


```
bip_zeitreihe_namen %>%  
  group_by(Regionalschlüssel) %>%  
  arrange(Regionalschlüssel, Jahr) %>%  
  mutate( bip_pro_kopf_wachstum = 100*(bip_pro_kopf  
  ungroup() %>%  
  group_by(ost_name, Jahr) %>%  
  mutate( durchschnitt = mean(bip_pro_kopf_wachstum,  
  ungroup() -> bip_wachstum  
  
bip_wachstum %>%  
  filter( Jahr >= 2000 ) %>%  
  ggplot()
```

```

bip_zeitreihe_namen %>%
  group_by(Regionalschlüssel) %>%
  arrange(Regionalschlüssel, Jahr) %>%
  mutate( bip_pro_kopf_wachstum = 100*(bip_pro_kopf
  ungroup() %>%
  group_by(ost_name, Jahr) %>%
  mutate( durchschnitt = mean(bip_pro_kopf_wachstum,
  ungroup() -> bip_wachstum

bip_wachstum %>%
  filter( Jahr >= 2000 ) %>%
  ggplot() +
  geom_line(aes(x = Jahr, y = bip_pro_kopf_wachstum,

```




```

bip_zeitreihe_namen %>%
  group_by(Regionalschlüssel) %>%
  arrange(Regionalschlüssel, Jahr) %>%
  mutate( bip_pro_kopf_wachstum = 100*(bip_pro_kopf
  ungroup() %>%
  group_by(ost_name, Jahr) %>%
  mutate( durchschnitt = mean(bip_pro_kopf_wachstum,
  ungroup() -> bip_wachstum

bip_wachstum %>%
  filter( Jahr >= 2000 ) %>%
  ggplot() +
  geom_line(aes(x = Jahr, y = bip_pro_kopf_wachstum,
  geom_line(aes(x = Jahr, y = durchschnitt, group =

```




```

bip_zeitreihe_namen %>%
  group_by(Regionalschlüssel) %>%
  arrange(Regionalschlüssel, Jahr) %>%
  mutate( bip_pro_kopf_wachstum = 100*(bip_pro_kopf
  ungroup() %>%
  group_by(ost_name, Jahr) %>%
  mutate( durchschnitt = mean(bip_pro_kopf_wachstum,
  ungroup() -> bip_wachstum

bip_wachstum %>%
  filter( Jahr >= 2000 ) %>%
  ggplot() +
  geom_line(aes(x = Jahr, y = bip_pro_kopf_wachstum,
  geom_line(aes(x = Jahr, y = durchschnitt, group =
  scale_color_manual(values = c("#D55E00", "#0072B2")

```




```

bip_zeitreihe_namen %>%
  group_by(Regionalschlüssel) %>%
  arrange(Regionalschlüssel, Jahr) %>%
  mutate( bip_pro_kopf_wachstum = 100*(bip_pro_kopf
  ungroup() %>%
  group_by(ost_name, Jahr) %>%
  mutate( durchschnitt = mean(bip_pro_kopf_wachstum,
  ungroup() -> bip_wachstum

bip_wachstum %>%
  filter( Jahr >= 2000 ) %>%
  ggplot() +
  geom_line(aes(x = Jahr, y = bip_pro_kopf_wachstum,
  geom_line(aes(x = Jahr, y = durchschnitt, group =
  scale_color_manual(values = c("#D55E00", "#0072B2")
  theme_minimal()

```






```

bip_zeitreihe_namen %>%
  group_by(Regionalschlüssel) %>%
  arrange(Regionalschlüssel, Jahr) %>%
  mutate( bip_pro_kopf_wachstum = 100*(bip_pro_kopf
  ungroup() %>%
  group_by(ost_name, Jahr) %>%
  mutate( durchschnitt = mean(bip_pro_kopf_wachstum,
  ungroup() -> bip_wachstum

bip_wachstum %>%
  filter( Jahr >= 2000 ) %>%
  ggplot() +
  geom_line(aes(x = Jahr, y = bip_pro_kopf_wachstum,
  geom_line(aes(x = Jahr, y = durchschnitt, group =
  scale_color_manual(values = c("#D55E00", "#0072B2")
  theme_minimal() +
  labs(color = "Durchschnitt der Landkreise",
        title = "Die Wachstumsrate des BIP pro Kopf v
        caption = "Quelle: Daten der Statistischen Äm
        x = "Jahr",
        y = "Veränderung des BIP pro Kopf")

```

## Die Wachstumsrate des BIP pro Kopf von ost- und westdeutschen Landkreisen




Quelle: Daten der Statistischen Ämter der Länder und des Bundes.

```

bip_zeitreihe_namen %>%
  group_by(Regionalschlüssel) %>%
  arrange(Regionalschlüssel, Jahr) %>%
  mutate( bip_pro_kopf_wachstum = 100*(bip_pro_kopf
  ungroup() %>%
  group_by(ost_name, Jahr) %>%
  mutate( durchschnitt = mean(bip_pro_kopf_wachstum,
  ungroup() -> bip_wachstum

bip_wachstum %>%
  filter( Jahr >= 2000 ) %>%
  ggplot() +
  geom_line(aes(x = Jahr, y = bip_pro_kopf_wachstum,
  geom_line(aes(x = Jahr, y = durchschnitt, group =
  scale_color_manual(values = c("#D55E00", "#0072B2"
  theme_minimal() +
  labs(color = "Durchschnitt der Landkreise",
        title = "Die Wachstumsrate des BIP pro Kopf v
        caption = "Quelle: Daten der Statistischen Äm
        x = "Jahr",
        y = "Veränderung des BIP pro Kopf") +
  theme(legend.position = "none")

```




```

bip_zeitreihe_namen %>%
  group_by(Regionalschlüssel) %>%
  arrange(Regionalschlüssel, Jahr) %>%
  mutate( bip_pro_kopf_wachstum = 100*(bip_pro_kopf
  ungroup() %>%
  group_by(ost_name, Jahr) %>%
  mutate( durchschnitt = mean(bip_pro_kopf_wachstum,
  ungroup() -> bip_wachstum

bip_wachstum %>%
  filter( Jahr >= 2000 ) %>%
  ggplot() +
  geom_line(aes(x = Jahr, y = bip_pro_kopf_wachstum,
  geom_line(aes(x = Jahr, y = durchschnitt, group =
  scale_color_manual(values = c("#D55E00", "#0072B2")
  theme_minimal() +
  labs(color = "Durchschnitt der Landkreise",
        title = "Die Wachstumsrate des BIP pro Kopf v
        caption = "Quelle: Daten der Statistischen Äm
        x = "Jahr",
        y = "Veränderung des BIP pro Kopf") +
  theme(legend.position = "none") +
  geom_text(aes(x=2000, y=40, label = "-- Durchschni

```




```

bip_zeitreihe_namen %>%
  group_by(Regionalschlüssel) %>%
  arrange(Regionalschlüssel, Jahr) %>%
  mutate( bip_pro_kopf_wachstum = 100*(bip_pro_kopf
  ungroup() %>%
  group_by(ost_name, Jahr) %>%
  mutate( durchschnitt = mean(bip_pro_kopf_wachstum,
  ungroup() -> bip_wachstum

bip_wachstum %>%
  filter( Jahr >= 2000 ) %>%
  ggplot() +
  geom_line(aes(x = Jahr, y = bip_pro_kopf_wachstum,
  geom_line(aes(x = Jahr, y = durchschnitt, group =
  scale_color_manual(values = c("#D55E00", "#0072B2")
  theme_minimal() +
  labs(color = "Durchschnitt der Landkreise",
        title = "Die Wachstumsrate des BIP pro Kopf v
        caption = "Quelle: Daten der Statistischen Äm
        x = "Jahr",
        y = "Veränderung des BIP pro Kopf") +
  theme(legend.position = "none") +
  geom_text(aes(x=2000, y=40, label = "-- Durchschni
  geom_text(aes(x=2000, y=35, label = "-- Durchschni

```



# Wachstum des BIP pro Kopf

## Beschreibung:

- + Im Durchschnitt sehr ähnliche Wachstumsraten
- + Immer wieder vereinzelt sehr hohe Wachstumsraten pro Landkreis
  - + Hängt vermutlich mit großen Projekten auf Landkreisebene zusammen
- + Der Einbruch in der Finanzkrise ist sowohl bei ost- als auch westdeutschen Landkreisen zu sehen

## Interpretation:

- + Es findet keine Anpassung des BIP pro Kopf über die Zeit statt
- + Die Gelder durch den Soli-Ausgleich führen nicht zu der (erhofften) starken Aufholjagd
- + Ostdeutsche Landkreise haben sich stark entwickelt
  - + Diese Entwicklung sollte jedoch nicht absolut, sondern relativ zu westdeutschen Landkreisen betrachtet werden

# Wachstum des BIP pro Kopf

## Beschreibung:

- + Im Durchschnitt sehr ähnliche Wachstumsraten
- + Immer wieder vereinzelt sehr hohe Wachstumsraten pro Landkreis
  - + Hängt vermutlich mit großen Projekten auf Landkreisebene zusammen
- + Der Einbruch in der Finanzkrise ist sowohl bei ost- als auch westdeutschen Landkreisen zu sehen

## Interpretation:

- + Es findet keine Anpassung des BIP pro Kopf über die Zeit statt
- + Die Gelder durch den Soli-Ausgleich führen nicht zu der (erhofften) starken Aufholjagd
- + Ostdeutsche Landkreise haben sich stark entwickelt
  - + Diese Entwicklung sollte jedoch nicht absolut, sondern relativ zu westdeutschen Landkreisen betrachtet werden

Es ist kein Anpassungsprozess ersichtlich, dafür sind die Wachstumsraten zu ähnlich.

# Bruttoinlandsprodukt pro Kopf

Bisherige Grafiken:

- + Punktwolke + Boxplot zeigt die Verteilung
- + Liniendiagramm zeigt die Entwicklung

# Bruttoinlandsprodukt pro Kopf

Bisherige Grafiken:

- + Punktwolke + Boxplot zeigt die Verteilung
- + Liniendiagramm zeigt die Entwicklung

Alternative Darstellungen der Verteilung:

- + Historgamm (nächste Folie)
- + Kerndichteschätzer (siehe ausführliche Case-Study)

Alternative Darstellung der Entwicklung:

- + Small multiples (siehe ausführliche Case-Study)
- + Slopechart (siehe z.B. [Data Vizualisation von Claus Wilke](#) mit [Code hier](#))
- + Viele unterschiedliche Grafiken in der [R Graph Gallery](#) mit dem dazugehörigen Code



gesamtdaten

```
## # A tibble: 400 × 14
##   Regionalschlüssel total_alo landkreis_name bundesland bundesland_name
##   <chr>                <dbl> <chr>                <chr>      <chr>
## 1 01001                4131. Flensburg      01        Schleswig-Holst
## 2 01002                10581 Kiel          01        Schleswig-Holst
## 3 01003                9216. Lübeck      01        Schleswig-Holst
## 4 01004                3604. Neumünster    01        Schleswig-Holst
## 5 01051                4126. Dithmarschen  01        Schleswig-Holst
## 6 01053                5586. Herzogtum Lauenburg 01        Schleswig-Holst
## 7 01054                4491. Nordfriesland  01        Schleswig-Holst
## 8 01055                5176. Ostholstein   01        Schleswig-Holst
## 9 01056                9280. Pinneberg     01        Schleswig-Holst
## 10 01057               2848. Plön        01        Schleswig-Holst
## # i 390 more rows
## # i 9 more variables: Schulden_pro_kopf_lk <dbl>, Einwohner <dbl>,
## #   Schulden_gesamt <dbl>, bip <dbl>, bip_pro_kopf <dbl>, erw <dbl>,
## #   alo_quote <dbl>, ost <fct>, ost_name <chr>
```

```
gesamtdaten %>%
```

```
  group_by(ost_name)
```


```
## # A tibble: 400 × 14
## # Groups:   ost_name [2]
##   Regionalschluessel total_alo landkreis_name    bundesland bundesland_name
##   <chr>              <dbl> <chr>          <chr>      <chr>
## 1 01001              4131. Flensburg      01        Schleswig-Holst
## 2 01002             10581 Kiel            01        Schleswig-Holst
## 3 01003             9216. Lübeck          01        Schleswig-Holst
## 4 01004             3604. Neumünster      01        Schleswig-Holst
## 5 01051             4126. Dithmarschen    01        Schleswig-Holst
## 6 01053             5586. Herzogtum Lauenburg 01        Schleswig-Holst
## 7 01054             4491. Nordfriesland    01        Schleswig-Holst
## 8 01055             5176. Ostholstein     01        Schleswig-Holst
## 9 01056             9280. Pinneberg      01        Schleswig-Holst
## 10 01057            2848. Plön           01        Schleswig-Holst
## # i 390 more rows
## # i 9 more variables: Schulden_pro_kopf_lk <dbl>, Einwohner <dbl>,
## #   Schulden_gesamt <dbl>, bip <dbl>, bip_pro_kopf <dbl>, erw <dbl>,
## #   alo_quote <dbl>, ost <fct>, ost_name <chr>
```

```
gesamtdaten %>%  
  group_by(ost_name) %>%  
  summarise(durchschnitt = mean(bip_pro_kopf, na.rm
```

```
## # A tibble: 2 × 2  
##   ost_name      durchschnitt  
##   <chr>          <dbl>  
## 1 Ostdeutschland 33937.  
## 2 Westdeutschland 44860.
```

```
gesamtdaten %>%  
  group_by(ost_name) %>%  
  summarise(durchschnitt = mean(bip_pro_kopf, na.rm  
ungroup() -> mittel
```

```
gesamtdaten %>%  
  group_by(ost_name) %>%  
  summarise(durchschnitt = mean(bip_pro_kopf, na.rm  
  ungroup() -> mittel  
  
ggplot(gesamtdaten, aes(x = bip_pro_kopf))
```




```

gesamtdaten %>%
  group_by(ost_name) %>%
  summarise(durchschnitt = mean(bip_pro_kopf, na.rm
  ungroup() -> mittel


ggplot(gesamtdaten, aes(x = bip_pro_kopf)) +
  geom_histogram(data = filter(gesamtdaten, bip_pro_

```



```
gesamtdaten %>%
  group_by(ost_name) %>%
  summarise(durchschnitt = mean(bip_pro_kopf, na.rm = TRUE))
ungroup() -> mittel

ggplot(gesamtdaten, aes(x = bip_pro_kopf)) +
  geom_histogram(data = filter(gesamtdaten, bip_pro_
  geom_vline(data = mittel, aes(xintercept = durchsc
```




```

gesamtdaten %>%
  group_by(ost_name) %>%
  summarise(durchschnitt = mean(bip_pro_kopf, na.rm
  ungroup() -> mittel

ggplot(gesamtdaten, aes(x = bip_pro_kopf)) +
  geom_histogram(data = filter(gesamtdaten, bip_pro_
  geom_vline(data = mittel, aes(xintercept = durchsc
  facet_grid(ost_name~.)

```






```

gesamtdaten %>%
  group_by(ost_name) %>%
  summarise(durchschnitt = mean(bip_pro_kopf, na.rm
  ungroup() -> mittel

ggplot(gesamtdaten, aes(x = bip_pro_kopf)) +
  geom_histogram(data = filter(gesamtdaten, bip_pro_
  geom_vline(data = mittel, aes(xintercept = durchsc
  facet_grid(ost_name~.) +
  theme_bw()

```




```

gesamtdaten %>%
  group_by(ost_name) %>%
  summarise(durchschnitt = mean(bip_pro_kopf, na.rm
  ungroup() -> mittel


ggplot(gesamtdaten, aes(x = bip_pro_kopf)) +
  geom_histogram(data = filter(gesamtdaten, bip_pro_
  geom_vline(data = mittel, aes(xintercept = durchsc
  facet_grid(ost_name~.) +
  theme_bw() +
  labs(title = "Verteilung des BIP pro Kopf für Ost-
    subtitle = "Beobachtungen auf Landkreisebene
    x = "BIP pro Kopf",
    y = "Anzahl an Beobachtungen")

```



# Verteilung des BIP pro Kopf in 2022

Verteilung des BIP pro Kopf für Ost- und Westdeutschland  
Beobachtungen auf Landkreisebene in 2022



# Verteilung des BIP pro Kopf in 2022

Das Histogramm bestätigen das Bild des Boxplots:

- + Deutliche Unterschiede zwischen ost- und westdeutschen Landkreisen in 2022
- + Deutlich mehr Ausreißer nach oben bei westdeutschen Landkreisen
- + Verteilung ist für ostdeutsche Landkreise enger um den Mittelwert für das BIP pro Kopf von 33936€
- + Mittelwert und Median für westdeutsche Landkreise liegt deutlich weiter auseinander und zeigt, dass es hier mehr Ausreißer in den Daten gibt

Verschuldung der einzelnen Landkreise

# Verschuldung

Warum könnte die Verschuldung des öffentlichen Haushalts ein Indikator für eine hohe Arbeitslosenquote sein?


# Verschuldung

Warum könnte die Verschuldung des öffentlichen Haushalts ein Indikator für eine hohe Arbeitslosenquote sein?

Darstellung der Verschuldung der Landkreise mittels einer Deutschlandkarte.


Beschreiben und interpretieren Sie die folgende Grafik.

```
ggplot(  
  # Datensatz  
  data = schulden_landkreise_anteil  
)
```






```
ggplot(
  # Datensatz
  data = schulden_landkreise_anteil
) +
  geom_sf(
    mapping = aes(
      fill = fct_relevel(anteil_schulden, ">10%", af
    ),
    color = "white",
    size = 0.1
  )
)
```



```

ggplot(
  # Datensatz
  data = schulden_landkreise_anteil
) +
  geom_sf(
    mapping = aes(
      fill = fct_relevel(anteil_schulden, ">10%", af
    ),
    color = "white",
    size = 0.1
  ) +
  # Viridis Farbschema
  scale_fill_viridis_d(
    option = "inferno",
    name = "Anteil der Schulden\nam BIP",
    alpha = 0.8, # Deckkraft der Füllung
    begin = 0.1,
    end = 0.9,
    direction = -1,
    guide = guide_legend(reverse = T))


```



```

ggplot(
  # Datensatz
  data = schulden_landkreise_anteil
) +
  geom_sf(
    mapping = aes(
      fill = fct_relevel(anteil_schulden, ">10%", af
    ),
    color = "white",
    size = 0.1
  ) +
  # Viridis Farbschema
  scale_fill_viridis_d(
    option = "inferno",
    name = "Anteil der Schulden\nam BIP",
    alpha = 0.8, # Deckkraft der Füllung
    begin = 0.1,
    end = 0.9,
    direction = -1,
    guide = guide_legend(reverse = T)) +
  # etwas dickere Linien für Bundeslandgrenzen
  geom_sf(
    data = bundesland,
    fill = "transparent",
    color = "black",
    size = 0.5
  )

```




```

ggplot(
  # Datensatz
  data = schulden_landkreise_anteil
) +
  geom_sf(
    mapping = aes(
      fill = fct_relevel(anteil_schulden, ">10%", af
    ),
    color = "white",
    size = 0.1
  ) +
  # Viridis Farbschema
  scale_fill_viridis_d(
    option = "inferno",
    name = "Anteil der Schulden\nam BIP",
    alpha = 0.8, # Deckkraft der Füllung
    begin = 0.1,
    end = 0.9,
    direction = -1,
    guide = guide_legend(reverse = T)) +
  # etwas dickere Linien für Bundeslandgrenzen
  geom_sf(
    data = bundesland,
    fill = "transparent",
    color = "black",
    size = 0.5
  ) +
  # Titel
  labs(x = NULL,
       y = NULL,
       title = "Wie verschuldet sind die deutschen L
       subtitle = "Öffentliche Schulden im Vergleich

```

## Wie verschuldet sind die deutschen Landkreise?

### Öffentliche Schulden im Vergleich zum BIP in 2023



```

ggplot(
  # Datensatz
  data = schulden_landkreise_anteil
) +
  geom_sf(
    mapping = aes(
      fill = fct_relevel(anteil_schulden, ">10%", af
    ),
    color = "white",
    size = 0.1
  ) +
  # Viridis Farbschema
  scale_fill_viridis_d(
    option = "inferno",
    name = "Anteil der Schulden\nam BIP",
    alpha = 0.8, # Deckkraft der Füllung
    begin = 0.1,
    end = 0.9,
    direction = -1,
    guide = guide_legend(reverse = T)) +
  # etwas dickere Linien für Bundeslandgrenzen
  geom_sf(
    data = bundesland,
    fill = "transparent",
    color = "black",
    size = 0.5
  ) +
  # Titel
  labs(x = NULL,
       y = NULL,
       title = "Wie verschuldet sind die deutschen L
       subtitle = "Öffentliche Schulden im Vergleich
  theme_void()-> plot_schulden_lk

```


```

ggplot(
  # Datensatz
  data = schulden_landkreise_anteil
) +
  geom_sf(
    mapping = aes(
      fill = fct_relevel(anteil_schulden, ">10%", af
    ),
    color = "white",
    size = 0.1
  ) +
  # Viridis Farbschema
  scale_fill_viridis_d(
    option = "inferno",
    name = "Anteil der Schulden\nam BIP",
    alpha = 0.8, # Deckkraft der Füllung
    begin = 0.1,
    end = 0.9,
    direction = -1,
    guide = guide_legend(reverse = T)) +
  # etwas dickere Linien für Bundeslandgrenzen
  geom_sf(
    data = bundesland,
    fill = "transparent",
    color = "black",
    size = 0.5
  ) +
  # Titel
  labs(x = NULL,
       y = NULL,
       title = "Wie verschuldet sind die deutschen L
       subtitle = "Öffentliche Schulden im Vergleich
  theme_void()-> plot_schulden_lk

```


## Wie verschuldet sind die deutschen Landkreise?

### Öffentliche Schulden im Vergleich zum BIP in 2023



## Wie verschuldet sind die deutschen Landkreise?

Öffentliche Schulden im Vergleich zum BIP in 2023



# Verschuldung

## Beschreibung:

- + Niedrige Verschuldung im Verhältnis zum BIP: Baden-Württemberg, Bayern, Sachsen und Niedersachsen
- + Mittlere Verschuldung: Rheinland-Pfalz, Brandenburg, Hessen, Schleswig-Holstein
- + Hohe Verschuldung: Sachsen-Anhalt, Thüringen, Nordrhein-Westfalen, Saarland, Mecklenburg-Vorpommern


## Interpretation:

- + Strukturschwache Landkreise sind vermehrt in Ostdeutschland zu finden, allerdings scheint es eher ein Nord/Süd Gefälle als ein Ost/West Gefälle zu geben
- + Die ehemalige Herzkammer der deutschen Industrie, das Ruhrgebiet, leidet unter dem Strukturwandel hin zu erneuerbaren Energien
  - + Es fallen hier wichtige Steuereinnahmen für die öffentliche Hand weg




# Vergleich der Arbeitslosenquote und Verschuldung

Wie verschuldet sind die deutschen Landkreise?  
Öffentliche Schulden im Vergleich zum BIP in 2023



Arbeitslosigkeit in Deutschland  
Dargestellt ist die Arbeitslosenquote für alle Landkreise in 2023



# Vergleich der Arbeitslosenquote und Verschuldung

- + Tendenziell sind die Landkreise mit höheren Schulden auch die mit einer höheren Arbeitslosenquote
- + Verschuldung könnte ein erklärender Faktor für die Arbeitslosenquote sein
- + Grafisch ist der Zusammenhang jedoch nicht eindeutig verifizierbar
  - + Um Zusammenhänge deutlich zu machen müssen wir uns der **bivariaten deskriptiven Statistik** bemühen, insbesondere **Streudiagrammen** und **Korrelationsmatrizen**

Karten sind eine schöne Art geografisch unterschiedliche Informationen darzustellen, allerdings ist das Auge schlecht darin Farbverläufe zu unterscheiden!

Bei Karten immer eine sehr kontrastreiche Farbpalette verwenden!

# AUFGABE - EIGENE GRAFIK ERSTELLEN

**Ziel:** Erstellen und interpretieren Sie effektive Visualisierungen der Einkommensverteilung in Deutschland.

## Ablauf:

- + Gruppenbildung (4-5 Personen)
- + Datenauswahl & Analyse: Welche Information möchten Sie visualisieren? (Zeitreihe oder Querschnitt aus 2022?)
- + Visualisierung: Was ist die geeignete Grafik für ihre Fragestellung? Lassen Sie sich von [R Graph Gallery](#) oder der [Case-Study](#) inspirieren und erstellen Sie die für Sie passende Grafik in R
  - + Nutzen Sie die [R Graph Gallery](#) und [Chat AI](#) für die Erstellung
- + Interpretation der Grafik: Diskutieren Sie die Grafik in der Gruppe
- + Upload: Code für Grafik + kurze Interpretation im Google Forms hochladen: <https://forms.gle/R4qJEegZnFoTHU7f7>
- + Feedback-Runde im Plenum: Anonymes Feedback von Kommiliton\*innen und mir.

**Materialien:** Laptops mit R, RStudio, bereitgestellter Datensatz zu Einkommensdaten

**Erkenntnisse:** Effektive Grafiktypen auswählen und interpretieren + Teamarbeit stärken.

30:00

# Hinweise zum Prompting von Chat AI

## Wie sollte ein Prompt aufgebaut sein?

- + **Aufgabe:** Was soll Chat AI tun?
  - + Möglichst genau und spezifisch sein
- + **Instruktionen:** Wie soll Chat AI es tun?
  - + Soll Chat AI eine besondere Persona sein?
  - + Beispiele für den gewünschten Output mitgeben
  - + Chat AI fragen zur Lösung Schritt-für-Schritt zu kommen
- + **Kontext:** Was sollte Chat AI zu seiner Aufgabe wissen?
  - + Wie passt die Aufgabe z.B. zur Vorlesung die Sie gerade besuchen?

## Wenn Sie nicht weiter wissen, dann Fragen Sie Chat AI welche Infos es noch benötigt

- + "Sag mir, welche Informationen du benötigst, um ..."
- + "Stelle mir 5 Fragen, die dir helfen werden, mir die bestmögliche Antwort zu geben."

## Wenn Sie glauben Chat AI hat einen Fehler gemacht, dann sagen Sie ihm dies

## Komplexe Aufgaben in kleine Unteraufgaben herunterbrechen

# Bivariate deskriptive Analyse

# Die Korrelation

**Bisher:** Univariate Analyse, d.h. nur eine Variable

**Jetzt:** Bivariate Analyse, d.h. Zusammenhang zwischen **zwei** Variablen untersuchen

Hierzu nutzen wir die Korrelation der Variablen!

Der Korrelationskoeffizient für zwei Variablen  $(x_1, y_1), \dots, (x_n, y_n)$  ist definiert als:

$$\rho = \frac{1}{n} \sum_{i=1}^n \left( \frac{x_i - \mu_x}{\sigma_x} \right) \left( \frac{y_i - \mu_y}{\sigma_y} \right)$$

mit  $\mu_x, \mu_y$  als Mittelwerte von  $x_1, \dots, x_n$  und  $y_1, \dots, y_n$ .  $\sigma_x, \sigma_y$  sind die Standardabweichungen von diesem Mittelwert.  
 $\rho$  wird üblicherweise genutzt um den Korrelationskoeffizienten zu bezeichnen.

# Die Korrelation

**Bisher:** Univariate Analyse, d.h. nur eine Variable

**Jetzt:** Bivariate Analyse, d.h. Zusammenhang zwischen **zwei** Variablen untersuchen

Hierzu nutzen wir die Korrelation der Variablen!

Der Korrelationskoeffizient für zwei Variablen  $(x_1, y_1), \dots, (x_n, y_n)$  ist definiert als:

$$\rho = \frac{1}{n} \sum_{i=1}^n \left( \frac{x_i - \mu_x}{\sigma_x} \right) \left( \frac{y_i - \mu_y}{\sigma_y} \right)$$

mit  $\mu_x, \mu_y$  als Mittelwerte von  $x_1, \dots, x_n$  und  $y_1, \dots, y_n$ .  $\sigma_x, \sigma_y$  sind die Standardabweichungen von diesem Mittelwert.  $\rho$  wird üblicherweise genutzt um den Korrelationskoeffizienten zu bezeichnen.

Wie hängt die Arbeitslosenquote in den einzelnen Landkreisen mit deren BIP-pro-Kopf-Wachstum zusammen?

# Korrelation zwischen Arbeitslosenquote und BIP-pro-Kopf-Wachstum

Wir können uns die oben beschriebene Formel bzgl. des Zusammenhangs von zwei Variablen immer auch grafisch verdeutlichen

- + Wir haben zwei Dimensionen
  - + Variable x: BIP-pro-Kopf-Wachstum
  - + Variable y: Arbeitslosenquote

Im Streudiagramm können wir Variable x auf der x-Achse und Variable y auf der y-Achse abtragen




gesamtdaten


```
## # A tibble: 400 × 17
##   Regionalschlüssel total_alo landkreis_name bundesland bundesland_name
##   <chr>                <dbl> <chr>                <chr>      <chr>
## 1 01001                4131. Flensburg      01        Schleswig-Holst
## 2 01002                10581 Kiel          01        Schleswig-Holst
## 3 01003                9216. Lübeck      01        Schleswig-Holst
## 4 01004                3604. Neumünster    01        Schleswig-Holst
## 5 01051                4126. Dithmarschen  01        Schleswig-Holst
## 6 01053                5586. Herzogtum Lauenburg 01        Schleswig-Holst
## 7 01054                4491. Nordfriesland  01        Schleswig-Holst
## 8 01055                5176. Ostholstein   01        Schleswig-Holst
## 9 01056                9280. Pinneberg     01        Schleswig-Holst
## 10 01057               2848. Plön        01        Schleswig-Holst
## # i 390 more rows
## # i 12 more variables: Schulden_pro_kopf_lk <dbl>, Einwohner <dbl>,
## #   Schulden_gesamt <dbl>, bip <dbl>, bip_pro_kopf <dbl>, erw <dbl>,
## #   alo_quote <dbl>, ost <fct>, ost_name <chr>, bip_pro_kopf_wachstum <dbl>,
## #   Jahr <dbl>, anteil_schulden <dbl>
```

```
gesamtdaten %>%
```


```
  ggplot(aes(x = bip_pro_kopf_wachstum, y = alo_quot
```




```
gesamtdaten %>%  
  ggplot(aes(x = bip_pro_kopf_wachstum, y = alo_quot  
  geom_point()
```



```
gesamtdaten %>%  
  ggplot(aes(x = bip_pro_kopf_wachstum, y = alo_quot  
  geom_point() +  
  labs( x = "Wachstum des BIP %",  
        y = "Arbeitslosenquote in %",  
        title = "Korrelation des BIP-Wachstums und d
```



```
gesamtdaten %>%  
  ggplot(aes(x = bip_pro_kopf_wachstum, y = alo_quot  
  geom_point() +  
  labs( x = "Wachstum des BIP %",  
        y = "Arbeitslosenquote in %",  
        title = "Korrelation des BIP-Wachstums und d  
  theme_minimal()
```



# Korrelation zwischen Arbeitslosenquote und BIP-Wachstum

- ✚ Es fallen die Ausreißer ins Auge (+20% und -12%)
  - ✚ Vorheriges Jahr hohes/niedriges BIP, dadurch jetzt niedriges/hohes BIP-Wachstum
  - ✚ Die Energiekrise war bei den negativen Wachstumsraten der Auslöser (Ludwigshafen mit BASF war der betroffene Landkreis)
- ✚ Insgesamt scheint der Zusammenhang jetzt nicht so stark zu sein
  - ✚ Punktwolke deutet auf einen leicht negativen Zusammenhang hin

Korrelationskoeffizient:

```
cor(gesamtdaten$a_lo_quote,  
    gesamtdaten$bip_pro_kopf_wachstum,  
    use = "pairwise.complete.obs")
```

```
## [1] 0.05449384
```

# Korrelation zwischen Arbeitslosenquote und BIP-Wachstum

- ✚ Es fallen die Ausreißer ins Auge (+20% und -12%)
  - ✚ Vorheriges Jahr hohes/niedriges BIP, dadurch jetzt niedriges/hohes BIP-Wachstum
  - ✚ Die Energiekrise war bei den negativen Wachstumsraten der Auslöser (Ludwigshafen mit BASF war der betroffene Landkreis)
- ✚ Insgesamt scheint der Zusammenhang jetzt nicht so stark zu sein
  - ✚ Punktwolke deutet auf einen leicht negativen Zusammenhang hin

Korrelationskoeffizient:

```
cor(gesamtdaten$alo_quote,  
    gesamtdaten$bip_pro_kopf_wachstum,  
    use = "pairwise.complete.obs")
```

```
## [1] 0.05449384
```

Nun sollten wir noch die Korrelation zwischen Arbeitslosenquote und Verschuldung anschauen!

```
cor_alo_verschuldung <- cor(gesamtdaten$alo_quote, g
```




```
cor_alo_verschuldung <- cor(gesamtdaten$alo_quote, g  
gesamtdaten
```

```
## # A tibble: 400 × 17  
##   Regionalschlüssel total_alo landkreis_name bundesland bundesland_name  
##   <chr>                <dbl> <chr>                <chr>      <chr>  
## 1 01001                4131. Flensburg          01      Schleswig-Holst  
## 2 01002                10581 Kiel              01      Schleswig-Holst  
## 3 01003                9216. Lübeck            01      Schleswig-Holst  
## 4 01004                3604. Neumünster        01      Schleswig-Holst  
## 5 01051                4126. Dithmarschen      01      Schleswig-Holst  
## 6 01053                5586. Herzogtum Lauenburg 01      Schleswig-Holst  
## 7 01054                4491. Nordfriesland      01      Schleswig-Holst  
## 8 01055                5176. Ostholstein       01      Schleswig-Holst  
## 9 01056                9280. Pinneberg         01      Schleswig-Holst  
## 10 01057               2848. Plön              01      Schleswig-Holst  
## # i 390 more rows  
## # i 12 more variables: Schulden_pro_kopf_lk <dbl>, Einwohner <dbl>,  
## #   Schulden_gesamt <dbl>, bip <dbl>, bip_pro_kopf <dbl>, erw <dbl>,  
## #   alo_quote <dbl>, ost <fct>, ost_name <chr>, bip_pro_kopf_wachstum <dbl>,  
## #   Jahr <dbl>, anteil_schulden <dbl>
```


```
cor_alo_verschuldung <- cor(gesamtdaten$alo_quote, g  
gesamtdaten %>%  
  ggplot(aes(x = anteil_schulden, y = alo_quote))
```




```
cor_alo_verschuldung <- cor(gesamtdaten$alo_quote, g  
gesamtdaten %>%  
  ggplot(aes(x = anteil_schulden, y = alo_quote)) +  
  geom_point()
```



```
cor_alo_verschuldung <- cor(gesamtdaten$alo_quote, g
gesamtdaten %>%
  ggplot(aes(x = anteil_schulden, y = alo_quote)) +
  geom_point() +
  labs( x = "Anteil der Schulden am BIP in %",
        y = "Arbeitslosenquote in %",
        title = "Korrelation der öffentlichen Versch
```




```
cor_alo_verschuldung <- cor(gesamtdaten$alo_quote, g
gesamtdaten %>%
  ggplot(aes(x = anteil_schulden, y = alo_quote)) +
  geom_point() +
  labs( x = "Anteil der Schulden am BIP in %",
        y = "Arbeitslosenquote in %",
        title = "Korrelation der öffentlichen Versch
  theme_minimal()
```



```
cor_alo_verschuldung <- cor(gesamtdaten$alo_quote, g

gesamtdaten %>%
  ggplot(aes(x = anteil_schulden, y = alo_quote)) +
  geom_point() +
  labs( x = "Anteil der Schulden am BIP in %",
        y = "Arbeitslosenquote in %",
        title = "Korrelation der öffentlichen Versch
  theme_minimal() +
  geom_text(x = 0.02, y = 13, label = paste("r = ", a
```



# Korrelation zwischen Arbeitslosenquote und Verschuldung

Hier ist der positive Zusammenhang zwischen Verschuldung (x-Achse) und Arbeitslosenquote (y-Achse) deutlicher

Korrelationskoeffizient zeigt mit  $\rho = 0.54$  auch einen starken Zusammenhang

| $\rho$      | Beschreibung (nährungsweise) |
|-------------|------------------------------|
| +/- 0.1-0.3 | Schwacher                    |
| +/- 0.3-0.5 | Mittel                       |
| +/- 0.5-0.8 | Stark                        |
| +/- 0.8-0.9 | Sehr stark                   |

# Korrelation zwischen Arbeitslosenquote und Verschuldung

Hier ist der positive Zusammenhang zwischen Verschuldung (x-Achse) und Arbeitslosenquote (y-Achse) deutlicher

Korrelationskoeffizient zeigt mit  $\rho = 0.54$  auch einen starken Zusammenhang

| $\rho$      | Beschreibung (nährungsweise) |
|-------------|------------------------------|
| +/- 0.1-0.3 | Schwacher                    |
| +/- 0.3-0.5 | Mittel                       |
| +/- 0.5-0.8 | Stark                        |
| +/- 0.8-0.9 | Sehr stark                   |

Wir sehen eine positive Korrelation zwischen der Verschuldung von Landkreisen und deren Arbeitslosenquoten.



# Interpretation der Korrelation

- + Hat an sich keine intuitive quantitative Interpretation
- + Ist eine univariate Repräsentation des Zusammenhangs zweier Variablen
- + Kann dabei helfen stark korrelierte Variablen im Datensatz aufzuzeigen
  - + Dies ist für eine spätere lineare Regression wichtig
  - + Stichwort Multikollinearität

Im nächsten Semester beschäftigen wir uns mit der linearen Regression, hier können die Koeffizienten direkt interpretiert werden.

# Zusammenfassung und Ausblick

**Dieses Semester:** Deskriptiven Statistik

**Nächstes Semester:** Induktive Statistik, insbesondere durch lineare Regressionen

Was haben wir bisher gelernt?

# Zusammenfassung und Ausblick

**Dieses Semester:** Deskriptiven Statistik

**Nächstes Semester:** Induktive Statistik, insbesondere durch lineare Regressionen

Was haben wir bisher gelernt?

- + Daten in R einlesen
- + Diese Daten kompakt mittels Tabellen und Grafiken beschreiben
- + Den Zusammenhang einzelner Variablen untersuchen