

The background is a dark grey canvas filled with a complex, abstract composition of various data visualization elements. On the left side, there are three vertically stacked charts: a line chart with multiple overlapping lines in shades of yellow and orange, a line chart with two distinct wave patterns, and a bar chart with vertical bars of varying heights. On the right side, there are three more charts: a line chart with a jagged, mountain-like pattern, a chart with a series of vertical spikes, and a line chart with a single smooth wave. Scattered throughout the center and around these charts are numerous geometric shapes, including circles of different sizes and colors (orange, red, yellow, and grey), some of which are divided into segments like pie charts. Thin, curved lines and dots connect these shapes, creating a sense of movement and interconnectedness. The overall aesthetic is technical and analytical, with a color palette dominated by warm, earthy tones.

Case-Study zur Arbeitslosigkeit in Deutschland

Organisatorische Hinweise

- + Viele Deadlines
- + Ungewohntes Format (sehr technisch)
- + Github, RStudio, R
- + Arbeitsschritte mit Github (3. Problem Set von Github herunterladen und lösen)

Dies ist alles neu und das ist uns bewusst!

Warum das Ganze?

- + Durch die Deadlines sollten Sie sich mit dem Stoff auseinandersetzen
- + Github, R, RStudio und RMarkdown müssen Sie in den Projekten nutzen → Üben mit RTutor
- + Visualisierung, Interpretation und Präsentation in den Projekten gefragt → Üben mit der Case-Study
- + Arbeiten mit AI → Lernen wie AI ihre Arbeit sinnvoll ergänzen kann und wo nicht

Recap letzte Vorlesungseinheit

- + Verschiedene Arten einen Datensatz einzulesen
 - + `readr`, `readxl`, `haven`...
- + Variablenbezeichnungen stehen nicht zwangsläufig in erster Spalte
- + Es gibt oft und viele `NA`s in echten Daten
 - + Konsistenzchecks wichtig
- + Datensätze sind nicht immer in der Form das wir diese direkt Einlesen können
 - + Aus verschiedenen Quellen einlesen, z.B. über eine `for`-Schleife oder `lapply`
 - + Umformen, da die Daten im `wide`-Format vorliegen -> `pivot_longer`
- + Es ist wichtig sich selbst ein Bild von den Daten zu machen

Analyse der Daten

Deskriptive vs. induktive Statistik

- + Deskriptive Statistik (beschreibende Statistik) ist beschreibend (wer hätte es gedacht)
- + Induktive (auch schließende) Statistik versucht aus der Stichprobe auf die Grundgesamtheit zu schließen
- + Keine Unterscheidung in der Formel
- + Keine Unterscheidung in dem Datensatz der verwendet wird

Worin genau besteht der Unterschied zwischen der deskriptiven und der induktiven Statistik?

Deskriptive Statistik

- + Beschreibung des Datensatzes
 - + **Beispiel:** Daten von der Agentur für Arbeit über die Arbeitslosenquote in den Landkreisen
- + Mehrere Arten denkbar
 - + Tabellenform
 - + Visualisierung mittels Schaubildern

Sie wollen etwas über ihren aktuellen Datensatz lernen.

Induktive Statistik

- + Interesse gilt nicht dem Datensatz selbst, sondern der Population
 - + Sie haben keine Vollerhebung durchgeführt, sondern nur eine (zufällige) Stichprobe der Population gezogen
- + **Beispiel:** Mikrozensus, d.h. eine Befragung von zufällig ausgewählten Haushalten in Deutschland
- + Sie wollen aus der Stichprobe schätzen, wie sich die beobachtete Größe in der Population verhält
- + Es gibt viele Arten der induktiven Statistik. Die zwei häufigsten:
 - + Vorhersage
 - + Erkennen kausaler Zusammenhänge

In die induktive Statistik tauchen wir nächstes Semester tiefer ein.

Deskriptive Statistik


Univariate deskriptive Statistik

- + Eine Variable wird dargestellt:
 - + Verteilung
 - + Mittelwert
 - + Standardabweichung
 - + Median
 - + Quantile
- + Überblick verschaffen, Eigenschaften der Variablen aufzeigen

Univariate deskriptive Statistik

- + Darstellung über eine Tabelle
 - + Median, Mittelwert, Standardabweichung und Quantile
- + Darstellung über einen Boxplot
 - + Median, Inter-Quartile-Range (ICR), Ausreißer
- + Darstellung über ein Histogramm
 - + Verteilung mit Anzahl an Beobachtungen
- + Darstellung über einen Kerndichteschätzer
 - + Verteilung mit Dichte

Univariate descriptive Statistik (Boxplot)



Bivariate deskriptive Statistik

Darstellung von Zusammenhängen zweier Variablen

- + Korrelation zweier Variablen
- + Wenn sich eine Variable verändert, wie verändert sich die andere Variable?

Darstellung als:

- + Streudiagramm
- + Korrelationskoeffizient (meist innerhalb einer Korrelationsmatrix)

Wie sieht die deskriptive Statistik in
der Praxis aus?

Zweiter Teil der Case Study

Eingelesene Daten deskriptiv untersuchen

- + Erster Schritt: Deskriptive Tabellen mit `kableExtra` und `gt`
- + Zweiter Schritt: Grafiken mit `ggplot2`

Ziele des zweiten Teils der Case Study:

- + Daten visualisieren und Zusammenhänge grafisch veranschaulichen
- + Deskriptive Analysen mittels Korrelationstabellen und deskriptiven Tabellen anfertigen
- + Das Verständnis, wie Sie ihre Informationen zu bestimmten Fragestellungen möglichst effektiv aufbereiten
- + Interaktive Grafiken erstellen

Im dritten RTutor Problem Set werden Sie Visualisierung zu einzelnen Ländern auf europäischer Ebene erstellen.

Daten und Pakete laden

Wir laden die aus Teil 1 erstellten Datensätze:

```
library(tidyverse)
library(skimr)
library(sf)
library(viridis)
library(plotly)
library(kableExtra)
library(gt)
library(corrrr)
```

```
# Daten einlesen
einkommen <- readRDS("../case-study/data/einkommen.rds")
bundesland <- readRDS("../case-study/data/bundesland.rds")
landkreise <- readRDS("../case-study/data/landkreise.rds")
bip_zeitreihe <- readRDS("../case-study/data/bip_zeitreihe.rds")
gemeinden <- readRDS("../case-study/data/gemeinden.rds")
gesamtdaten <- readRDS("../case-study/data/gesamtdaten.rds")
schulden_bereinigt <- readRDS("../case-study/data/schulden_bereinigt.rds")
```

Deskriptive Analysen

Arbeitslosenquote berechnen

Zuerst: Überblick über die Daten gewinnen

- + Wie viele Landkreise haben wir in den Daten?
- + Wie ist die Verteilung der Schulden, Arbeitsquote und des BIP?

Hierzu müssen wir erst noch die Arbeitslosenquote berechnen:

$$\text{Arbeitslosenquote} = \text{Erwerbslose} / (\text{Erwerbstätige} + \text{Erwerbslose})$$

```
# Zuerst wollen wir uns noch die Arbeitslosenquote pro Landkreis berechnen
gesamtdaten <- gesamtdaten %>%
  mutate(alo_quote = (total_alo / (erw+total_alo))*100)
```

Anzahl an Beobachtungen

Quick and dirty (einfacher Tibble Datensatz): Einen Blick auf die Anzahl an Erwerbstätigen und Einwohnern in Deutschland werfen.

```
# Wie viele Erwerbstätige und Einwohner (ohne Berlin, Hamburg, Bremen und Bremerhaven) hat Deutschland?  
gesamtdaten %>%  
  summarise(total_erw = sum(erw, na.rm=TRUE), total_einwohner = sum(Einwohner, na.rm=TRUE))
```

```
## # A tibble: 1 × 2  
##   total_erw total_einwohner  
##   <dbl>         <dbl>  
## 1  42115549      78122610
```

- ✚ 42,1 Mio. Erwerbstätige und 78,1 Mio. Einwohner in Deutschland
- ✚ Folgende Stadtstaaten sind nicht in unseren Berechnungen enthalten:
 - ✚ Hamburg (1,8 Mio.)
 - ✚ Berlin (3,8 Mio.)
 - ✚ Bremen (0,6 Mio.)
 - ✚ Bremerhaven (0,1 Mio.)

Anzahl an Beobachtungen

Etwas besser mit `skimr` Daten veranschaulichen

```
# Anschließend wollen wir eine Summary Statistic für alle Variablen ausgeben lassen
# Entfernen der Histogramme, damit alles auch schön in PDF gedruckt werden kann
gesamtdaten %>%
  select(aio_quote, Schulden_pro_kopf_lk, bip_pro_kopf, landkreis_name) %>%
  skim_without_charts() %>%
  summary()
```

Anzahl an Beobachtungen

Table: Data summary

Name	Piped data
Number of rows	400
Number of columns	4
—	
Column type frequency:	
character	1
numeric	3
—	
Group variables	None

Anzahl an Beobachtungen

- + 400 individuelle Beobachtungen in unserem Datensatz.

Hierbei handelt es sich um alle Landkreise und kreisfreien Städte in Deutschland.

Stimmen diese Angaben?

- + In Deutschland gibt es 294 Landkreise)
- + Weiterhin gibt es in Deutschland 106 kreisfreie Städte

(Quelle: Wikipedia)

Anzahl an Beobachtungen

Variable type: character

skim_variable	n_missing	complete_rate	min	max	empty	n_unique	whitespace
landkreis_name	0	1	3	32	0	378	0

- + Nur 378 unterschiedliche Landkreis Namen in unserem Datensatz mit 400 unterschiedlichen Beobachtungen (Regionalschlüsseln).

Woher kommt dies?

- + Stadt München ist eine Beobachtung
- + Landkreis München eine weitere Beobachtung

Beide haben unterschiedliche Regionalschlüssel. D.h. der "landkreis_name" ist der gleiche, jedoch ist der Regionalschlüssel ein anderer.

Anzahl an Beobachtungen

Nun möchten wir uns noch die einzelnen Variablen aus dem Datensatz näher anschauen:

Variable type: numeric

skim_variable	n_missing	complete_rate	mean	sd	p0	p25	p50	p75	p100
alo_quote	2	1.00	5.29	2.08	1.64	3.63	5.07	6.62	14.2
Schulden_pro_kopf_lk	4	0.99	3051.94	2303.19	202.36	1564.83	2367.83	3778.56	17680.7
bip_pro_kopf	2	1.00	42801.26	17280.40	17953.34	32377.34	38778.96	46569.47	149442.9
Einwohner	4	0.99	197279.32	153820.49	34607.00	104722.25	157359.00	241283.75	1502969.0

Anzahl an Beobachtungen

- + Fehlende Beobachtungen für Schulden pro Kopf: *vier* Landkreise
- + Fehlende Beobachtung für Einwohner: *vier* Landkreise
- + Fehlende Beobachtungen für BIP pro Kopf: *zwei* Landkreise
- + Fehlende Beobachtungen für die Arbeitslosenquote: *zwei* Landkreise

```
gesamtdaten %>%  
  filter(is.na(Einwohner)) %>%  
  select(landkreis_name)
```

```
## # A tibble: 4 × 1  
##   landkreis_name  
##   <chr>  
## 1 Hamburg  
## 2 Bremen  
## 3 Bremerhaven  
## 4 Berlin
```

Wir können diese Landkreise nicht mit in unsere Analyse mit einbeziehen auf Grund der fehlenden Informationen zu Einwohnern!

Beschreibung der Tabelle

Variable type: numeric

skim_variable	n_missing	complete_rate	mean	sd	p0	p25	p50	p75	p100
alo_quote	2	1.00	5.29	2.08	1.64	3.63	5.07	6.62	14.23
Schulden_pro_kopf_lk	4	0.99	3051.94	2303.19	202.36	1564.83	2367.83	3778.56	17680.79
bip_pro_kopf	2	1.00	42801.26	17280.40	17953.34	32377.34	38778.96	46569.47	149442.98

Bitte diskutieren Sie mit ihrem/ihrer Sitznachbar*in und beschreiben Sie die Tabelle in ihren eigenen Worten!

Gehen Sie hierbei bitte auf **eine Variable** (alo_quote, Schulden_pro_Kopf_lk, bip_pro_kopf) und die folgenden Punkte ein:

- + Mittelwert
- + Standardabweichung
- + Median

05:00

Arbeitslosenquote

Mittelwert: 5,29 Prozent

- + Hoch
- + Jedoch SGB II und SGB III
- + Konsistenzcheck auf [Statista](#) zeigt eine Arbeitslosenquote von 5,7% für 2023
- + **Jedoch:** Wir haben nicht Berlin und Hamburg in den Daten

Standardabweichung: 2,08

- + Sehr hohe Streuung
- + Deutliche regionale Unterschiede
- + Ist in Prozentpunkten

Median: 5,07 Prozent

- + Nahe am Mittelwert
- + Deutet darauf hin das es wenige Landkreise mit sehr extremen Ausreißern gibt

Verschuldung pro Kopf

Mittelwert: 3052€

- + Relativ hoch

Standardabweichung: 2303€

- + Sehr hohe Streuung

- + Deutliche regionale Unterschiede

Median: 2368€

- + Weiter weg vom Mittelwert

- + Deutet darauf hin das es einzelne Landkreise mit sehr extremen Ausreißern gibt

BIP pro Kopf

Mittelwert: 42801€

- + Insgesamt recht hoch
- + Starker Wirtschaftsstandort Deutschland

Standardabweichung: 17280€

- + Sehr hohe Streuung
- + Deutliche regionale Unterschiede
- + Könnte von einzelnen Landkreisen getrieben werden

Median: 38779€

- + Weiter weg vom Mittelwert
- + Deutet darauf hin das es einzelne Landkreise mit sehr extremen Ausreißern gibt

Die Arbeitslosenquote auf Bundeslandebene

Die Arbeitslosenquote auf Bundeslandebene

Es gibt deutliche Unterschiede in der Arbeitslosenquote über die Bundesländer hinweg!

Wir betrachten:

- + Querschnittsdaten aus 2023
- + Alle Landkreise
- + Für einige Landkreise haben wir keine Informationen (sogenannte "Missing values" -> `n_missing`)

Wir möchten nun die regionale Verteilung der Arbeitslosenquote in Deutschland im Jahr 2023 näher betrachten.

Die Arbeitslosenquote auf Bundeslandebene

Zuerst aggregieren wir die Daten auf Bundeslandebene:

```
bula_data <- gesamtdaten %>%  
  group_by( bundesland_name ) %>%  
  summarise(mean_alo = mean(alo_quote), sd_alo = sd(alo_quote), median_alo = median(alo_quote), .groups = 'dr
```

Die Arbeitslosenquote auf Bundeslandebene

count: false

```
gesamtdaten
```

```
## # A tibble: 400 × 12
##   Regionalschlüssel total_alo landkreis_name bundesland bundesland_name
##   <chr>                <dbl> <chr>          <chr>      <chr>
## 1 01001                4131. Flensburg      01        Schleswig-Holst
## 2 01002               10581 Kiel            01        Schleswig-Holst
## 3 01003                9216. Lübeck       01        Schleswig-Holst
## 4 01004                3604. Neumünster    01        Schleswig-Holst
## 5 01051                4126. Dithmarschen    01        Schleswig-Holst
## 6 01053                5586. Herzogtum Lauenburg 01        Schleswig-Holst
## 7 01054                4491. Nordfriesland    01        Schleswig-Holst
## 8 01055                5176. Ostholstein     01        Schleswig-Holst
## 9 01056                9280. Pinneberg      01        Schleswig-Holst
## 10 01057               2848. Plön        01        Schleswig-Holst
## # i 390 more rows
## # i 7 more variables: Schulden_pro_kopf_lk <dbl>, Einwohner <dbl>,
## #   Schulden_gesamt <dbl>, bip <dbl>, bip_pro_kopf <dbl>, erw <dbl>,
## #   alo_quote <dbl>
```



```
gesamtdaten %>%  
  group_by( bundesland_name ) %>%  
  summarise(mean_alo = mean(alo_quote),  
            sd_alo = sd(alo_quote),  
            median_alo = median(alo_quote), .groups
```

Die Arbeitslosenquote auf Bundeslandebene

Anschließend wollen wir uns eine ansprechende und informative deskriptive Tabelle erstellen:

```
## # A tibble: 14 × 4
##   bundesland_name    mean_alo sd_alo median_alo
##   <chr>            <dbl>   <dbl>   <dbl>
## 1 Bayern           3.26    0.715
## 2 Baden-Württemberg 3.73    0.722
## 3 Hessen           5.25    1.27
## 4 Rheinland-Pfalz   5.41    1.46
## 5 Schleswig-Holstein 5.76    0.832
## 6 Saarland          6.01    1.74
## 7 Niedersachsen     6.05    1.73
## 8 Sachsen           6.09    0.854
## 9 Thüringen         6.26    1.58
## 10 Brandenburg       6.75    1.51
## 11 Nordrhein-Westfalen 7.03    2.35
## 12 Mecklenburg-Vorpommern 7.64    1.22
## 13 Sachsen-Anhalt    7.84    1.43
## 14 Bremen            9.59    2.97
```

Bundesland	Arbeitslosenquote		
	Mittelwert	Std.	Median
Bayern	3.26	0.72	3.14
Baden-Württemberg	3.73	0.72	3.66
Hessen	5.25	1.27	5.37
Rheinland-Pfalz	5.41	1.46	5.36
Schleswig-Holstein	5.76	0.83	5.87
Saarland	6.01	1.74	5.61
Niedersachsen	6.05	1.73	6.22
Sachsen	6.09	0.85	5.98
Thüringen	6.26	1.58	5.70
Brandenburg	6.75	1.51	7.11
Nordrhein-Westfalen	7.03	2.35	6.62
Mecklenburg-Vorpommern	7.64	1.22	7.81
Sachsen-Anhalt	7.84	1.43	7.75
Bremen	9.59	2.97	9.59

Bitte beachten:

Wir haben keine Informationen zu Berlin und Hamburg, weshalb sie nicht in der Tabelle aufgeführt wurden.

¹ Die ostdeutschen Bundesländer sind grau hinterlegt.

Die Arbeitslosenquote auf Bundeslandebene

Die Darstellung mit dem Paket `kableExtra` ist deutlich ansprechender als nur einen Tibble zu zeigen!

Folgender Code wurde hier verwendet, welchen wir in der nächsten Folie Schritt für Schritt durchgehen werden:

```
bula_data %>%
  arrange( mean_alo ) %>%
  filter( !is.na(mean_alo) ) %>%
  kbl(col.names = c("Bundesland",
                   "Mittelwert",
                   "Std.",
                   "Median"), digits = 2) %>%
  kable_styling(bootstrap_options = c("striped", "hover", "condensed", "responsive")) %>%
  kable_paper(full_width = F) %>%
  row_spec(c(8,9, 10, 12,13), bold = T, color = "white", background = "#BBBBBB") %>%
  add_header_above(c(" " = 1, "Arbeitslosenquote" = 3), align = "c") %>%
  footnote(general = "Wir haben keine Informationen zu Berlin und Hamburg, weshalb sie nicht in der Tabelle a",
           general_title = "Bitte beachten: ",
           number = "Die ostdeutschen Bundesländer sind grau hinterlegt.")
```

```
bula_data %>%
  arrange( mean_alo ) %>%
  filter( !is.na(mean_alo) ) %>%
  kbl(col.names = c("Bundesland",
                    "Mittelwert",
                    "Std.",
                    "Median"), digits = 2) %>%
  kable_styling(bootstrap_options = c("striped", "ho
  kable_paper(full_width = F) %>%
  row_spec(c(8,9, 10, 12,13), bold = T, color = "whi
  add_header_above(c(" " = 1, "Arbeitslosenquote" =
  footnote(general = "Wir haben keine Informationen
    general_title = "Bitte beachten: ",
    number = "Die ostdeutschen Bundesländer s
```

Bundesland	Arbeitslosenquote		
	Mittelwert	Std.	Median
Bayern	3.26	0.72	3.14
Baden-Württemberg	3.73	0.72	3.66
Hessen	5.25	1.27	5.37
Rheinland-Pfalz	5.41	1.46	5.36
Schleswig-Holstein	5.76	0.83	5.87
Saarland	6.01	1.74	5.61
Niedersachsen	6.05	1.73	6.22
Sachsen	6.09	0.85	5.98
Thüringen	6.26	1.58	5.70
Brandenburg	6.75	1.51	7.11
Nordrhein-Westfalen	7.03	2.35	6.62
Mecklenburg-Vorpommern	7.64	1.22	7.81
Sachsen-Anhalt	7.84	1.43	7.75
Bremen	9.59	2.97	9.59

Bitte beachten:

Wir haben keine Informationen zu Berlin und Hamburg, weshalb sie nicht in der Tabelle aufgeführt wurden.

¹ Die ostdeutschen Bundesländer sind grau hinterlegt.

Was ist hier eine Beobachtung?

Bundesland	Arbeitslosenquote		
	Mittelwert	Std.	Median
Bayern	3.26	0.72	3.14
Baden-Württemberg	3.73	0.72	3.66
Hessen	5.25	1.27	5.37
Rheinland-Pfalz	5.41	1.46	5.36
Schleswig-Holstein	5.76	0.83	5.87
Saarland	6.01	1.74	5.61
Niedersachsen	6.05	1.73	6.22
Sachsen	6.09	0.85	5.98
Thüringen	6.26	1.58	5.70
Brandenburg	6.75	1.51	7.11
Nordrhein-Westfalen	7.03	2.35	6.62
Mecklenburg-Vorpommern	7.64	1.22	7.81
Sachsen-Anhalt	7.84	1.43	7.75
Bremen	9.59	2.97	9.59

Bitte beachten:

Wir haben keine Informationen zu Berlin und Hamburg, weshalb sie nicht in der Tabelle aufgeführt wurden.

¹ Die ostdeutschen Bundesländer sind grau hinterlegt.

Die Arbeitslosenquote auf Bundeslandebene

Was lernen wir aus der deskriptiven Tabelle?

- + Landkreise im Süden Deutschlands haben durchschnittlich eine eher niedrige Arbeitslosenquote ($<4\%$)
- + Landkreise in den ostdeutschen Bundesländern haben tendenziell höhere Arbeitslosenquoten ($>5.5\%$)
- + Bundesländer wie Bayern oder Baden-Württemberg haben relativ niedrige Arbeitslosenquoten und relativ geringe regionale Unterschiede (niedrige Standardabweichungen).
- + Bundesländer wie Nordrhein-Westfalen haben zwar eine relativ niedrige Arbeitslosenquote, aber sehr unterschiedliche regionale Verteilungen (hohe Standardabweichungen), was auf starke regionale Unterschiede hinweist.
- + Median liegt recht nahe am Mittelwert für die Bundesländern

Sehr große Unterschiede in den durchschnittlichen Arbeitslosenquoten zwischen Landkreisen in Ost- und Westdeutschland!

```
gesamtdaten %>%
```

```
  mutate( ost = as.factor(ifelse(bundesland_name %in%  
    ost_name = ifelse(ost == 1, "Ostdeutschland", "Westdeutschland")
```

```
## # A tibble: 400 × 14
```

```
##   Regionalschlüssel total_alo landkreis_name bundesland bundesland_name  
##   <chr>                <dbl> <chr>          <chr>      <chr>  
## 1 01001                4131. Flensburg      01      Schleswig-Holst  
## 2 01002                10581 Kiel          01      Schleswig-Holst  
## 3 01003                9216. Lübeck      01      Schleswig-Holst  
## 4 01004                3604. Neumünster    01      Schleswig-Holst  
## 5 01051                4126. Dithmarschen    01      Schleswig-Holst  
## 6 01053                5586. Herzogtum Lauenburg 01      Schleswig-Holst  
## 7 01054                4491. Nordfriesland    01      Schleswig-Holst  
## 8 01055                5176. Ostholstein      01      Schleswig-Holst  
## 9 01056                9280. Pinneberg      01      Schleswig-Holst  
## 10 01057               2848. Plön          01      Schleswig-Holst  
## # i 390 more rows  
## # i 9 more variables: Schulden_pro_kopf_lk <dbl>, Einwohner <dbl>,  
## #   Schulden_gesamt <dbl>, bip <dbl>, bip_pro_kopf <dbl>, erw <dbl>,  
## #   alo_quote <dbl>, ost <fct>, ost_name <chr>
```

Die Arbeitslosenquote zwischen Ost- und Westdeutschland

```
gesamtdaten %>%
  group_by(ost_name) %>%
  summarise(mean_alo = mean(alo_quote, na.rm = T), sd_alo = sd(alo_quote, na.rm = T), min_alo = min(alo_quote), max_alo = max(alo_quote))
ungroup() %>%
  kbl(col.names = c("Bundesland",
                    "Mittelwert",
                    "Std.",
                    "Minimum",
                    "P25",
                    "Median",
                    "P75",
                    "Maximum"), digits = 2) %>%
  kable_styling(bootstrap_options = c("striped", "hover", "condensed", "responsive")) %>%
  kable_paper(full_width = F) %>%
  add_header_above(c(" " = 1, "Arbeitslosenquote" = 7), align = "c") %>%
  footnote(general = "Wir haben keine Informationen zu Berlin und Hamburg, weshalb sie nicht in der Berechnung enthalten sind.",
           general_title = "Bitte beachten: ")
```



```

gesamtdaten %>%
  group_by(ost_name) %>%
  summarise(mean_alo = mean(alo_quote, na.rm = T), s
  ungroup() %>%
  kbl(col.names = c("Bundesland",
                    "Mittelwert",
                    "Std.",
                    "Minimum",
                    "P25",
                    "Median",
                    "P75",
                    "Maximum"), digits = 2) %>%
  kable_styling(bootstrap_options = c("striped", "ho
  kable_paper(full_width = F) %>%
  add_header_above(c(" " = 1, "Arbeitslosenquote" =
  footnote(general = "Wir haben keine Informationen
            general_title = "Bitte beachten: ")

```

Arbeitslosenquote

Bundesland	Mittelwert	Std.	Minimum	P25	Median	P75	Maximum
Ostdeutschland	6.79	1.52	4.09	5.69	6.74	7.70	11.11
Westdeutschland	4.94	2.03	1.64	3.38	4.37	6.17	14.23

Bitte beachten:

Wir haben keine Informationen zu Berlin und Hamburg, weshalb sie nicht in der Berechnung enthalten sind.

Beschreiben Sie die Tabelle!

Die Arbeitslosenquote zwischen Ost- und Westdeutschland

Große Unterschiede werden sichtbar:

- + Mittelwert über 1,8 Prozentpunkte niedriger in den Landkreisen der westdeutschen Bundesländer
- + Die Standardabweichung ist in Westdeutschland deutlich höher als in Ostdeutschland
- + Der Median der ostdeutschen Landkreise liegt nahe dem Mittelwert dieser Landkreise. Der Median in den westdeutschen Landkreisen liegt jedoch deutlich unter deren Mittelwert
- + Im **25% Quantil** in den **ostdeutschen Landkreisen** ist die Arbeitslosenquote bei **5,69%**
- + Bei den **westdeutschen Landkreisen** ist das **75% Quantil** bei einer Arbeitslosenquote von **6,17%**!

ARBEITSLOSENQUOTE, BIP PRO KOPF UND SCHULDEN PRO KOPF

```
gesamtdaten %>%
  group_by( bundesland_name ) %>%
  summarise(mean_alo = mean(alo_quote), sd_alo = sd(alo_quote),
            mean_bip_kopf = mean(bip_pro_kopf), sd_bip_kopf = sd(bip_pro_kopf),
            mean_schulden_kopf = mean(Schulden_gesamt/Einwohner), sd_schulden = sd(Schulden_gesamt/Einwohner))
ungroup() -> bula_data_all

bula_data_all %>%
  arrange( mean_alo ) %>%
  filter( !is.na(mean_schulden_kopf) ) %>%
  kbl(col.names = c("Bundesland", "Mittelwert", "Std.", "Mittelwert", "Std.", "Mittelwert", "Std."), digits = 2,
      caption = "Deskriptive Tabelle komplett") %>%
  kable_styling(bootstrap_options = c("striped", "hover", "condensed", "responsive")) %>%
  kable_paper(full_width = F) %>%
  row_spec(c(8,9, 10, 12,13), bold = T, color = "white", background = "#BBBBBB") %>%
  add_header_above(c(" " = 1, "Arbeitslosenquote" = 2, "BIP pro Kopf" = 2, "Schulden pro Kopf" = 2), align = "left")
  footnote(general = "Wir haben keine Informationen zu Berlin, Hamburg und Bremen bzgl. ihrer Schulden pro Kopf",
           general_title = "Bitte beachten: ",
           number = "Die ostdeutschen Bundesländer sind grau hinterlegt.")
```

```
gesamtdaten %>%
  group_by( bundesland_name ) %>%
  summarise(mean_alo = mean(alo_quote), sd_alo = sd(alo_quote))
ungroup() -> bula_data_all

bula_data_all %>%
  arrange( mean_alo ) %>%
  filter( !is.na(mean_schulden_kopf) ) %>%
  kbl(col.names = c("Bundesland", "Mittelwert", "Std.", "Arbeitslosenquote", "BIP pro Kopf", "Schulden pro Kopf"),
      caption = "Deskriptive Tabelle komplett") %>%
  kable_styling(bootstrap_options = c("striped", "hover"),
                font_size = 9) %>%
  kable_paper(full_width = F) %>%
  row_spec(c(8,9, 10, 12,13), bold = T, color = "white")
add_header_above(c(" " = 1, "Arbeitslosenquote" = 1, "BIP pro Kopf" = 1, "Schulden pro Kopf" = 1))
footnote(general = "Wir haben keine Informationen zu Berlin, Hamburg und Bremen bzgl. ihrer Schulden pro Kopf, weshalb sie nicht in der Tabelle aufgeführt wurden.",
         general_title = "Bitte beachten: ",
         number = "Die ostdeutschen Bundesländer sind grau hinterlegt.")
```

Deskriptive Tabelle komplett

Bundesland	Arbeitslosenquote		BIP pro Kopf		Schulden pro Kopf	
	Mittelwert	Std.	Mittelwert	Std.	Mittelwert	Std.
Bayern	3.26	0.72	49281.51	21402.37	2242.23	1658.98
Baden-Württemberg	3.73	0.72	49824.77	15016.77	3181.10	2482.35
Hessen	5.25	1.27	45974.34	18556.10	4002.22	3566.69
Rheinland-Pfalz	5.41	1.46	40223.17	18368.50	3134.87	3519.37
Schleswig-Holstein	5.76	0.83	39299.56	9913.17	3282.60	1319.29
Saarland	6.01	1.74	36453.36	8554.62	5232.31	1217.73
Niedersachsen	6.05	1.73	40509.82	20508.37	2533.96	1808.01
Sachsen	6.09	0.85	34595.31	5878.85	2447.50	1000.71
Thüringen	6.26	1.58	32239.94	6650.04	2766.11	622.36
Brandenburg	6.75	1.51	35440.47	7562.58	2416.97	1183.76
Nordrhein-Westfalen	7.03	2.35	41434.87	12333.98	4387.14	2378.29
Mecklenburg-Vorpommern	7.64	1.22	34663.84	7287.85	3998.78	2075.06
Sachsen-Anhalt	7.84	1.43	33643.87	5191.52	2934.74	1495.63

Bitte beachten:
Wir haben keine Informationen zu Berlin, Hamburg und Bremen bzgl. ihrer Schulden pro Kopf, weshalb sie nicht in der Tabelle aufgeführt wurden.
¹ Die ostdeutschen Bundesländer sind grau hinterlegt.

ARBEITSLOSENQUOTE, BIP PRO KOPF UND SCHULDEN PRO KOPF

Deskriptive Tabelle komplett						
Bundesland	Arbeitslosenquote		BIP pro Kopf		Schulden pro Kopf	
	Mittelwert	Std.	Mittelwert	Std.	Mittelwert	Std.
Bayern	3.26	0.72	49281.51	21402.37	2242.23	1658.98
Baden-Württemberg	3.73	0.72	49824.77	15016.77	3181.10	2482.35
Hessen	5.25	1.27	45974.34	18556.10	4002.22	3566.69
Rheinland-Pfalz	5.41	1.46	40223.17	18368.50	3134.87	3519.37
Schleswig-Holstein	5.76	0.83	39299.56	9913.17	3282.60	1319.29
Saarland	6.01	1.74	36453.36	8554.62	5232.31	1217.73
Niedersachsen	6.05	1.73	40509.82	20508.37	2533.96	1808.01
Sachsen	6.09	0.85	34595.31	5878.85	2447.50	1000.71
Thüringen	6.26	1.58	32239.94	6650.04	2766.11	622.36
Brandenburg	6.75	1.51	35440.47	7562.58	2416.97	1183.76
Nordrhein-Westfalen	7.03	2.35	41434.87	12333.98	4387.14	2378.29
Mecklenburg-Vorpommern	7.64	1.22	34663.84	7287.85	3998.78	2075.06
Sachsen-Anhalt	7.84	1.43	33643.87	5191.52	2934.74	1495.63

Bitte beachten:

Wir haben keine Informationen zu Berlin, Hamburg und Bremen bzgl. ihrer Schulden pro Kopf, weshalb sie nicht in der Tabelle aufgeführt wurden.

¹ Die ostdeutschen Bundesländer sind grau hinterlegt.

Was lernen wir aus dieser Tabelle?

ARBEITSLOSENQUOTE, BIP PRO KOPF UND SCHULDEN PRO KOPF

- + Landkreise in Bundesländer mit niedrigen Arbeitslosenquoten haben durchschnittlich ein hohes BIP pro Kopf
- + Ostdeutsche Landkreise haben im Durchschnitt ein BIP pro Kopf $< 36000\text{€}$
- + Westdeutsche Landkreise haben im Durchschnitt ein BIP pro Kopf $> 36000\text{€}$
- + Kein klares Bild der Landkreise hinsichtlich der Schulden pro Kopf

Allein durch Mittelwert und Standardabweichung können wir bereits sehr viel über regionale Unterschiede lernen.

Entwicklung des BIP

Auch zeitliche Entwicklungen können in einer Tabelle dargestellt werden

Als Beispiel sollten Sie sich die Tabelle zur Entwicklung des BIP pro Kopf in der Case-Study anschauen

Hier gelangen Sie direkt zur [entsprechenden Sektion in der ausformulierten Case-Study](#).

Datenvisualisierung

Arbeitslosenquote

Das Auge verarbeitet Informationen deutlich schneller und intuitiver wenn diese in einer Grafik präsentiert werden, anstatt in Tabellenform.

Daher ist es wichtig Grafiken in den deskriptiven Analysen mit einzubeziehen

Daten: Querschnittsdaten zur Arbeitslosigkeit in den Landkreisen aus dem Jahr 2023


Die folgende Grafik sollte enthalten:

- + **Zeige alle Daten:** Jeder Landkreis wird durch einen Punkt in der Grafik repräsentiert
- + Boxplot der Arbeitslosigkeit wird über die Punktwolke gelegt

```
gesamtdaten %>%
  select(alo_quote, landkreis_name, bundesland_name,
  mutate(baden_wuerttemberg = as.factor(ifelse(bunde
ggplot(aes(x = ost_name, y=alo_quote)) +
  geom_jitter(aes(color = ifelse(baden_wuerttemberg
scale_color_identity() +
  geom_boxplot(alpha = 0.1) +
  theme_minimal() +
  labs(title = "Arbeitslosenquote in Deutschland",
        subtitle = "Eine Beobachtung repräsentiert ei
        x = "",
        y = "Arbeitslosenquote",
        caption = "Quelle: Daten der Agentur für Arbe
```

Arbeitslosenquote in Deutschland

Eine Beobachtung repräsentiert einen Landkreis, Baden-Württemberg rot eingefärbt




Quelle: Daten der Agentur für Arbeit aus dem Jahr 2023

Arbeitslosenquote

Beschreiben Sie das gezeigte Schaubild

Arbeitslosenquote in Deutschland

Eine Beobachtung repräsentiert einen Landkreis, Baden-Württemberg rot eingefärbt



Quelle: Daten der Agentur für Arbeit aus dem Jahr 2023

Arbeitslosenquote

Beschreibung des Schaubilds:

- + Rote Datenpunkte Baden-Württemberg, fast alle unter dem Median in Westdeutschland
- + Median in Westdeutschland deutlich geringer als in Ostdeutschland
- + 75% Quantil in Westdeutschland deutlich unter dem Median in Ostdeutschland
- + Die meisten Landkreise unter 15% Arbeitslosenquote; Verglichen mit den europäischen Daten sehr gut

Bruttoinlandsprodukt pro Kopf

Es gibt deutliche regionale Unterschiede zwischen den Landkreisen. Doch ist dies auch beim BIP pro Kopf der Fall? Und war das schon immer so?

Wir betrachten das BIP pro Kopf über die Zeit für ost- und westdeutsche Landkreise!

Hier können wir sehen:

- + ob es auch regionale Unterschiede im BIP pro Kopf gibt
- + ob die regionalen Unterschiede schon längere Zeit bestehen
- + ob die regionalen Unterschiede sich vergrößern oder verkleinern


Bruttoinlandsprodukt pro Kopf

Das Bruttoinlandsprodukt stellt die wichtigste gesamtwirtschaftliche Kenngröße dar. Falls das BIP in einem Landkreis hoch ist könnte dies unter anderem daran liegen, dass

- + viele Personen in diesem Landkreis erwerbstätig sind,
- + oder das die Erwerbstätigen in Branchen mit hoher Produktivität arbeiten.

Falls der erste Punkt zutrifft sollte ein hohes BIP pro Kopf (berechnet als BIP pro **Einwohner**) tendenziell auch mit einer niedrigeren Arbeitslosenquote einhergehen.

```
options(scipen = 5)
bip_zeitreihe_namen %>%
  filter( Jahr >= 2000 ) %>%
  group_by(ost_name, Jahr) %>%
  mutate( durchschnitt = mean(bip_pro_kopf),
          ulm = ifelse(landkreis_name == "Ulm", bip_
ggplot() +
  geom_line(aes(x = Jahr, y = bip_pro_kopf, group =
  geom_line(aes(x = Jahr, y = durchschnitt, group =
  geom_line(aes(x = Jahr, y = ulm, group = Regionals
  scale_y_continuous(trans = "log10") +
  theme_minimal() +
  facet_wrap(ost_name ~ .) +
  theme(legend.position = "none") +
  labs(title = "Ein Vergleich des BIP pro Kopf von o
        subtitle = "Durchschnittswerte in Dunkelblau,
        caption = "Quelle: Daten der Statistischen Äm
        x = "Jahr",
        y = "BIP pro Kopf")
```



Beschreiben und interpretieren Sie das gezeigte Schaubild.

Bruttoinlandsprodukt pro Kopf

Beschreibung:

- + Logarithmische Skalierung der y-Achse
- + Das Niveau des BIP pro Kopf ist in den ostdeutschen Landkreisen deutlich niedriger als in den westdeutschen.
- + Stadtkreis Ulm hat ein sehr hohes BIP pro Kopf, auch im Zeitablauf
- + Das BIP Pro Kopf nimmt im Zeitablauf in den ostdeutschen Landkreisen zu, doch erreicht es mit durchschnittlich 33936€ den Wert, welchen die westdeutschen Landkreise durchschnittlich in 2012 hatten!
- + In 2008/2009 gibt es überall einen Einbruch beim BIP pro Kopf, jedoch scheint dieser in den ostdeutschen Bundesländern nicht so stark gewesen zu sein

Interpretation:


- + Eine Wachstumsprozess im BIP pro Kopf findet in allen Landkreisen statt, jedoch gibt es für die ostdeutschen Landkreise, welche deutlich niedriger gestartet sind, keinen erkennbaren Anpassungsprozess in Form eines schnelleren Wachstums
- + Wir sehen auch keinen Anpassungsprozess der Landkreise in Westdeutschland
- + Fraglich ist, ob wir hier mit einem Anpassungsprozess von strukturschwachen Landkreisen überhaupt rechnen sollten

Bruttoinlandsprodukt pro Kopf

Daten ab 1992 vorhanden, d.h. wir können auch weiter zurück gehen:

- + **Allerdings:** Keine Daten zu *allen* Landkreisen, daher Vorsicht!
- + Hier sehen wir einen Anpassungsprozess in den 1990er Jahren
- + Anpassung verlangsamt sich, ab 2010 praktisch parallel

Ein Vergleich des BIP pro Kopf von ost- und westdeutschen Landkreisen
Zeitreihe ab 1992 bis 2022



Quelle: Daten der Statistischen Ämter der Länder und des Bundes.

Wachstum des BIP pro Kopf

Paneldaten beim BIP pro Kopf vorhanden, d.h. wir können:

- + Das **Wachstum** des BIP pro Kopf
- + Für alle Landkreise in Deutschland
- + Seit 2000 bis 2022

berechnen und visualisieren.


Können wir einen Anpassungsprozess über die Wachstumsraten des BIP pro Kopf feststellen?

```

bip_zeitreihe_namen %>%
  group_by(Regionalschlüssel) %>%
  arrange(Regionalschlüssel, Jahr) %>%
  mutate( bip_pro_kopf_wachstum = 100*(bip_pro_kopf
  ungroup() %>%
  group_by(ost_name, Jahr) %>%
  mutate( durchschnitt = mean(bip_pro_kopf_wachstum,
  ungroup() -> bip_wachstum

bip_wachstum %>%
  filter( Jahr >= 2000 ) %>%
  ggplot() +
  geom_line(aes(x = Jahr, y = bip_pro_kopf_wachstum,
  geom_line(aes(x = Jahr, y = durchschnitt, group =
  scale_color_manual(values = c("#D55E00", "#0072B2")
  theme_minimal() +
  labs(color = "Durchschnitt der Landkreise",
        title = "Die Wachstumsrate des BIP pro Kopf v
        caption = "Quelle: Daten der Statistischen Äm
        x = "Jahr",
        y = "Veränderung des BIP pro Kopf") +
  theme(legend.position = "none") +
  geom_text(aes(x=2000, y=40, label = "-- Durchschni
  geom_text(aes(x=2000, y=35, label = "-- Durchschni

```



Wachstum des BIP pro Kopf

Beschreibung:

- + Im Durchschnitt sehr ähnliche Wachstumsraten
- + Immer wieder vereinzelt sehr hohe Wachstumsraten pro Landkreis
 - + Hängt vermutlich mit großen Projekten auf Landkreisebene zusammen
- + Der Einbruch in der Finanzkrise ist sowohl bei ost- als auch westdeutschen Landkreisen zu sehen

Interpretation:

- + Es findet keine Anpassung des BIP pro Kopf über die Zeit statt
- + Die Gelder durch den Soli-Ausgleich führen nicht zu der (erhofften) starken Aufholjagd
- + Ostdeutsche Landkreise haben sich stark entwickelt
 - + Diese Entwicklung sollte jedoch nicht absolut, sondern relativ zu westdeutschen Landkreisen betrachtet werden

Es ist kein Anpassungsprozess ersichtlich, dafür sind die Wachstumsraten zu ähnlich.

Bruttoinlandsprodukt pro Kopf

Bisherige Grafiken:

- + Punktwolke + Boxplot zeigt die Verteilung
- + Liniendiagramm zeigt die Entwicklung

Alternative Darstellungen der Verteilung:

- + Histogramm (nächste Folie)
- + Kerndichteschätzer (siehe ausführliche Case-Study)

Alternative Darstellung der Entwicklung:


- + Small multiples (siehe ausführliche Case-Study)
- + Slopechart (siehe z.B. [Data Vizualisation von Claus Wilke](#) mit [Code hier](#))
- + Viele unterschiedliche Grafiken in der [R Graph Gallery](#) mit dem dazugehörigen Code

```

gesamtdaten %>%
  group_by(ost_name) %>%
  summarise(durchschnitt = mean(bip_pro_kopf, na.rm
  ungroup() -> mittel


ggplot(gesamtdaten, aes(x = bip_pro_kopf)) +
  geom_histogram(data = filter(gesamtdaten, bip_pro_
  geom_vline(data = mittel, aes(xintercept = durchsc
  facet_grid(ost_name~.) +
  theme_bw() +
  labs(title = "Verteilung des BIP pro Kopf für Ost-
    subtitle = "Beobachtungen auf Landkreisebene
    x = "BIP pro Kopf",
    y = "Anzahl an Beobachtungen")

```



Verteilung des BIP pro Kopf in 2022

Verteilung des BIP pro Kopf für Ost- und Westdeutschland
Beobachtungen auf Landkreisebene in 2022



Verteilung des BIP pro Kopf in 2022

Das Histogramm bestätigen das Bild des Boxplots:

- + Deutliche Unterschiede zwischen ost- und westdeutschen Landkreisen in 2022
- + Deutlich mehr Ausreißer nach oben bei westdeutschen Landkreisen
- + Verteilung ist für ostdeutsche Landkreise enger um den Mittelwert für das BIP pro Kopf von 33936€
- + Mittelwert und Median für westdeutsche Landkreise liegt deutlich weiter auseinander und zeigt, dass es hier mehr Ausreißer in den Daten gibt

Verschuldung der einzelnen Landkreise

Verschuldung

Warum könnte die Verschuldung des öffentlichen Haushalts ein Indikator für eine hohe Arbeitslosenquote sein?

Darstellung der Verschuldung der Landkreise mittels einer Deutschlandkarte.

Beschreiben und interpretieren Sie die folgende Grafik.


```

ggplot(
  # Datensatz
  data = schulden_landkreise_anteil
) +
  geom_sf(
    mapping = aes(
      fill = fct_relevel(anteil_schulden, ">10%", af
    ),
    color = "white",
    size = 0.1
  ) +
  # Viridis Farbschema
  scale_fill_viridis_d(
    option = "inferno",
    name = "Anteil der Schulden\nam BIP",
    alpha = 0.8, # Deckkraft der Füllung
    begin = 0.1,
    end = 0.9,
    direction = -1,
    guide = guide_legend(reverse = T)) +
  # etwas dickere Linien für Bundeslandgrenzen
  geom_sf(
    data = bundesland,
    fill = "transparent",
    color = "black",
    size = 0.5
  ) +
  # Titel
  labs(x = NULL,
       y = NULL,
       title = "Wie verschuldet sind die deutschen L
       subtitle = "Öffentliche Schulden im Vergleich

```


Wie verschuldet sind die deutschen Landkreise?

Öffentliche Schulden im Vergleich zum BIP in 2023



Wie verschuldet sind die deutschen Landkreise?

Öffentliche Schulden im Vergleich zum BIP in 2023



Verschuldung

Beschreibung:


- + Niedrige Verschuldung im Verhältnis zum BIP: Baden-Württemberg, Bayern, Sachsen und Niedersachsen
- + Mittlere Verschuldung: Rheinland-Pfalz, Brandenburg, Hessen, Schleswig-Holstein
- + Hohe Verschuldung: Sachsen-Anhalt, Thüringen, Nordrhein-Westfalen, Saarland, Mecklenburg-Vorpommern

Interpretation:


- + Strukturschwache Landkreise sind vermehrt in Ostdeutschland zu finden, allerdings scheint es eher ein Nord/Süd Gefälle als ein Ost/West Gefälle zu geben
- + Die ehemalige Herzkammer der deutschen Industrie, das Ruhrgebiet, leidet unter dem Strukturwandel hin zu erneuerbaren Energien
 - + Es fallen hier wichtige Steuereinnahmen für die öffentliche Hand weg

Vergleich der Arbeitslosenquote und Verschuldung

Wie verschuldet sind die deutschen Landkreise?
Öffentliche Schulden im Vergleich zum BIP in 2023



Arbeitslosigkeit in Deutschland
Dargestellt ist die Arbeitslosenquote für alle Landkreise in 2023



Vergleich der Arbeitslosenquote und Verschuldung

- + Tendenziell sind die Landkreise mit höheren Schulden auch die mit einer höheren Arbeitslosenquote
- + Verschuldung könnte ein erklärender Faktor für die Arbeitslosenquote sein
- + Grafisch ist der Zusammenhang jedoch nicht eindeutig verifizierbar
 - + Um Zusammenhänge deutlich zu machen müssen wir uns der **bivariaten deskriptiven Statistik** bemühen, insbesondere **Streudiagrammen** und **Korrelationsmatrizen**

Karten sind eine schöne Art geografisch unterschiedliche Informationen darzustellen, allerdings ist das Auge schlecht darin Farbverläufe zu unterscheiden!

Bei Karten immer eine sehr kontrastreiche Farbpalette verwenden!

AUFGABE - EIGENE GRAFIK ERSTELLEN

Ziel: Erstellen und interpretieren Sie effektive Visualisierungen der Einkommensverteilung in Deutschland.

Ablauf:

- + Gruppenbildung (4-5 Personen)
- + Datenauswahl & Analyse: Welche Information möchten Sie visualisieren? (Zeitreihe oder Querschnitt aus 2022?)
- + Visualisierung: Was ist die geeignete Grafik für ihre Fragestellung? Lassen Sie sich von [R Graph Gallery](#) oder der [Case-Study](#) inspirieren und erstellen Sie die für Sie passende Grafik in R
 - + Nutzen Sie die [R Graph Gallery](#) und [Chat AI](#) für die Erstellung
- + Interpretation der Grafik: Diskutieren Sie die Grafik in der Gruppe
- + Upload: Code für Grafik + kurze Interpretation im Google Forms hochladen: <https://forms.gle/R4qJEegZnFoTHU7f7>
- + Feedback-Runde im Plenum: Anonymes Feedback von Kommiliton*innen und mir.

Materialien: Laptops mit R, RStudio, bereitgestellter Datensatz zu Einkommensdaten

Erkenntnisse: Effektive Grafiktypen auswählen und interpretieren + Teamarbeit stärken.

30:00

Hinweise zum Prompting von Chat AI

Wie sollte ein Prompt aufgebaut sein?

- + **Aufgabe:** Was soll Chat AI tun?
 - + Möglichst genau und spezifisch sein
- + **Instruktionen:** Wie soll Chat AI es tun?
 - + Soll Chat AI eine besondere Persona sein?
 - + Beispiele für den gewünschten Output mitgeben
 - + Chat AI fragen zur Lösung Schritt-für-Schritt zu kommen
- + **Kontext:** Was sollte Chat AI zu seiner Aufgabe wissen?
 - + Wie passt die Aufgabe z.B. zur Vorlesung die Sie gerade besuchen?

Wenn Sie nicht weiter wissen, dann Fragen Sie Chat AI welche Infos es noch benötigt

- + "Sag mir, welche Informationen du benötigst, um ..."
- + "Stelle mir 5 Fragen, die dir helfen werden, mir die bestmögliche Antwort zu geben."

Wenn Sie glauben Chat AI hat einen Fehler gemacht, dann sagen Sie ihm dies

Komplexe Aufgaben in kleine Unteraufgaben herunterbrechen

Bivariate deskriptive Analyse

Die Korrelation

Bisher: Univariate Analyse, d.h. nur eine Variable

Jetzt: Bivariate Analyse, d.h. Zusammenhang zwischen **zwei** Variablen untersuchen

Hierzu nutzen wir die Korrelation der Variablen!

Der Korrelationskoeffizient für zwei Variablen $(x_1, y_1), \dots, (x_n, y_n)$ ist definiert als:

$$\rho = \frac{1}{n} \sum_{i=1}^n \left(\frac{x_i - \mu_x}{\sigma_x} \right) \left(\frac{y_i - \mu_y}{\sigma_y} \right)$$

mit μ_x, μ_y als Mittelwerte von $x_1, \dots, x_n$ und $y_1, \dots, y_n$. σ_x, σ_y sind die Standardabweichungen von diesem Mittelwert. ρ wird üblicherweise genutzt um den Korrelationskoeffizienten zu bezeichnen.

Wie hängt die Arbeitslosenquote in den einzelnen Landkreisen mit deren BIP-pro-Kopf-Wachstum zusammen?

Korrelation zwischen Arbeitslosenquote und BIP-pro-Kopf-Wachstum

Wir können uns die oben beschriebene Formel bzgl. des Zusammenhangs von zwei Variablen immer auch grafisch verdeutlichen

- + Wir haben zwei Dimensionen
 - + Variable x: BIP-pro-Kopf-Wachstum
 - + Variable y: Arbeitslosenquote

Im Streudiagramm können wir Variable x auf der x-Achse und Variable y auf der y-Achse abtragen

Korrelation zwischen Arbeitslosenquote und BIP-Wachstum

- ✚ Es fallen die Ausreißer ins Auge (+20% und -12%)
 - ✚ Vorheriges Jahr hohes/niedriges BIP, dadurch jetzt niedriges/hohes BIP-Wachstum
 - ✚ Die Energiekrise war bei den negativen Wachstumsraten der Auslöser (Ludwigshafen mit BASF war der betroffene Landkreis)
- ✚ Insgesamt scheint der Zusammenhang jetzt nicht so stark zu sein
 - ✚ Punktwolke deutet auf einen leicht negativen Zusammenhang hin


Korrelationskoeffizient:

```
cor(gesamtdaten$alo_quote,  
    gesamtdaten$bip_pro_kopf_wachstum,  
    use = "pairwise.complete.obs")
```

```
## [1] 0.05449384
```

Nun sollten wir noch die Korrelation zwischen Arbeitslosenquote und Verschuldung anschauen!

```
cor_alo_verschuldung <- cor(gesamtdaten$alo_quote, g
gesamtdaten %>%
  ggplot(aes(x = anteil_schulden, y = alo_quote)) +
  geom_point() +
  labs( x = "Anteil der Schulden am BIP in %",
        y = "Arbeitslosenquote in %",
        title = "Korrelation der öffentlichen Versch
  theme_minimal() +
  geom_text(x = 0.02, y = 13, label = paste("r = ", a
```



Korrelation zwischen Arbeitslosenquote und Verschuldung

Hier ist der positive Zusammenhang zwischen Verschuldung (x-Achse) und Arbeitslosenquote (y-Achse) deutlicher

Korrelationskoeffizient zeigt mit $\rho = 0.54$ auch einen starken Zusammenhang

ρ	Beschreibung (nährungsweise)
+/- 0.1-0.3	Schwacher
+/- 0.3-0.5	Mittel
+/- 0.5-0.8	Stark
+/- 0.8-0.9	Sehr stark

Wir sehen eine positive Korrelation zwischen der Verschuldung von Landkreisen und deren Arbeitslosenquoten.

Interpretation der Korrelation

- + Hat an sich keine intuitive quantitative Interpretation
- + Ist eine univariate Repräsentation des Zusammenhangs zweier Variablen
- + Kann dabei helfen stark korrelierte Variablen im Datensatz aufzuzeigen
 - + Dies ist für eine spätere lineare Regression wichtig
 - + Stichwort Multikollinearität

Im nächsten Semester beschäftigen wir uns mit der linearen Regression, hier können die Koeffizienten direkt interpretiert werden.

Zusammenfassung und Ausblick

Dieses Semester: Deskriptiven Statistik

Nächstes Semester: Induktive Statistik, insbesondere durch lineare Regressionen

Was haben wir bisher gelernt?

- + Daten in R einlesen
- + Diese Daten kompakt mittels Tabellen und Grafiken beschreiben
- + Den Zusammenhang einzelner Variablen untersuchen